



Chpt.6 Sampling and Distribution

第六章 样本及抽样分布



概率论：

- 假设(已知)随机变量服从某一分布，研究它的性质、特点与规律，如数字特征、分布函数的特性；
- 人类客观对实践的总结形成了概率论；

但是我们可以问：

- 概率所描述的知识是如何获取的？
比如，假如 X 服从正态分布，如何获取其参数？
- 实际中，如何判断一个随机变量是否服从某一分布。
比如，如何判断 X 是否为正态分布？



数理统计：

- 随机变量其分布未知或者不完全知道(如：是正态分布，但不知参数)，期望通过重复的、独立的观察得到许多数据，以概率论为理论基础，通过对这些数据的分析，估计分布的参数，乃至推断出随机变量的分布。
- 统计要进行抽样、需要推断，这些工作形成了一定的理论：统计推断理论。

统计推断的理论基础：



□ 概率论

描述了一些随机现象，以及研究随机现象的手段；

□ 大数定理

1 频率稳定性： 事件A发生的频率以概率收敛到概率p

$$\frac{n_A}{n} \xrightarrow{p} p \quad (n \rightarrow \infty)$$

2 算术均值稳定性： $\frac{1}{n}(X_1 + X_2 + \cdots + X_n) \xrightarrow{p} \mu \quad (n \rightarrow \infty)$

□ 中心极限定理

大量相互独立的随机因素的综合影响，尽管这诸多的因素之分布是未知的，但是他们的和服从正态分布。

6.1 样本概念--总体、个体

[定义]:

- 对某一数量（或几个）指标进行随机实验、观察，将试验的全部可能的观察值称为总体。
- 每个可能的观察值称为个体
- 总体中所包含的个体的总数称为总体的容量。容量有限的称为有限总体，容量为无限的称为无限总体。

总体是对对象某些指标的所有观察的值:

观察全校本科生的身高，得到12000个身高观测值；

扔硬币10000次，观察反正面的情况，得到10000个数值。

由此见到这些值有些会相同的，数目也可以是无限种的。



随机变量与总体的区别：

[1] 随机变量与基本随机事件相对应，随机变量显然只是一组互异的值，进一步对应每个值(或一个区间)出现的可能性大小

总体是从另一个角度，所有试验结果一一罗列出，所以可能出现大量相等的值。

Example: 随机抛一枚硬币， X 表示随机变量，正面为0，反面为1

X	0	1
p	0.5	0.5

对此试验进行观察10000次，总体为

序号	1	2	3	4	...	10000
取值	0	1	0	0	...	1

随机变量与总体的区别：



[2] 总体中的每个值是对随机变量 X 的观察值，这样一个总体对应一个随机变量；

总体的研究 $\longleftrightarrow$ 随机变量的 X 的研究

随机变量的分布、数字特征就称为总体的分布、数字特征

[3] 总体是从统计的角度看
随机变量是从概率角度看的


问题：在实际中总体的分布是未知的，如何解决？

途径一：逐个观察总体中的每个个体

不现实、不可行（具有破坏性、无限则不可能）

途径二：选取有代表性的个体

不知道总体，难以选择有代表性的个体



抽样：对总体进行一次观察并记录其结果（取值是多种可能），称为一次抽样；对 X 独立进行 n 次观察，并将结果按顺序记为 $X_1, \dots, X_n$

样本：随机抽取部分个体，以用于推断总体的特性。

这是从理论上将抽样，实际中一经完成，得到一组实数值， $x_1, x_2, \dots, x_n$ 称为**样本值**。



从总体中抽取样本必须满足：

- (1) **随机性** 为使样本具有充分的代表性，抽样必须是随机的，应使总体中的每一个个体都有同等的机会被抽取到.
- (2) **独立性** 各次抽样必须是相互独立的，即每次抽样的结果既不影响其它各次抽样的结果，也不受其它各次抽样结果的影响.

称这种随机的、独立的抽样为**简单随机抽样**
由此得到的样本称为**简单随机样本**.

从总体中抽取样本必须满足：



若从总体中进行放回抽样，属于简单随机抽样，得到的样本就是简单随机样本；

若从有限总体中进行不放回抽样，则不是简单随机抽样。

当总体容量 N 很大而样本容量 n 较小($n/N \leq 10\%$)时，可近似看作放回抽样，从而可近似看作简单随机抽样，得到的样本也可近似地作为简单随机样本。

6.1 样本概念

从总体中抽取容量为 n 的样本，就是对代表总体的随机变量 X 随机地、独立地进行 n 次观测，每次观测的结果仍可以看作一个随机变量。

n 次观测的结果就是 n 个随机变量： $X_1, \dots, X_n$ ，它们相互独立，并与总体 X 服从相同的分布。

若将样本 $X_1, \dots, X_n$ 看作一个 n 维随机变量 $(X_1, \dots, X_n)$ ，则

(1) 当总体 X 是离散随机变量，且概率分布为 $p(x)$ 时， $(X_1, \dots, X_n)$ 的概率分布

$$p(x_1, \dots, x_n) = p(x_1)p(x_2) \cdots p(x_n)$$

(2) 当总体 X 是连续随机变量，且概率密度为 $f(x)$ 时， $(X_1, \dots, X_n)$ 的概率密度

$$f(x_1, \dots, x_n) = f(x_1)f(x_2) \cdots f(x_n)$$

6.2 统计量

背景：为了对总体 X 的某些概率特征(分布、均值、方差)作出推断，需要考虑各种适用的样本的，由函数满足的性质进一步得到一定的推断。

如大数定理（辛钦）： $X_1, \dots, X_n$ 独立同分布，且 $E(X_i)=\mu$ ，

则
$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{p} \mu$$

样本是总体 X 的代表和反映，容量为 n 的样本 $X_1, \dots, X_n$ ，可以看作是一个 n 维随机变量 $(X_1, \dots, X_n)$ ，则
$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{p} \mu$$

如果有一组样本值 $x_1, x_2, \dots, x_n$ ，那么我们可以估计得到
$$\mu \approx \frac{1}{n} (x_1 + x_2 + \dots + x_n)$$

6.2 统计量



来自总体 X 的 n 个样本 $X_1, \dots, X_n$ 构成 n 维随机变量 $(X_1, \dots, X_n)$,
其函数 $g(X_1, \dots, X_n)$, 若其中不含任何未知量, 则称其为
统计量。

统计量都是随机变量, 由样本 $X_1, \dots, X_n$ 的观测值 $x_1, \dots, x_n$,
算得的函数值 $g(x_1, \dots, x_n)$ 是统计量 $g(X_1, \dots, X_n)$ 的观测
值.

研究规律得用随机变量

实际应用可以直接用观测值了

常用统计量及其观测值：

(1) 样本均值 $\bar{X} = \frac{1}{n} \sum_{k=1}^n X_k$ 观测值为 $\bar{x} = \frac{1}{n} \sum_{k=1}^n x_k$

(2) 样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$

观测值为 $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$

(3) 样本标准差 $S = \sqrt{S^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$

观测值为 $s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$

常用统计量及其观测值：

(4) 样本k阶原点矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$

观测值为 $a_k = \frac{1}{n} \sum_{i=1}^n x_i^k$

(5) 样本k阶中心矩 $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$

观测值为 $b_k = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k$

我们来比较一下

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad Y_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

假 $E(X_i) = \mu \quad D(X_i) = \sigma^2$

则 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad E(\bar{X}) = \mu, \quad D(\bar{X}) = \frac{1}{n} \sigma^2$

$$S^2 \xrightarrow{P} \sigma^2$$

$$Y_n^2 \xrightarrow{P} \sigma^2$$

$$S^2 \approx \sigma^2$$

$$y_n^2 \approx \sigma^2$$

假如我们要用样本估计 σ^2 时，用 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$

而不用 $Y_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 。盖因前者均值为 σ^2

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$= \frac{1}{n-1} \sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2)$$

$$= \frac{1}{n-1} \sum_{i=1}^n X_i^2 - 2\bar{X} \frac{1}{n-1} \sum_{i=1}^n X_i + \frac{n}{n-1} \bar{X}^2$$

$$= \frac{1}{n-1} \sum_{i=1}^n X_i^2 - 2 \frac{n}{n-1} \bar{X}^2 + \frac{n}{n-1} \bar{X}^2$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n X_i^2 - \frac{n}{n-1} \bar{X}^2$$

$$E(X_i^2) = D(X_i) + (EX_i)^2 \quad E(\bar{X}^2) = D(\bar{X}) + (E\bar{X})^2$$

$$E(X_i^2) = \sigma^2 + \mu^2 \quad E(\bar{X}^2) = \frac{\sigma^2}{n} + \mu^2$$

$$E(S^2) = \frac{1}{n-1} \sum_{i=1}^n E(X_i^2) - \frac{n}{n-1} E(\bar{X}^2)$$

$$= \frac{n}{n-1} (\sigma^2 + \mu^2) - \frac{n}{n-1} \left(\frac{1}{n} \sigma^2 + \mu^2 \right)$$

$$= \sigma^2$$

$$\begin{aligned}
 Y_n^2 &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \\
 &= \frac{n-1}{n} \bullet \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \\
 &= \frac{n-1}{n} S^2
 \end{aligned}$$

$$\begin{aligned}
 E(Y_n^2) &= \frac{n-1}{n} ES^2 \\
 &= \frac{n-1}{n} \sigma^2
 \end{aligned}$$

6.3 抽样分布



样本是随机变量

统计量是样本的函数，从而统计量也是随机变量

统计量的分布称为抽样分布

为什么要研究抽样分布：

- 一般而言，总体分布已知，抽样分布也是知道的，但是确切得到是困难的；
- 从另外一个角度，我们希望由统计量的分布（特别是在观测值得到后），估计、推断出总体的一些特征。我们希望研究统计分布，以便作出统计推断。

几类抽样分布



□ 样本均值分布 $\frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1)$

□ T分布 $t = \frac{\bar{X} - \mu}{S / \sqrt{n}} \sim t(n-1)$

□ χ^2 分布 $\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 \sim \chi^2(n) \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$

□ F分布 $\frac{S_1^2 / \sigma_1^2}{S_2^2 / \sigma_2^2} : F(n_1 - 1, n_2 - 1)$

注意： 以上是对 $X \sim N(\mu, \sigma^2)$ 而言的；取得 n 个样本



一. 样本均值分布

假设总体分布的均值与方差都是已知的，那么我们可以对来自总体的多个样本的均值做出估计。

假设 $X_1, \dots, X_n$ 是来自总体 X 的独立样本, 样本均值为

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad . \quad \text{一般情况下我们知道} \quad \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \rightarrow N(0, 1)$$

假设 $X_1, \dots, X_n$ 是来自正态总体 $X \sim N(\mu, \sigma^2)$ 的独立样本, 则样本均值 $\bar{X}$ 服从正态分布 $N(\mu, \frac{\sigma^2}{n})$, 标准量服从标准正态分布 $\frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1)$



一. 样本均值分布

🥤 案例1：可乐装填量的质检（正态总体）

背景

某工厂罐装可乐的标准容量为 330ml，单罐容量的标准差为 5ml（总体服从正态分布）。质检员每日随机抽取 25 罐计算平均容量。

关键问题

样本均值 $\bar{x}$ 会如何波动？

抽样规律

1. $\bar{x}$ 的分布中心仍在 330ml
2. $\bar{x}$ 的波动幅度（即抽样分布的标准差）为：

$$\frac{\text{单罐标准差}}{\sqrt{\text{样本量}}} = \frac{5}{\sqrt{25}} = 1 \text{ ml}$$

3. 95% 的抽样结果中， $\bar{x}$ 落在 $[330 - 1.96 \times 1, 330 + 1.96 \times 1] = [328.04, 331.96]$



一. 样本均值分布

👤👩👧 案例2：家庭孩子数量的调查（偏态总体）

背景

某城市家庭孩子数量分布：

- 60% 家庭有 0-1 个孩子，30% 有 2 个，10% 有 3-5 个
- 总体均值 $\mu = 1.2$ ，单家庭标准差 $\sigma = 1.25$

抽样对比

样本量	样本均值 $\bar{x}$ 的波动幅度	分布形态变化
$n = 5$	$\frac{1.25}{\sqrt{5}} \approx 0.56$	右偏（类似总体）
$n = 50$	$\frac{1.25}{\sqrt{50}} \approx 0.18$	接近正态分布

二. χ^2 分布



前面我们更多地讨论了样本均值的分布，关于样本方差有何种分布？

一般的总体不会得到很直接的结果；

对于正态总体 $X \sim N(\mu, \sigma^2)$ ，则统计量 $\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2$ 服从自由度为 n 的 χ^2 分布. 事实上

$$Y_i = (X_i - \mu) / \sigma \sim N(0,1) \quad (i=1,2,\dots,n)$$

且相互独立，由以下定理知

$$\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 = Y_1^2 + \dots + Y_n^2 \sim \chi^2(n)$$

二. χ^2 分布



[定义6.1] 设随机变量 $X_1, \dots, X_n$ 是来自标准正态总体

$X \sim N(0,1)$ 的独立样本。则随机变量 $\chi^2 = X_1^2 + X_2^2 + \dots + X_n^2$


服从自由度为 n 的 χ^2 分布，记为 $\chi^2(n)$ ，其概率密度：

$$f_{\chi^2}(x) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma\left(\frac{n}{2}\right)} x^{\frac{n}{2}-1} e^{-\frac{x}{2}}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

Remark 1: χ^2 分布具有可加性, 也就是说,

$\chi_1^2 \sim \chi^2(n_1), \chi_2^2 \sim \chi^2(n_2)$ 且它们相互独立,

则 $\chi_1^2 + \chi_2^2 \sim \chi^2(n_1 + n_2)$




Remark 2: $\chi^2 \sim \chi^2(n)$

则 $E(\chi^2) = n$, $D(\chi^2) = 2n$

对不同的自由度 n 及不同的数 $\alpha(0 < \alpha < 1)$, 满足的

$$P\{\chi^2 > \chi_\alpha^2(n)\} = \int_{\chi_\alpha^2(n)}^{\infty} f(x)dx = \alpha$$

值 $\chi_\alpha^2(n)$ 称为 χ^2 分布的 α 分位数。



二. χ^2 分布



想象一个“异常检测器”

工厂质检员每天检查流水线：

- 查5个零件 → 每个零件有“正常/异常”指示灯
- 红灯计数 = 当天异常零件数（比如2个红灯）

形态：多数日子红灯少（0~2个），红灯多的日子很少（右偏）

本质：卡方分布就是“异常事件数量”的概率分布图

二. χ^2 分布



把卡方分布想象成“闯关游戏得分”：

- 游戏规则：5道关卡，每关随机出现陷阱
- 得分 = 触发陷阱的次数
- 得分分布：
 - 0分（完美通关）：20%玩家
 - 1~2分（正常）：65%玩家
 - 5分（全踩中）：<1%玩家（长尾）

卡方分布 = 倒霉程度的概率分布

自由度越大（关卡越多），越容易得中等分数（分布越对称）



.....[定义6.2] 若随机变量 $X \sim N(0,1)$, $Y \sim \chi^2(n)$,

则 $t = \frac{X}{\sqrt{Y/n}} \sim t(n)$, 概率密度

$$f_t(t) = \frac{\Gamma(\frac{n+1}{2})}{\Gamma(\frac{n}{2})\sqrt{n\pi}} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}, \quad -\infty < t < +\infty$$



三. T分布

[定理三] 若总体服从正态分布 $X \sim N(\mu, \sigma^2)$, $\{X_i\}, S$

分别是来自总体的样本与样本标准差, $S^2 = \frac{1}{n-1} \sum_{k=1}^n (X_i - \bar{X})^2$

那么随机变量 $t = \frac{\bar{X} - \mu}{S/\sqrt{n}}$ 服从自由度为n-1的t分布, 记

为 $t \sim t(n-1)$, 其概率密度为:

$$f_t(t) = \frac{\Gamma\left(\frac{n}{2}\right)}{\Gamma\left(\frac{n-1}{2}\right)\sqrt{(n-1)\pi}} \left(1 + \frac{t^2}{n-1}\right)^{-\frac{n}{2}}, \quad -\infty < t < +\infty$$

Remark1: 其中伽玛函数 $\Gamma(\alpha) = \int_0^{\infty} u^{\alpha-1} e^{-u} du \quad (\alpha > 0)$,

有如下性质:

$$(1) \quad \Gamma(\alpha + 1) = \alpha \Gamma(\alpha)$$

$$(2) \quad \Gamma(n) = (n-1)!$$

$$(3) \quad \Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$$


Remark2: 由定理可以知道总体为正态分布 $X \sim N(\mu, \sigma^2)$

随机变量 $t = \frac{\bar{X} - \mu}{S/\sqrt{n}}$ 服从自由度为n-1的 t 分布。

$t = \frac{\bar{X} - \mu}{S/\sqrt{n}}$ 中如 μ 是非统计量(未知), 由对 t 的分析可以

估计出 μ , 而且是在 σ 也未知的情况下

Remark 3: t 分布的分布曲线关于 $t = 0$ 对称;



Remark 3: t 分布的形式如上所言。之所以叫做 t 分布是因为在1900年代，Dublin城的W.S.Gosset用笔名“Student”发表了一篇文章提出了该分布。

Remark 5: 由 t 分布的出处，我们可以知道它是对 $\frac{\bar{X} - \mu}{\sigma / \sqrt{n}}$ 的一个近似，而后者在 n 无限大时趋近于标准正态分布。故此，可以推测当自由度 n 无限增大时, t 分布将趋近于标准正态分布 $N(0,1)$, 或者

$$f_t(t) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma(n/2)} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}} \rightarrow \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}$$



三. T分布

案例1：新药小规模临床试验（小样本的烦恼）

背景

某药厂研发降压药，由于成本限制：

- 只招募 **10名** 高血压患者试药
- 服药后平均降压值 $\bar{x} = 8 \text{ mmHg}$
- 样本标准差 $s = 3 \text{ mmHg}$

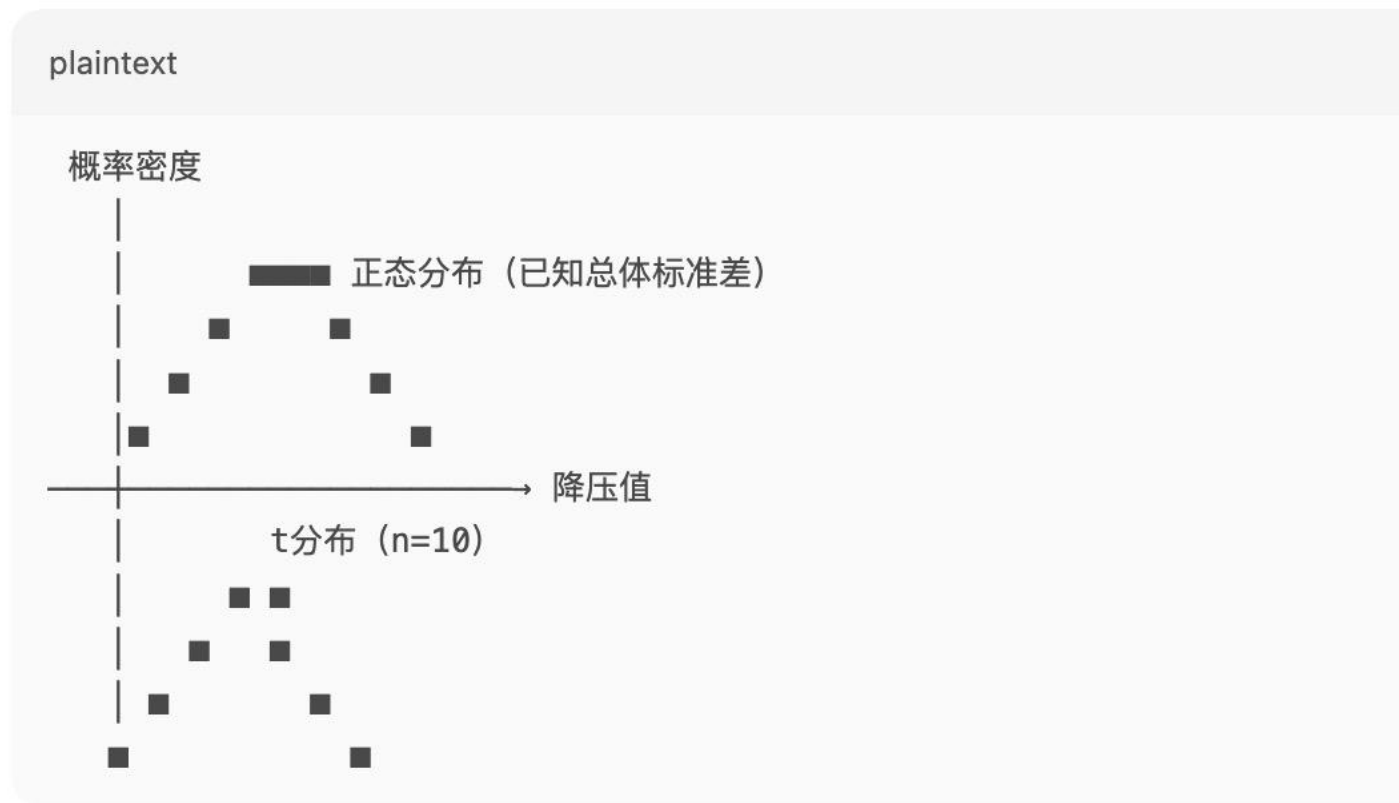
关键问题

如何估计所有高血压患者的平均降压效果？



三. T分布

正态分布 vs t分布对比图



- t分布尾巴更厚 → 对小样本的不确定性更大
- 95%置信区间：
 - 正态分布: $[8 - 1.96 \times 0.95, 8 + 1.96 \times 0.95] \approx [6.1, 9.9]$
 - t分布 (df=9): $[8 - 2.26 \times 0.95, 8 + 2.26 \times 0.95] \approx [5.9, 10.1]$ (范围更宽)



三. T分布

🔧 案例2：手机电池小批量抽检（方差未知的代价）

背景

质检员抽检 **8块** 新批次手机电池：

- 平均续航 $\bar{x} = 22$ 小时
- 样本波动 $s = 1.5$ 小时（无法获知总体标准差！）

不同样本量的置信区间对比

样本量	95%置信区间	分布类型
$n = 8$	[20.7, 23.3]小时	t分布 (df=7)
$n = 50$	[21.6, 22.4]小时	正态分布



三. T分布

案例3：南极科考站温度记录（极端环境小数据）

背景

科考员在冬季仅获得 **6天** 的户外温度：

- 日均温： -42°C
- 样本标准差： 5°C

t分布的现实意义：

核心规律：

1. 样本越小 $\rightarrow$ 尾巴越厚（补偿不确定性）
2. $n \geq 30$ 时 $\rightarrow$ t分布 $\approx$ 正态分布（尾巴变薄）

plaintext

真实均值可能范围：



- t分布给出更保守的区间（考虑极端天气风险）

科学决策：

- 若用正态分布，可能低估低温风险
- t分布（ $df=5$ ）95%区间： $[-42 \pm 2.57 \times 2.04] \approx [-47.2, -36.8]^{\circ}\text{C}$

分位点

[分位点] 随机变量 X , 对一个正数 α ($0 < \alpha < 1$), 满足

$P\{X > x_\alpha\} = \alpha$ 的值 x_α 称为 X 分布的 α 分位数.


对不同的自由度 n 及不同的数 α ($0 < \alpha < 1$), 满足

$$P\{t > t_\alpha(n)\} = \int_{t_\alpha(n)}^{\infty} f_t(t) dt = \alpha$$

的 $t_\alpha(n)$ 值称为 t 分布的 α 分位数。

由 $f_t(t)$ 的对称性知:

$$t_{1-\alpha}(n) = -t_\alpha(n)$$



[定理二] S^2 是来自正态总体 $X \sim N(\mu, \sigma^2)$ 的 n 个样本的方差，那么 $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$



四. 二个正态总体的统计量的分布

有时，需要比较来自两个总体的样本的方差， $F = S_1^2 / S_2^2$

[定理四] 如果 S_1^2 和 S_2^2 是两个 n_1, n_2 独立样本的方差，来自两个具有相同方差（但是未知）的独立正态总体，那么 S_1^2 / S_2^2 服从参数为 $n_1 - 1, n_2 - 1$ 的F分布，记为 $F \sim F(n_1 - 1, n_2 - 1)$

四. 二个正态总体的统计量的分布




[定义6.6] 若随机变量 $U \sim \chi^2(n_1), V \sim \chi^2(n_2)$, U 与 V 独立, 则

随机变量 $F = \frac{U/n_1}{V/n_2}$ 服从自由度为 (n_1, n_2) 的 F 分布, 记为 $F \sim F(n_1, n_2)$, 其概率密度为

$$f_F(z) = \begin{cases} \frac{\Gamma\left(\frac{n_1+n_2}{2}\right)}{\Gamma\left(\frac{n_1}{2}\right)\Gamma\left(\frac{n_2}{2}\right)} n_1^{\frac{n_1}{2}-1} n_2^{\frac{n_2}{2}-1} \frac{z^{\frac{n_1}{2}-1}}{(n_1 z + n_2)^{\frac{n_1+n_2}{2}}} & z > 0 \\ 0 & z \leq 0 \end{cases}$$

F分布

$F \sim F(n_1, n_2)$ 其中分子的自由度 n_1 为第一自由度；分母的自由度 n_2 为第二自由度。




Remark 1: 如果 $X \sim F(m, n)$, 则 $\frac{1}{X} \sim F(n, m)$ 。

F分布

满足 $\int_{F_\alpha(n_1, n_2)}^{\infty} f(x; n_1, n_2) dx = \alpha, \quad 0 < \alpha < 1$

称 $F_\alpha(n_1, n_2)$ 为F分布的 α 分位点。



Remark 2:

$$F_\alpha(n_1, n_2) = \frac{1}{F_{1-\alpha}(n_2, n_1)}.$$



🔪 案例1：双胞胎减肥计划（比较波动性）

背景

一对双胞胎尝试不同减肥方法：

- 哥哥（饮食控制）：每周体重变化记录 → 波动小
- 弟弟（运动减肥）：每周体重变化记录 → 波动大

计算波动比：

$$F = \frac{\text{弟弟的体重波动}}{\text{哥哥的体重波动}} = \frac{(\text{弟弟方差})}{(\text{哥哥方差})}$$

发现规律：

- 若两人波动相同 → $F \approx 1$
- 若弟弟波动更大 → $F > 1$

“ F 值多大才算‘明显不稳定’？”

☑ F分布给出概率答案：查表得临界值（如 $F_{0.05} = 4.0$ ）



案例2：两条生产线质量PK（方差齐性检验）

工厂问题

A生产线和B生产线生产同款螺丝：

- 抽检A线：10个螺丝，直径方差 $s_A^2 = 0.02 \text{ mm}^2$
- 抽检B线：8个螺丝，直径方差 $s_B^2 = 0.08 \text{ mm}^2$

计算方差比：

$$F = \frac{\text{波动大的线}}{\text{波动小的线}} = \frac{s_B^2}{s_A^2} = \frac{0.08}{0.02} = 4.0$$

F分布判断：

1. 分子自由度 $df_1 = 8 - 1 = 7$ (B线样本)
2. 分母自由度 $df_2 = 10 - 1 = 9$ (A线样本)
3. 查表得临界值 $F_{0.05}(7, 9) = 3.29$
4. $4.0 > 3.29 \rightarrow$ B线波动显著更大（需检修！）



🍎 终极生活类比

汽车省油性能对比：

- 车型A（10次加油）：油耗波动小 → 分母
- 车型B（8次加油）：油耗波动大 → 分子

$F\text{值} = B\text{的波动} / A\text{的波动}$

$F > \text{临界值} \rightarrow \text{B车型油耗不稳定！慎买！}$

[定理四] 设 $X_1, X_2, \dots, X_{n_1}$ 与 $Y_1, Y_2, \dots, Y_{n_2}$ 分别是来自正态总体 $N(\mu_1, \sigma_1^2)$ 和 $N(\mu_2, \sigma_2^2)$ 的样本，且两个样本独立。

$\bar{X} = \frac{1}{n_1} \sum_{i=1}^{n_1} X_i$, $\bar{Y} = \frac{1}{n_2} \sum_{j=1}^{n_2} Y_j$ 分别是两个样本的样本均值

$S_1^2 = \frac{1}{n_1 - 1} \sum_{i=1}^{n_1} (X_i - \bar{X})^2$, $S_2^2 = \frac{1}{n_2 - 1} \sum_{j=1}^{n_2} (Y_j - \bar{Y})^2$ 是各样本方差

则有：

$$[1] \quad \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0,1)$$

$$[2] \quad \frac{\frac{S_1^2}{\sigma_1^2}}{\frac{S_2^2}{\sigma_2^2}} = \frac{\frac{S_1^2}{S_2^2}}{\frac{\sigma_1^2}{\sigma_2^2}} \sim F(n_1 - 1, n_2 - 1)$$

[3] 当 $\sigma_1 = \sigma_2 = \sigma$ 时

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$$

$$\text{其中 } S_w = \sqrt{\frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}}$$

证明:

[1] 由 $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$, $X_1, X_2, \dots, X_{n_1}$ 与

$Y_1, Y_2, \dots, Y_{n_2}$ 分别是来自两个总体的简单样本

$X_1, X_2, \dots, X_{n_1}$ 的线性组合 $\bar{X} = \frac{1}{n_1} \sum_{i=1}^{n_1} X_i$ 服从正态分布 $N(\mu_1, \frac{\sigma_1^2}{n_1})$

同理 $\bar{Y} \sim N(\mu_2, \frac{\sigma_2^2}{n_2})$

又由于 $\bar{X}, \bar{Y}$ 独立, 其组合是正态分布, 所以

$$\bar{X} - \bar{Y} \sim N(\mu_1 - \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2})$$

其标准化随机变量 $\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1)$

[2] $\chi_1^2 = \frac{(n_1 - 1)S_1^2}{\sigma_1^2} \sim \chi^2(n_1 - 1)$

$$\chi_2^2 = \frac{(n_2 - 1)S_2^2}{\sigma_2^2} \sim \chi^2(n_2 - 1)$$

由于 S_1^2 与 S_2^2 独立,

$$\frac{\chi_1^2 / (n_1 - 1)}{\chi_2^2 / (n_2 - 1)} \sim F(n_1 - 1, n_2 - 1)$$

$$\frac{S_1^2 / \sigma_1^2}{S_2^2 / \sigma_2^2} = \frac{S_1^2 / S_2^2}{\sigma_1^2 / \sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$$

[3] 随机变量 $U = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sigma \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim N(0,1)$, 由上知, 统计量

$$\chi_1^2 = \frac{(n_1 - 1)S_1^2}{\sigma^2} \sim \chi^2(n_1 - 1)$$

$$\chi_2^2 = \frac{(n_2 - 1)S_2^2}{\sigma^2} \sim \chi^2(n_2 - 1)$$

又由于 S_1^2 与 S_2^2 独立, 利用 χ^2 分布的可加性知随机变量

$$V = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{\sigma^2} \sim \chi^2(n_1 + n_2 - 2)$$

随机变量U,V独立, 因此

$$\frac{U}{\sqrt{\frac{V}{n_1 + n_2 - 2}}} = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$$

$$S_w = \sqrt{\frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}}$$



[定理6.8] 假设 $X_1, \dots, X_n$ 是来自正态总体 $X \sim N(\mu, \sigma^2)$ 的独立样本，则样本均值 $\bar{X}$ 与样本方差 S^2 独立。

考研的试题中出现过本定理的应用！



典型习题



设 $(X_1, X_2, \dots, X_n)$ 是来自正态总体 X 的简单随机样, 本

$$Y_1 = \frac{1}{6} \sum_{i=1}^6 X_i, \quad Y_2 = \frac{1}{3} (X_7 + X_8 + X_9),$$

$$S^2 = \frac{1}{2} \sum_{i=7}^9 (X_i - Y_2)^2, \quad Z = \frac{\sqrt{2} (Y_1 - Y_2)}{S},$$

证明统计量 Z 服从自由度为 2 的 t 分布。

习题1



解：证 记 $DX = \sigma^2$ ，易见 $EY_1 = EY_2$, $DY_1 = \frac{\sigma^2}{6}$, $DY_2 = \frac{\sigma^2}{3}$.

由于 Y_1 和 Y_2 独立，可见 $E(Y_1 - Y_2) = 0$, $D(Y_1 - Y_2) = \frac{\sigma^2}{2}$.

从而 $U = \frac{Y_1 - Y_2}{\sigma / \sqrt{2}} \sim N(0, 1)$, 由正态总体样本方差的性质，知

$\chi^2 = \frac{2S^2}{\sigma^2}$ 服从自由度为2的 χ^2 分布.

由于 Y_1 与 Y_2 ， Y_1 与 S^2 ，以及 Y_2 与 S^2 独立，可见 $Y_1 - Y_2$ 与 S^2 独立

于是，由服从 t 分布随机变量的结构，知 $Z = \frac{\sqrt{2}(Y_1 - Y_2)}{S} = \frac{U}{\sqrt{\chi^2/2}}$

服从自由度为2的 t 分布.



习题2

设随机变量 X 与 Y 相互独立且都服从正态分布 $N(0, 3^2)$ ，而 $X_1, \dots, X_9$ 和 $Y_1, \dots, Y_9$ 分别是来自 X 与 Y 的简单随机样本，则统计量 $U = \frac{X_1 + \dots + X_9}{\sqrt{Y_1^2 + \dots + Y_9^2}}$ 服从 () 分布，参数为 () 。

解： $t, 9$

由于 $X_1 + \dots + X_9 \sim N(0, 81)$ ，则

$$\frac{1}{9}(X_1 + \dots + X_9) \sim N(0, 1), \quad \frac{1}{3}Y_1 \sim N(0, 1) \text{ 且相互独立}$$

$$\frac{1}{9}(Y_1^2 + \dots + Y_9^2) \sim \chi^2(9) \text{ 且与 } \frac{1}{9}(X_1 + \dots + X_9) \text{ 相互对立}$$

按 $t(9)$ 分布定义，知 $\frac{X_1 + \dots + X_9}{\sqrt{Y_1^2 + \dots + Y_9^2}}$ 服从 $t(9)$ 分布。



设 $X_1, \dots, X_n$ 是来自正态总体 $N(\mu, \sigma^2)$ 的简单随机样本, $\bar{X}$ 是样本均值, 记

$$S_1^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, S_2^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2,$$

$$S_3^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \mu)^2, S_4^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2.$$

则服从自由度为 $n-1$ 的 t 分布的随机变量是

$$(A) \quad t = \frac{\bar{X} - \mu}{S_1 / \sqrt{n-1}}, \quad (B) \quad t = \frac{\bar{X} - \mu}{S_2 / \sqrt{n-1}},$$

$$(C) \quad t = \frac{\bar{X} - \mu}{S_3 / \sqrt{n}}, \quad (D) \quad t = \frac{\bar{X} - \mu}{S_4 / \sqrt{n}}.$$

习题3



解： **B**

由于已知
$$\frac{\sqrt{n} (\bar{X} - \mu)}{\sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})^2}} \sim t(n-1),$$
 经过形式

变换, 它正是选项 (B), 而且 S_3 和 S_4 与 $\bar{X}$ 不独立,
故 (C) 和 (D) 是不成立的.

习题4



设总体 $X \sim N(\mu_1, \sigma^2)$ ，总体 $Y \sim (\mu_2, \sigma^2)$ ， $X_1, \dots, X_{n_1}$ 和 $Y_1, \dots, Y_{n_2}$ 分别是来自总体 X, Y 的简单随机样本，求

$$E \left| \frac{\sum_{i=1}^{n_1} (X_i - \bar{X})^2 + \sum_{i=1}^{n_2} (Y_i - \bar{Y})^2}{n_1 + n_2 - 2} \right|.$$

习题4



解：

$$\begin{aligned} & E \left[\frac{\sum_{i=1}^{n_1} (X_i - \bar{X})^2 + \sum_{i=1}^{n_2} (Y_i - \bar{Y})^2}{n_1 + n_2 - 2} \right] \\ &= \frac{1}{n_1 + n_2 - 2} E \left[\sum_{i=1}^{n_1} (X_i - \bar{X})^2 + \sum_{i=1}^{n_2} (Y_i - \bar{Y})^2 \right] \\ &= \frac{1}{n_1 + n_2 - 2} E[(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2] \\ &= \frac{1}{n_1 + n_2 - 2} [\sigma^2(n_1 - 1) + \sigma^2(n_2 - 1)] = \sigma^2 \end{aligned}$$



1 . 设统计量 $T \sim t(n)$, 则 $T^2 \sim$ _____ ;

2 . 设 $X \sim N(\mu, \sigma^2)$, $(X_1, X_2, \dots, X_n)$ 为样本 , $\bar{X}$ 是样本均值。则 $U = n\left(\frac{\bar{X} - \mu}{\sigma}\right)^2$ 服从的分布为_____ ;

3 . 设 $X \sim F(n_1, n_2)$ $P(X > F_\alpha(n_1, n_2)) = 0.1$ $Y = \frac{1}{X}$ 则 $P(Y < F_{1-\alpha}(n_2, n_1)) =$ _____ ;



4 . $X \sim N(0,4)$, (X_1, X_2, X_3) **为样本。若要求**

$[aX_1^2 + b(X_2 - X_3)^2] \sim \chi^2(2)$ 则 $(a,b) = \underline{\hspace{1cm}}$;

5 . 总体 X 与 Y 相互独立 , 且 $X \sim N(\mu_1, \sigma^2)$

$Y \sim N(\mu_2, \sigma^2)$ $(X_1, X_2, \dots, X_n)$ 与 $(Y_1, Y_2, \dots, Y_n)$ 是两总

体中抽取的独立样本。 S_1^2 与 S_2^2 是两样本方差

则 $\frac{(n-1)(S_1^2 + S_2^2)}{\sigma^2} \sim \underline{\hspace{1cm}}$ 。

答案 1. $F(1, n)$; 2. $\chi^2(1)$; 3. 0.1 ; 4. $(\frac{1}{4}, \frac{1}{8})$;

5. $\chi^2(2n-2)$



设总体 $X \sim N(\mu, 4)$, $(X_1, X_2, \dots, X_n)$ 是简单随机样本, $\bar{X}$ 为样本均值, (1) 若 $n = 25$, 计算 $P(|\bar{X} - \mu| < 0.1)$; (2) 若要求 $P(|\bar{X} - \mu| \leq 0.1) \geq 0.95$, 至少 n 取多大?

解: (1) 因为 $\frac{\bar{X} - \mu}{2} \cdot 5 \sim N(0, 1)$ 所以

$$\begin{aligned} P(|\bar{X} - \mu| < 0.1) &= P\left(\frac{|\bar{X} - \mu|}{2} \cdot 5 < 0.25\right) \\ &= 2\Phi(2.5) - 1 = 2 \times 0.5987 - 1 = 0.1974 \end{aligned}$$

(2) 为使 $P(|\bar{X} - \mu| \leq 0.1) \geq 0.95$

$$P(|\bar{X} - \mu| < 0.1) = P\left(\frac{|\bar{X} - \mu|}{2} \sqrt{n} < 0.05\sqrt{n}\right) \geq 0.95 = \Phi(1.65)$$

$$2\Phi(0.05\sqrt{n}) - 1 \geq 0.95 \quad \Phi(0.05\sqrt{n}) \geq 0.975 = \Phi(1.96)$$

$$0.05\sqrt{n} \geq 1.96 \quad n \geq 1536.64 \quad \text{所以 } n \text{ 至少取 } 1537.$$



例3 . 设 $X \sim N(0,1)$, $(X_1, X_2, \dots, X_6)$ **是简单随机样本,**
 $Y = (X_1 + X_2 + X_3)^2 + (X_4 + X_5 + X_6)^2$ **试决定常数** c ,
使 cY **服从** χ^2 **分布。**

解：因为 $(X_1 + X_2 + X_3) \sim N(0,3)$

$(X_4 + X_5 + X_6) \sim N(0,3)$ **所以**

$$\left(\frac{X_1 + X_2 + X_3}{\sqrt{3}}\right)^2 + \left(\frac{X_4 + X_5 + X_6}{\sqrt{3}}\right)^2 \sim \chi^2(2)$$

故 $c = \frac{1}{3}$ 。



例4 . $\bar{X} \sim N(\mu, \sigma^2)$ 抽取样本容量 $n=16$ 的简单随机样本 , $(X_1, X_2, \dots, X_n)$ 计算:

$$P\left(\frac{\sigma^2}{2} \leq \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2 \leq 2\sigma^2\right)$$

解 : 因为 $\frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} \sim \chi^2(n)$, 所以 ,

当 $n=16$ 时 , 有

$$\begin{aligned} P\left(\frac{\sigma^2}{2} \leq \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2 \leq 2\sigma^2\right) &= P\left(8 \leq \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} \leq 32\right) \\ &= 0.95 - 0.01 = 0.94 \end{aligned}$$



例5 . 设 $X \sim N(\mu, 4^2)$, $n=10$, $(X_1, X_2, \dots, X_n)$ **为样本,**

S^2 为样本方差 , 即 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ **已知**

$P(S^2 < a) = 0.9$ 求 a

解 : 因为 $\frac{(n-1)S^2}{16} \sim \chi^2(9)$ **所以**

$$P(S^2 < a) = P\left(\frac{(n-1)S^2}{16} < \frac{9}{16}a\right) = 0.9$$

$$\frac{9}{16}a = 14.684 \quad a = 26.105$$



例6 . $X \sim N(\mu_1, \sigma^2)$, $Y \sim N(\mu_2, \sigma^2)$ 且相互独立 ,

从 X 、 Y 两总体中分别抽取 $n_1 = 10$, 和 $n_2 = 15$
简单随机样本 , 样本方差分别为 S_1^2 与 S_2^2 计算

$$P(S_1^2 - 4S_2^2 > 0)$$

解 : 因为 , $\frac{S_1^2}{S_2^2} \sim F(9, 14)$ **所以**

$$P(S_1^2 - 4S_2^2 > 0) = P\left(\frac{S_1^2}{S_2^2} > 4\right) = 1 - 0.990 = 0.01$$