



Chpt.1 Basic Concepts of Probability

第一章 概率论的基本概念

1.2.2 样本空间



[定义 1.2]: 把随机试验所有的结果组成的集合 S 称为随机试验的样本空间。样本空间中的元素称为样本点。

Example 1.2.1 抛硬币：将一枚硬币抛三次，观察出现正面H、反面T的情况；

$S = \{ HHH, HHT, HTH, HTT, THH, THT, TTH, TTT \}$

1.2 Definition & Properties of Probability



1.2.3 随机事件

定义： 试验的样本空间 S 的子集称为 E 的随机事件

基本事件——样本空间中单个样本点

随机事件—— S 的子集

必然事件—— S 本身




不可能事件 ——空集 Φ

事件是可以关联的，事件之间的各种关联构成新的事件。

1.2.4 事件的关系与运算





- B包含A ($B \supseteq A$) If $x \in A \Rightarrow x \in B$
- 和事件（并）： $A \cup B = \{x \mid x \in A \text{ 或 } x \in B\}$
n个事件的和 $\bigcup_{i=1}^n A_i$, 可列（可数事件）和 $\bigcup_{i=1}^{\infty} A_i$
- 积事件（交）： $A \cap B = \{x \mid x \in A \text{ 且 } x \in B\}$
n个事件的交 $\bigcap_{i=1}^n A_i$, 有时记作 $A_1 A_2 \dots A_n$
可列（可数事件）交 $\bigcap_{i=1}^{\infty} A_i$





1.2.4 事件的关系与运算


- 差事件: $A - B = \{x \mid x \in A \text{ and } x \notin B\}$
- 互不相容(互斥): $A \cap B = \Phi$
- 逆事件(对立事件): $A \cup B = S, A \cap B = \Phi$
A的逆事件记为 $\overline{A} = S - A$
- 对称差: $A \Delta B = (A - B) \cup (B - A)$





1.2.4 事件的关系与运算

- 交换律: $A \cap B = B \cap A$
- 结合律: $A \cup (B \cup C) = (A \cup B) \cup C$
 $A \cap (B \cap C) = (A \cap B) \cap C$
- 分配律: $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$
 $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$
- 德摩根律: $\overline{A \cup B} = \overline{A} \cap \overline{B} \quad \overline{A \cap B} = \overline{A} \cup \overline{B}$



1.2.5 概率定义与基本特性



[定义1.3] 随机试验 E ，样本空间为 S ，其中事件的概率 $P(A)$ 满足：

[1] Nonnegative: $0 \leq P(A) \leq 1$

[2] Normalization: $P(S)=1$

[3] 可列可加性: $A_1, A_2, A_3, \dots$ 是两两互不相容的事件
则

$$P(A_1 \cup A_2 \cup A_3 \cup \dots) = P(A_1) + P(A_2) + P(A_3) + \dots$$

1.2.5 概率定义与基本特性



[1] 不可能事件概率为零: $P(\Phi)=0$

[2] 有限可加性:

$A_1, A_2, \dots, A_k$ 是两两互不相容的事件则

$$P(A_1 \cup A_2 \cup \dots \cup A_k) = P(A_1) + P(A_2) + \dots + P(A_k)$$

[3] 可减性:

$$A \subset B, \text{ 则 } P(B - A) = P(B) - P(A)$$

$$\text{特别地 } P(\bar{A}) = 1 - P(A)$$

[4] 不降性:

$$A \subset B, P(A) \leq P(B);$$

$$\forall \text{ 事件 } A, P(A) \leq 1$$

1.2.5 概率定义与基本特性



加法公式：


$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

可以利用面积原理加以说明

Proof:

$$A \cup B = A \cup (B - A \cap B)$$

$$\begin{aligned} P(A \cup B) &= P(A) + P(B - A \cap B) \\ &= P(A) + P(B) - P(A \cap B) \end{aligned}$$



奇加偶减

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum P(A_i) - \sum P(A_i A_j) + \sum P(A_i A_j A_k) + \cdots + (-1)^{n-1} P(A_1 A_2 \cdots A_n)$$

1.3.2 条件概率与乘法定理



[定义1.4] 概率是对随机事件发生可能性大小的描述，在一事件A发生的前提下，另一事件B是否发生依然是随机的，其发生的可能性大小与A的发生有关系，记这样的概率为 $P(B|A)$.

How to calculate $P(B|A)$

A是大前提，在A发生的前提下，看B发生的可能性；
假设A在S中有m个，AB有k个，总样本数是n个；
则

$$P(B|A) = k/m = \frac{k/n}{m/n} = \frac{P(AB)}{P(A)}$$

乘法定理



$$P(AB) = P(B|A)P(A)$$

$$P(ABC) = P(C|AB)P(AB) = P(C|AB)P(B|A)P(A)$$

$$P(A_1 A_2 \dots A_n) = P(A_n | A_1 A_2 \dots A_{n-1}) P(A_1 A_2 \dots A_{n-2} A_{n-1})$$

$$= P(A_n | A_1 A_2 \dots A_{n-1}) P(A_{n-1} | A_1 A_2 \dots A_{n-2}) P(A_1 A_2 \dots A_{n-2})$$

⋮

$$= P(A_n | A_1 A_2 \dots A_{n-1}) P(A_{n-1} | A_1 A_2 \dots A_{n-2}) \dots P(A_2 | A_1) P(A_1)$$

$$= P(A_1) P(A_2 | A_1) P(A_3 | A_1 A_2) \dots P(A_n | A_1 A_2 \dots A_{n-1})$$

积的概率分解为多个条件概率的积，而这些条件概率相对是容易计算的

1.3.3 独立事件



[定义1.2]: A 、 B 为两事件，如果满足
 $P(AB)=P(A)P(B)$ ，则称 A 、 B 相互独立。

[定理1.1] A 、 B 两事件， $P(A)>0$ ，如 A 、 B 相互独立，
则 $P(B|A)=P(B)$ 。反之也成立。

[定理1.2] 如事件 A 、 B 是独立的，则下列各对事件也独立：
 A 与 $\bar{B}$ ， $\bar{A}$ 与 B ， $\bar{A}$ 与 $\bar{B}$ 。

1.3.3 独立事件




事件 A, B 是独立的, 则 A 与 $\bar{B}$ 独立

如果证明了此, 我们就知道:

B 与 $\bar{A}$ 独立 (即 $\bar{A}$ 与 B 独立)

$\bar{A}$ 与 $\bar{B}$ 独立



Proof:

$$\begin{aligned} P(A\bar{B}) &= P\{A \cap (S - B)\} \\ &= P(A - AB) \\ &= P(A) - P(AB) \\ &= P(A) - P(A)P(B) \end{aligned}$$

$$\begin{aligned} &= P(A)\{1 - P(B)\} \\ &= P(A)P(\bar{B}) \end{aligned}$$

1.3.3 独立事件



[定义1.3] 三个事件的相互独立

$$P(AB)=P(A)P(B)$$

$$P(BC)=P(B)P(C)$$

$$P(AC)=P(A)P(C)$$


$$P(ABC)=P(A)P(B)P(C)$$

一般，设 $A_1, A_2, \dots, A_n$ 是 n 个事件，如果其中的任意多个事件的积事件的概率都等于各个事件概率的积，则称 $A_1, A_2, \dots, A_n$ 相互独立。

1.3.3 Rule of Total Probability



上面的例子，事实上是把事件 A 的概率计算转化为 A 在空间 S 上几个部分的概率计算。



空间 S 的划分：

设 S 为随机试验 E 的样本空间， $B_1, B_2, \dots, B_n$ 为 E 的一组事件，如果

[1] $B_1, B_2, \dots, B_n$ 是两两互斥的事件；

[2] $B_1 \cup B_2 \cup \dots \cup B_n = S$

则称 $B_1, B_2, \dots, B_n$ 称为样本空间 S 的一个划分

1.3.3 Rule of Total Probability



[定理]: 设 S 为随机试验 E 的样本空间, $B_1, B_2, \dots, B_n$ 为 S 的一个划分, 且 $P(B_i) > 0, i=1, 2, \dots, n$ 。则 E 的任意事件 A 的概率为

$$P(A) = P(A|B_1)P(B_1) + P(A|B_2)P(B_2) + \dots + P(A|B_n)P(B_n)$$

Remark: 上述称为**全概率公式**, 它事实上是把在一个复杂空间 S 上事件 A 的概率, 分解为在数个小的子空间上的概率之和

$$P(A) = P(AB_1) + P(AB_2) + \dots + P(AB_n)$$

进一步地把在每个子空间上的概率分解为条件概率的积.

$$P(A) = P(A|B_1)P(B_1) + P(A|B_2)P(B_2) + \dots + P(A|B_n)P(B_n)$$

由此, 简化运算 (比照加法公式、乘法公式)

1.3.4 Bayes' Theorem



这里，事件 A 、 B 、 C 发生后，我们希望知道导致这些事件发生几种原因的可能性。这几种原因就是 B_1 、 B_2 、 B_3 ，他们是事实上是空间 S 的一个划分。

[Bayes定理]: 设试验 E 的样本空间为 S ， $B_1, B_2, \dots, B_n$ 为样本空间 S 的一个划分， A 为 E 的事件， $P(A) > 0$, $P(B_i) > 0 (i = 1, 2, \dots, n)$ ，则：

$$P(B_i | A) = \frac{P(A | B_i)P(B_i)}{\sum_{j=1}^n P(A | B_j)P(B_j)} \quad i = 1, 2, \dots, n$$

1.4 Model & Calculation for Probability



1.4.1 古典概型

古典概率是一类比较简单、直观的随机试验。有以下两个明显特征：

- 试验所得的可能的结果个数有限，即基本事件个数有限

$$S = \{e_1, e_2, \dots, e_n\}$$

- 各个试验结果在每次实验中发生的可能性是一样的

$$P(e_i) = 1/n$$

事件 A 是基本事件的集合，包含了 k 个基本事件，则

$$\begin{aligned} P(A) &= P(e_{i1}) + P(e_{i2}) + \dots + P(e_{ik}) \\ &= k / n \end{aligned}$$



Chpt.2 Random Variables & Probability Distributions

第二章 随机变量及其分布

2.2 Discrete Random Variables & Its Distribution



2.2.2 概率分布律

对离散型随机变量涉及到两点：[1] 随机变量所有可能的取值；[2] 取每个值得概率。

如果X所有可能的取值为 x_k ($k=1,2,\dots$)，X取 x_k (即事件 $A=\{x=x_k\}$) 的概率记为

$$P(X = x_k) = p_k \quad (k = 1, 2, \dots)$$

称之为离散随机变量X的概率分布或分布律。

其直观的表现是列表

$$\begin{pmatrix} x_1 & x_2 & L & x_n & L \\ p(x_1) & p(x_2) & L & p(x_n) & L \end{pmatrix}$$



2.2.3 常见的概率分布

(一) 退化分布（单点分布）

设随机变量 X 只取一个常数值 c ，即

$$P(X=c)=1$$

称它为退化(degenerate)分布，又称为单点分布。

事实上， $\{X=c\}$ 是一概率为1的事件， X 可以看作一个常数，但有时我们宁愿把它看作（退化的）随机变量。

(二) 0-1分布（两点分布/Bernoulli分布）

随机变量 X 只取两个值0和1，满足分布：

$$P(X=0)=1-p \quad p > 0$$

$$P(X=1)=p$$

称 X 服从参数为 p 的 0-1分布（也称伯努里分布）。



2.2.3 常见的概率分布

(三) 二项分布

对于n重伯努里 (Bernoulli) 试验, 假设每次成功的概率是p, 定义随机变量X描述n次试验中事件A可能发生的次数k

$$\begin{aligned} P\{X = k\} &= b(k, n, p) \\ &= C_n^k p^k (1-p)^{n-k} \quad (k = 0, 1, 2, \dots, n) \end{aligned}$$

称X服从参数为n和p的二项分布 (Binomial distribution), 记为 $X \sim b(n, p)$ 或 $X \sim B(n, p)$.

(四) 泊松分布(Poisson)



从上面的泊松定理可引入另一类重要的分布。

设随机变量 X 可取一切非负整数值，取这些值的概率为：

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda} \quad k = 0, 1, 2, \dots$$

其中 $\lambda > 0$ 是它的参数，称 X 服从参数为 λ 的泊松分布，简记 $X \sim \pi(\lambda)$

容易知道：

$$P\{X = k\} > 0 \quad (k = 0, 1, 2, \dots)$$

$$\sum_{k=0}^{\infty} P\{X = k\} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = 1$$



[3] $n \rightarrow \infty$ 时的渐近性质

假定 p 与 n 有关, 记作 p_n 。考虑 $n \rightarrow \infty$ 的情况, 有下面的定理:

[泊松(Poisson)定理] 如果存在正常数 λ , 当 $n \rightarrow \infty$ 时有 $np_n \rightarrow \lambda$, 则

$$\lim_{n \rightarrow \infty} b(k, n, p) = \frac{\lambda^k}{k!} e^{-\lambda} \quad k=0, 1, 2, \dots$$



[3] $n \rightarrow \infty$ 时的渐近性质

Proof: 记 $\lambda_n = np_n$

$$\begin{aligned} b(k, n, p) &= C_n^k (p_n)^k (1 - p_n)^{n-k} \\ &= \frac{n(n-1)(n-2)\cdots(n-k+1)}{k!} \left(\frac{\lambda_n}{n}\right)^k \left(1 - \frac{\lambda_n}{n}\right)^{(n-k)} \\ &= \frac{\lambda_n^k}{k!} \frac{n(n-1)(n-2)\cdots(n-k+1)}{n^k} \left(1 - \frac{\lambda_n}{n}\right)^n \bigg/ \left(1 - \frac{\lambda_n}{n}\right)^k \\ &\quad \begin{array}{cccc} \downarrow & \downarrow & \downarrow & \downarrow \\ \boxed{\frac{\lambda^k}{k!}} & \boxed{1} & \boxed{e^{-\lambda}} & \boxed{1} \end{array} \\ &\rightarrow \frac{\lambda^k}{k!} e^{-\lambda} \quad (n \rightarrow \infty) \end{aligned}$$



[3] $n \rightarrow \infty$ 时的渐近性质

$$\lim_{n \rightarrow \infty} b(k, n, p) = \frac{\lambda^k}{k!} e^{-\lambda} \quad k=0,1,2,\dots$$

定理的条件 $np_n \rightarrow \lambda$ 意味着当 n 很大时, p_n 必定很小.

因此, 利用泊松定理, 对于二项分布, 当 n 很大, p 很小时
有以下近似式:

$$C_n^k p^k (1-p)^{n-k} \approx \frac{\lambda^k e^{-\lambda}}{k!}$$

其中 $\lambda = np$

实际计算中, $n \geq 100$, $np \leq 10$ 时近似效果就很好.



2.2.3 常见的概率分布

(五) 几何分布

单次试验中事件 A 发生概率为 p ，现重复多次，直到 A 出现为止。定义 X 为事件 A 首次发生时所进行的试验次数，则 X 为一随机变量，可能的取值为

$$P(X = k) = (1 - p)^{k-1} p \quad (k = 1, 2, \dots)$$

称 X 服从参数为 p 的几何分布

几何分布的无记忆性

假定在前 m 次试验中，事件 A 一直没有发生，则从第 $m+1$ 次开始直到成功的次数 Y 也服从同样的几何分布(实验次数 Y 与 m 无关，好像把前面 m 次失败‘忘记’了)。

(证明见《概率论引论》，汪仁宫，pp.57)

2.3 Distribution Function of Random Variable



2.3.2 定义

设随机变量 X ，对任意的实数 x ，随机变量 X 取值落入区间 $(-\infty, x]$ 内的概率为 $F(x)$

$$F(x) = P(X \leq x) \quad -\infty < x < +\infty$$

称为随机变量 X 的分布函数 (distribution function)。

[1] 对确定的随机变量 X ，其分布函数 $F(x)$ 是唯一确定的，它是实变量 X 的函数，因此我们可以利用实变函数论这一有力工具来研究随机变量。

[2] 有了分布函数，则对任一波雷尔集 A ，概率 $P(A)$ 可以用分布函数来表示。

$$\begin{aligned} P(a < X \leq b) &= P\{(-\infty, b]\} - P\{(-\infty, a]\} \\ &= F(b) - F(a) \end{aligned}$$

2.3 Distribution Function of Random Variable



2.3.3 分布函数的特性

由于分布函数已经是一个普通函数，就可以用数学分析、实变函数来研究。至此已经达到目的：

概率事件 $\Rightarrow$ 随机变量(统一描述) $\Rightarrow$ 分布函数(函数工具)

(1) $F(x)$ 是一个不减的函数, $\forall x_1 \leq x_2, F(x_1) \leq F(x_2)$

(2) $0 \leq F(x) \leq 1$

(3) $F(-\infty) = \lim_{x \rightarrow -\infty} F(x) = 0$ $F(\infty) = \lim_{x \rightarrow \infty} F(x) = 1$

(4) 函数的右连续性 $F(x+0) = \lim_{y \rightarrow x+0} F(y)$

(严格证明见：《概率论》，王仁宫，pp.38, pp.66)

2.3 Distribution Function of Random Variable




Example 2.7 离散随机变量的分布函数，随机变量 X 的分布列为

$$\begin{pmatrix} x_1 & x_2 & \cdots & x_k & \cdots \\ p(x_1) & p(x_2) & \cdots & p(x_k) & \cdots \end{pmatrix}$$

且 $x_1 < x_2 < \cdots < x_k < \cdots$ ，则 X 的分布函数为 $F(x) = P(X \leq x) = \sum_{x_k \leq x} p(x_k)$

$$F(x) = \begin{cases} 0, & x < x_1, \\ p(x_1), & x_1 \leq x < x_2, \\ \text{L} & \text{L} \\ \sum_{i \leq k} p(x_i), & x_k \leq x < x_{k+1}, \\ \text{L} & \text{L} \end{cases}$$



2.4 Distribution for Continuous Random Variables



2.4.1 连续型随机变量及密度函数

猜测连续型随机变量的分布函数（依据）：

[1] 概率定义一再地引用几何面积的概念；

[2] 对于一个随机变量 X 取得某个区间的所有值时，从离散随机变量的分布函数为概率的和。

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t)dt$$

Definition 1 如果对于随机变量 X 的分布函数 $F(x)$ ，存在非负函数 $f(x)$ ，使对于任意实数 x 满足

$$F(x) = \int_{-\infty}^x f(t)dt$$

则称 X 为连续型(continuous)随机变量，称 $f(x)$ 为 X 的概率密度函数，简称为密度函数(density function)。

2.4 Distribution for Continuous Random Variables



2.4.2 连续型随机变量的特性

连续型随机变量的分布函数 $F(x)$ 具有下列数学性质：

(1) $f(x) \geq 0$

(2) $\int_{-\infty}^{+\infty} f(x)dx = 1.$

(3) 随机变量 X 落在任意区间 $(a, b]$ 的概率：

$$\begin{aligned} P\{a < x \leq b\} &= F(b) - F(a) \\ &= \int_a^b f(x)dx. \end{aligned}$$

(4) 若 $f(x)$ 在 x 处连续，则有 $F'(x) = f(x)$

(5) 特别，对任一常数 c ， $P\{X = c\} = 0.$

2.4 Distribution for Continuous Random Variables



2.4.2 连续型随机变量的特性

连续型随机变量的分布函数 $F(x)$ 具有下列数学性质：

$$\begin{aligned} P\{a < x \leq b\} &= F(b) - F(a) \\ &= \int_a^b f(x) dx. \end{aligned}$$

$$(6) \quad P(a \leq x \leq b) = P\{x \leq b\} - P\{x \leq a\} + P\{x = a\}$$

$$P(a \leq x < b)$$

$$P(a < x < b)$$

都同上

2.4.3 常见的连续型随机变量



[一] 均匀 (Uniform) 分布

考虑在一个区间 $[a, b]$ 上方抛点，假设点落入任意一个等长度区间的概率（可能性）是相同的（或者说点落入某个区间的可能性大小只与区间长度有关，与区间端点无关），用随机变量 X 表示区间的端点 $(-\infty, x]$ ，则 X 的分布函数为

$$F(x) = P\{X \leq x\} = \begin{cases} 0, & x \leq a \\ \frac{x-a}{b-a}, & a < x < b \\ 1, & x \geq b \end{cases}$$
$$f(x) = \begin{cases} \frac{1}{b-a}, & a < x < b, \\ 0, & \text{else} \end{cases}$$

称具有上述概率密度的连续型随机变量 X 为在区间 $[a, b]$ 上服从均匀分布，简记作 $X \sim U(a, b)$ 。



2.4.3 常见的连续型随机变量

[二] 指数 (Exponential) 分布

随机变量 X 的密度函数为（当然，我们说它应该满足分布密度）

$$f(x) = \begin{cases} \frac{1}{\theta} e^{-x/\theta} = \frac{1}{\theta} \text{Exp}\left(-\frac{x}{\theta}\right), & x > 0 \\ 0, & \text{else} \end{cases}$$

其中 $\theta > 0$ 为常数，则称 X 服从参数为 θ 的**指数分布**(Exponential)。

其分布函数为

$$F(x) = \begin{cases} 1 - e^{-x/\theta}, & x > 0 \\ 0, & \text{else} \end{cases}$$

从而当 $x > 0$ 时有： $P\{X > x\} = 1 - P\{X \leq x\} = 1 - F(x) = e^{-x/\theta}$

指数分布常用来描述产品的寿命。



[三] 正态分布

若随机变量 X 的密度函数为

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad -\infty < x < \infty$$

就称 X 服从正态(Normal)分布，记作 $X \sim N(\mu, \sigma^2)$ 。其中, $\sigma > 0$, $-\infty < \mu < \infty$ 。

我们来证明上述定义的 $f(x)$ 的确是密度函数。

显然 $f(x) > 0$;

进一步证明 $\int_{-\infty}^{\infty} f(x) dx = 1$ 即证明

$$\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx = 1 \xrightarrow{t=\frac{x-\mu}{\sigma}} \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{t^2}{2}} dt = 1.$$



1. 正态分布的特性

[5] 当 $\mu=0, \sigma=1$ 时, 称为标准正态分布(standardized normal distribution), 它的密度曲线关于纵轴对称, 其密度及分布函数特别记为 $\varphi(x)$ 和 $\Phi(x)$:

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \quad -\infty < x < \infty$$

容易知道 $\Phi(-x) = 1 - \Phi(x)$.



2.5 随机变量的函数及其分布-I

人们经常碰到随机变量的函数。例如分子运动动能 $T = mv^2/2$ 是分子运动速度—随机变量 v 的函数；

数理统计中经常用到 $\chi^2(n)$ 分布，相应的随机变量

$$\chi^2 = \xi_1^2 + \xi_2^2 + \dots + \xi_n^2$$

其中各 ξ_i 相互独立，都服从 $N(0, 1)$ 。 χ^2 是 $\xi_1, \dots, \xi_n$ 的函数。

一般地，若 X 是随机变量， $y = g(x)$ 是普通的实函数，则 $Y = g(X)$ 是 X 的函数。

产生两个问题：

- (1) Y 是随机变量吗？
- (2) 如果是， Y 的分布与 X 的分布有什么关系？



2.5.1 离散型随机变量的函数

Example (pp.62 例1) 假设随机变量 X 具有如下分布律

求： $Y = (X - 1)^2$ 的分布。

解： Y 的可能取值为0,1,4, 是有限个, 只须算出对应的概率。由于

X	-1	0	1	2
p_n	0.2	0.3	0.1	0.4

$$P\{Y=0\} = P\{X=1\} = 0.1,$$

$$\text{故 } P\{Y=1\} = P\{X=0\} + P\{X=2\} = 0.7$$

$$P\{Y=4\} = P\{X = -1\} = 0.2$$

类似可得其它概率。我们得到 Y 的分布：

Y	0	1	4
p_n	0.1	0.7	0.2

一般, 设 X 有分布列 $P\{X = x_i\} = p\{x_i\}$, $i=1,2,\dots$, 则

$Y=f(X)$ 有分布列 $P\{Y = y_j\} = \sum_{f(x_i)=y_j} p(x_i), \quad j=1,2,L$



2.5.2 一维连续型随机变量的函数的分布

设 X 的密度函数为 $f_X(x)$ ，我们要求出 $Y = g(X)$ 的分布函数 $F_Y(y)$ 。
事实上

$$\begin{aligned} F_Y(y) &= P(Y \leq y) = P(g(X) \leq y) \\ &= P(X \in D) \end{aligned}$$

而 $D = \{x \mid g(x) \leq y\}$ 是一维的波雷尔集，故

$$F_Y(y) = P(X \in D) = \int_{x \in D} f_X(x) dx$$

至于 Y 是不是连续型随机变量，它的密度函数是什么，在一般场合无法作出决定，但在某些特殊而又常见的场合，我们可以直接导出 Y 的密度函数 $f_Y(y)$ 。



2.5.2 一维连续型随机变量的函数的分布

某些情形下，我们可以直接导出 Y 的密度函数 $f_Y(y)$ 。

定理1 X 为连续型随机变量，有概率密度函数

$$f_X(x) (-\infty < x < \infty)$$

若 $g(X)$ 严格单调且处处可导，则 $Y = g(X)$ 也是连续型随机变量。若令其中 $h(y)$ 是 $g(x)$ 的反函数，则 Y 的密度函数为

$$f_Y(y) = \begin{cases} |h'(y)| f_X[h(y)] & y \in g(x) \text{ 的值域} \\ 0 & y \in \text{其它} \end{cases}$$



Chpt.3 Multi-Dimensional Random Variables and Their Distributions

第三章 多维随机变量及其分布



3.1 多维随机变量

3.1.2 多维随机变量的联合分布

多维随机变量 $X_1, X_2, \dots, X_n$ ，对于任意 n 个实数 $x_1, x_2, \dots, x_n$ 或实向量 $(x_1, x_2, \dots, x_n) \in \mathbb{R}^n$ ，称 n 元函数

$$F(x_1, x_2, \dots, x_n) = P\{X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n\}$$

为随机向量 $X = (X_1, X_2, \dots, X_n)$ 的(联合)分布函数.

注意：记

$$\begin{aligned} P\{X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n\} \\ \triangleq \\ = P\{(X_1 \leq x_1) \cap (X_2 \leq x_2) \cap \dots \cap (X_n \leq x_n)\} \end{aligned}$$

Remark: 注意到多维随机变量 $X_1, X_2, \dots, X_n$ 是针对同一试验而言的，是在同一个样本空间 S 上定义的随机变量。



3.1.2 多维随机变量的联合分布

联合分布的性质

- $0 \leq F(x_1, x_2, \dots, x_n) \leq 1$
- $F(x_1, x_2, \dots, x_{i-1}, -\infty, x_{i+1}, \dots, x_n) = 0 \quad i = 1, 2, \dots, n$
- $F(\infty, \infty, \dots, \infty) = 1$
- $F(x_1, x_2, \dots, x_n)$ 是 $x_1, x_2, \dots, x_n$ 的不减函数，即对任意的两个向量 $(x_1, x_2, \dots, x_n)$ 和 $(x'_1, x'_2, \dots, x'_n)$ ，只要 $x'_i \geq x_i \quad (i = 1, 2, \dots, n)$ ，总有

$$F(x'_1, x'_2, \dots, x'_n) \geq F(x_1, x_2, \dots, x_n)$$


3.1.2 多维随机变量的联合分布



对二维随机向量 (X, Y) ，分布函数 $F(x, y) = P\{X \leq x, Y \leq y\}$ ，其中 $(x, y) \in \mathbf{R}$ 表示随机向量 (X, Y) 落在 (x, y) 为顶点的位于该点左下方的无穷矩形内的概率。

依照上述解释， (X, Y) 落在 $[x_1 < x \leq x_2, y_1 < y \leq y_2]$ 的概率为

$$\begin{aligned} & P\{x_1 < X \leq x_2, y_1 < Y \leq y_2\} \\ &= F(x_2, y_2) - F(x_2, y_1) - F(x_1, y_2) \\ & \quad + F(x_1, y_1) \end{aligned}$$



3.1.3 离散多维随机变量的联合分布



一般，离散型的二维联合分布列为

$$P\{X = x_i, Y = y_j\} = p_{ij} \quad (i, j=1, 2, \dots)$$

或写成表格的形式如下表

$X \backslash Y$	y_1	y_2	$\dots$	y_j	$\dots$
x_1	p_{11}	p_{12}	$\dots$	p_{1j}	$\dots$
x_2	p_{21}	p_{22}	$\dots$	p_{2j}	$\dots$
$\dots$	$\dots$	$\dots$	$\dots$	$\dots$	$\dots$
x_i	p_{i1}	p_{i2}	$\dots$	p_{ij}	$\dots$
$\dots$	$\dots$	$\dots$	$\dots$	$\dots$	$\dots$

3.1.3 离散多维随机变量的联合分布



他们必须满足

$$p_{ij} \geq 0$$

$$\sum_i \sum_j p_{ij} = 1 \quad (i, j=1, 2, \dots)$$

n维离散型随机向量的联合分布是

$$P\{X_1 = x_{i_1}, X_2 = x_{i_2}, \dots, X_n = x_{i_n}\} = p_{i_1 i_2 \dots i_n}$$

$$i_1, i_2, \dots, i_n = 1, 2, \dots$$

3.1.4 N维连续型随机变量的分布函数



[Definition] 对n维随机变量 $X = (X_1, X_2, \dots, X_n)$ 若存在n元可积的非负函数 $f(x_1, x_2, \dots, x_n)$, 对于任意的 $(x_1, x_2, \dots, x_n) \in R^n$

$$F(x_1, x_2, \dots, x_n) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_n} f(y_1, y_2, \dots, y_n) dy_1 dy_2 \cdots dy_n$$

则 $X = (X_1, X_2, \dots, X_n)$ 是n维的连续随机变量, F 称为它的连续型分布, 称 $f(x_1, x_2, \dots, x_n)$ 为 (联合)密度函数.



3.1.4 N维连续型随机变量的分布函数

[1] 显然，密度函数满足如下条件：

$$f(x_1, x_2, \dots, x_n) \geq 0$$
$$\int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f(y_1, y_2, \dots, y_n) dy_1 dy_2 \cdots dy_n = 1$$

[2] 对连续型随机向量，分布函数 $F(x_1, x_2, \dots, x_n)$ 对每一变量都是连续的，且在密度函数 $f(x_1, x_2, \dots, x_n)$ 的连续点，有偏导数

$$\frac{\partial^n F}{\partial x_1 \cdots \partial x_n} = f(x_1, x_2, \dots, x_n)$$

[3] G 是 R^n 中的任意一个区域， $(X_1, X_2, \dots, X_n)$ 落入区域 G 内的概率为

$$P\{X \in G\} = \int_G \cdots \int f(y_1, y_2, \dots, y_n) dy_1 dy_2 \cdots dy_n$$



3.2.2 离散随机变量的边缘分布

以二维随机变量(X,Y)为例

$$F_x(x) = F(x, \infty) = \sum_{\substack{x_i \leq x \\ y_j < \infty}} p_{ij} = \sum_{x_i \leq x} \left(\sum_{j=1}^{\infty} p_{ij} \right)$$

$$P\{X = x_i\} = \sum_{j=1}^{\infty} p_{ij} \stackrel{\Delta}{=} p_{i\bullet} \quad \text{--称为}(X,Y)\text{关于}X\text{的边缘分布}$$

$$P\{Y = y_j\} = \sum_{i=1}^{\infty} p_{ij} \stackrel{\Delta}{=} p_{\bullet j} \quad \text{--称为}(X,Y)\text{关于}Y\text{的边缘分布}$$

Remark 1: 这里 $p_{i\bullet}$ 表示对第二个足标 j 求和, $p_{\bullet j}$ 表示对第一个足标 i 求和.

Remark 2: 上两式分别表示 X 与 Y 的分布列, 它们恰好为二维随机变量分布表按行相加与按列相加的结果, 把它们分别写在表1中两表的右边和下边, 称为边际分布(marginal distribution).

3.2.3 连续型随机变量的边缘分布



以二维连续型随机变量 (X, Y) 为例，设其密度函数为 $f(x, y)$ ，分布函数为 $F(x, y)$ ，则 X 的边际分布函数

$$\begin{aligned} F_X(x) &= P\{X \leq x\} = \int_{-\infty}^x \int_{-\infty}^{\infty} f(x, y) dx dy \\ &= \int_{-\infty}^x \left[\int_{-\infty}^{\infty} f(x, y) dy \right] dx \end{aligned}$$

$$F_X(x) = F(x, +\infty)$$

同理， Y 的边际分布函数为

$$F_Y(y) = \int_{-\infty}^y \left[\int_{-\infty}^{\infty} f(x, y) dx \right] dy = F(+\infty, y)$$



$$\text{记 } f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy \quad f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx$$

根据连续型随机变量的定义，由式可见， X 是连续型随机变量，它的密度函数就是 $f_X(x)$ 。同理 Y 是连续型随机变量，其密度函数为 $f_Y(y)$ 。 $f_X(x)$ 和 $f_Y(y)$ 称为 (X, Y) (或 $f(x, y)$)的**边际密度**。由此，也可以看出边际密度的两种求法：

[1] 由联合分布函数 $F(x, y)$

计算 $F(x, +\infty)$ 得 $F_X(x)$ ， 计算 $F(+\infty, y)$ 得 $F_Y(y)$ ，而后微分得到

$$f_X(x) = F'_X(x), \quad f_Y(y) = F'_Y(y)$$

[2] 由联合分布密度 $f(x, y)$

对 y 积分得到

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy$$

对 x 积分得到

$$f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx$$

3.3 相互独立的随机变量



边缘分布不能反映联合分布，也就是说边缘分布少了点什么。那么，什么可以与边缘分布共同来描述联合分布呢？

(以下可以仅仅从事件的角度而非随机变量的角度看)

$$\begin{aligned} F(x_1, x_2) &= P\{\{X_1 \leq x_1\} \cap \{X_2 \leq x_2\}\} \\ &= P\{X_2 \leq x_2 \mid X_1 \leq x_1\} P\{X_1 \leq x_1\} \\ &= P\{X_2 \leq x_2 \mid X_1 \leq x_1\} F_{x_1}(x_1) \end{aligned}$$

当 $\{X_1 \leq x_1\}$ 独立于 $\{X_2 \leq x_2\}$

$$F(x_1, x_1) = F_{x_1}(x_1) F_{x_2}(x_2)$$

此时，边缘分布函数完全界定了联合分布函数。

3.3 相互独立的随机变量



[定义] 随机变量 X_1, X_2 , $F(x, y), F_X(x), F_Y(y)$ 分别是分布函数和边缘分布函数, 如果对于任意的 (x_1, x_2) 满足

$$F(x_1, x_2) = F_{X_1}(x_1)F_{X_2}(x_2)$$

则称随机变量是 X_1, X_2 相互独立的。

当 (X_1, X_2) 是连续型随机向量时, X_1, X_2 联合概率密度为 $f(x_1, x_2)$, 边缘概率密度分别是 $f_{X_1}(x_1), f_{X_2}(x_2)$, 则 X_1, X_2 独立的条件等价于

$$f(x_1, x_2) = f_{X_1}(x_1)f_{X_2}(x_2)$$

3.4.1 离散随机变量的条件分布



[定义] 对于固定的 j , $P(Y = y_j) > 0$, 则称

$$P(X = x_i | Y = y_j) = \frac{p_{ij}}{p_{\cdot j}} \quad (i = 1, 2, \dots, L)$$

为在 $Y = y_j$ 条件下随机变量 X 的条件分布律。

$P(X = x_i | Y = y_j) = \frac{p_{ij}}{p_{\cdot j}}$ 与前面Chpt.1中的条件概率是一致的;

把所有的这样的条件概率写出就得到了条件分布律.

3.4 条件分布(Conditional Distribution)



3.4.2 连续型随机变量的条件分布

在连续型的情况，因为对任何 y , $P(Y=y)=0$ ，故只能借助于密度函数定义条件密度。 $Y=y$ 时 X 的条件分布函数, 可采取极限方式定义：

$$P(X \leq x | Y = y) = \lim_{\varepsilon \rightarrow 0+} P(X \leq x | y - \varepsilon \leq Y \leq y + \varepsilon)$$

记为 $F_{X|Y}(x | y)$

假设 (X, Y) 的联合分布函数为 $F(x, y)$ ，概率密度为 $f(x, y)$ ，那么

$$F_{X|Y}(x | y) = \lim_{\varepsilon \rightarrow 0+} P(X \leq x | y - \varepsilon \leq Y \leq y + \varepsilon)$$


条件分布函数与条件密度函数的关系



$$F_{X|Y}(x|y) = \int_{-\infty}^x f_{X|Y}(x|y) \, dx = \int_{-\infty}^x \frac{f(x, y)}{f_Y(y)} \, dx$$

$$F_{Y|X}(y|x) = \int_{-\infty}^y f_{Y|X}(y|x) \, dy = \int_{-\infty}^y \frac{f(x, y)}{f_X(x)} \, dy$$

联合分布、边缘分布、条件分布的关系如下



3.5 随机变量的函数的分布-II



3.5.1 基本概念

n 维随机变量 $X = (X_1, X_2, \dots, X_n)$ 的联合分布函数 $F_X(x_1, x_2, \dots, x_n)$

定义随机变量 $Y_i = g_i(X_1, X_2, \dots, X_n) (i = 1, 2, \dots, m)$ 。

记随机向量 $Y = (Y_1, Y_2, \dots, Y_m)$ 的分布函数 $F_Y(y_1, y_2, \dots, y_m)$

$$C = \{(x_1, x_2, \dots, x_n) \mid g_i(x_1, x_2, \dots, x_n) \leq y_i, i = 1, 2, \dots, m\}$$

则

$$\begin{aligned} & F_Y(y_1, y_2, \dots, y_m) \\ &= P(Y_1 \leq y_1, Y_2 \leq y_2, \dots, Y_m \leq y_m) \\ &= P(g_1(X_1, X_2, \dots, X_n) \leq y_1, \dots, g_m(X_1, X_2, \dots, X_n) \leq y_m) \\ &= P((X_1, \dots, X_n) \in C) \end{aligned}$$

3.5 随机变量函数的分布-II



如果 X 有联合概率密度 $f_X(x_1, \cdots, x_n)$, 则

$$F_Y(y_1, y_2, \cdots, y_m) = \int \cdots \int_C f_X(x_1, \cdots, x_n) dx_1 \cdots dx_n$$

这就归结为一个求解 n 重积分的问题。

下面就一些具体的函数形式求解。

[一] $Z = X + Y$

[二] $Z = X/Y$

[三] $Z = \max(X_1, X_2, \cdots, X_n)$

$$Z = \min(X_1, X_2, \cdots, X_n)$$



3.5.2 几个具体的随机变量的函数

[一] $Z=X+Y$

设 (X,Y) 的联合分布概率密度为 $f(x,y)$, Z 的分布函数为 $F_Z(z)$, 概率密度为 $f_Z(z)$

$$F_Z(z) = P(Z \leq z)$$


$$= \iint_{x+y \leq z} f(x,y) dx dy$$

$$= \int_{-\infty}^{+\infty} dx \int_{-\infty}^{z-x} f(x,y) dy$$



$$t = y + x$$

$$= \int_{-\infty}^z \left[\int_{-\infty}^{+\infty} f(x, t-x) dx \right] dt$$





[一] $Z=X+Y$ 的分布函数

$$f_z(z) = \int_{-\infty}^{+\infty} f(x, z-x)dx = \int_{-\infty}^{+\infty} f(z-y, y)dy$$

当 (X, Y) 相互独立时, $f(x, y) = f_X(x)f_Y(y)$

$$f_z(z) = \int_{-\infty}^{+\infty} f_X(x)f_Y(z-x)dx$$

$$f_z(z) = \int_{-\infty}^{+\infty} f_X(z-y)f_Y(y)dy$$

这两个公式称为卷积公式(convolution)

$$Z = X + Y \quad f_z(z) = \int_{-\infty}^{+\infty} f(x, z-x)dx = \int_{-\infty}^{+\infty} f(z-y, y)dy$$

$$Z = X - Y \quad f_z(z) = \int_{-\infty}^{+\infty} f(x, x-z)dx = \int_{-\infty}^{+\infty} f(z+y, y)dy$$

[二] $Z=X/Y$

$$F_z(z) = P\left(\frac{X}{Y} \leq z\right)$$


$$= \iint_{\frac{x}{y} \leq z} f(x, y) dx dy$$

$$= \iint_{G_1} f(x, y) dx dy + \iint_{G_2} f(x, y) dx dy$$

$$= \int_0^{+\infty} dy \int_{-\infty}^{zy} f(x, y) dx + \int_{-\infty}^0 dy \int_{zy}^{+\infty} f(x, y) dx$$



$$x = yu$$



[二] $Z=X/Y$



$$\int_0^{+\infty} dy \int_{-\infty}^{zy} f(x, y) dx + \int_{-\infty}^0 dy \int_{zy}^{+\infty} f(x, y) dx$$

$$\downarrow \quad x = yu$$

$$= \int_{-\infty}^z du \int_0^{+\infty} y f(yu, y) dy + \int_{-\infty}^z du \int_{-\infty}^0 y f(yu, y) dy$$

第二部分 $y < 0$

$$= \int_{-\infty}^z du \int_0^{+\infty} y f(yu, y) dy - \int_{-\infty}^z du \int_{-\infty}^0 y f(yu, y) dy$$

$$= \int_{-\infty}^z du \int_0^{+\infty} |y| f(yu, y) dy + \int_{-\infty}^z du \int_{-\infty}^0 |y| f(yu, y) dy$$

注意：密度函数不为负

$$= \int_{-\infty}^z du \int_{-\infty}^{+\infty} |y| f(yu, y) dy \quad f_z(z) = \int_{-\infty}^{+\infty} |y| f(yz, y) dy$$

[三] 次序量的分布（极值分布）



设 $X_1, X_2, \dots, X_n$ 独立同分布，联合分布函数 $F(x_1, \dots, x_n)$.
把 $X_1, X_2, \dots, X_n$ 每取一组值 $x_1, x_2, \dots, x_n$ 都按大小次序排列，所得随机变量 $X_1^*, X_2^*, \dots, X_n^*$ 称为次序统计量 (order statistic), 它们满足

$$X_1^* \leq X_2^* \leq \dots \leq X_n^*$$

因此

$$X_1^* = \min\{X_1, X_2, \dots, X_n\}$$

$$X_n^* = \max\{X_1, X_2, \dots, X_n\}$$



$$Z = \max(X_1, X_2, \dots, X_n)$$

$$\begin{aligned} F_Z(z) &= P(\max(X_1, X_2, \dots, X_n) \leq z) \\ &= P(X_1 \leq z, X_2 \leq z, \dots, X_n \leq z) \\ &= F(z, z, \dots, z) \end{aligned}$$

如 $X_1, X_2, \dots, X_n$ 独立, 则有

$$F_Z(z) = F_{X_1}(z) \prod_{i=2}^n F_{X_i}(z)$$

如果 $X_1, X_2, \dots, X_n$ 独立同分布, 分布函数为 $F_X(x)$

$$F_Z(z) = [F_X(z)]^n$$



$$Z = \min(X_1, \cdots, X_n)$$

$$\begin{aligned} F_z(z) &= P(\min(X_1, \cdots, X_n) \leq z) \\ &= 1 - P(\min(X_1, \cdots, X_n) \geq z) \\ &= 1 - P(X_1 \geq z, \cdots, X_n \geq z) \end{aligned}$$

如果 $X_1, \cdots, X_n$ 独立，则有

$$\begin{aligned} F_z(z) &= 1 - P(X_1 \geq z)P(X_2 \geq z) \cdots P(X_n \geq z) \\ &= 1 - [1 - P(X_1 \leq z)] \cdots [1 - P(X_n \leq z)] \\ &= 1 - [1 - F_{X_1}(z)] \cdots [1 - F_{X_n}(z)] \end{aligned}$$

对于多个随机变量 $X_1, X_2, \cdots, X_n$ 如有独立同分布 $F_X(x)$ ，则

$$F_z(z) = 1 - [1 - F_X(z)]^n$$



Chpt.4 Digital Features of Random Variables

第四章 随机变量的数字特征



4.1 随机变量的数学期望

4.1.1 数学期望定义

离散随机变量的均值

[Definition] 设离散型随机变量 X 的分布列为

$$\begin{pmatrix} x_1 & x_2 & \cdots & x_k & \cdots \\ p_1 & p_2 & \cdots & p_k & \cdots \end{pmatrix}$$

如果级数 $\sum x_k p_k$ 绝对收敛, 即 $\sum_k |x_k| p_k < \infty$, 就称此级数的和为 X 的 **数学期望** (mathematical expectation) 或 **均值** (mean), 记作 $E(X)$ 。

Example 退化分布 $P\{X=a\}=1$ 的数学期望 $EX=a$, 也即常数的数学期望就是它本身。



连续型随机变量 X ，其密度函数为 $f(x)$. 其数学期望的定义可借鉴离散型情形的定义及普通积分的导出过程来引入.

STEP 1: 先设 X 只在有限区间 $[a, b]$ 上取值，将 $[a, b]$ 作分割：

$$a = x_0 < x_1 < \cdots < x_n = b$$

X 落在各小段的概率

$$P\{x_k < X \leq x_{k+1}\} = \int_{x_k}^{x_{k+1}} f(x)dx \approx f(x_k)\Delta x_k$$

近似地视为落在一点上 x_k 的概率

STEP 2: 与它相应的离散型随机变量的数学期望 $\sum x_k f(x_k)\Delta x_k$

STEP 3: 令 $n \rightarrow \infty$, $\max\{\Delta x_k\} \rightarrow 0$ ，则和式的极限为积分.

$$\int_a^b x f(x) dx$$



自然把它作为 X 的数学期望. 如果 X 在整个实轴 $(-\infty, \infty)$ 上取值, 让 $a \rightarrow -\infty$, $b \rightarrow \infty$, 就得如下的一般定义.

Definition 设 X 为连续型随机变量, 有密度函数 $f(x)$, 则当

$$\int_{-\infty}^{\infty} |x| f(x) dx < \infty$$

时, 称 $E(x) = \int_{-\infty}^{\infty} xf(x)dx$ 为 X 的数学期望.

如果 $\int_{-\infty}^{\infty} |x| f(x)dx = \infty$, 就称 X 的数学期望不存在.

Example 均匀分布的密度函数: $a \leq x \leq b$ 时, 它的数学期望

$$E(x) = \int_a^b \frac{x}{b-a} dx = \frac{a+b}{2}$$



4.1.2 随机变量函数的数学期望

我们知道 X 的分布列为

X	$x_1 \cdots \cdots x_k$
p	$p_1 \cdots \cdots p_k$

可以知道 X^2 的分布列为

X^2	$x_1^2 \cdots \cdots x_k^2$
p	$p_1 \cdots \cdots p_k$

故此
$$E(X^2) = \sum x_k^2 p_k$$

函数 $g(x)$, 随机变量 $Y=g(x)$, 有 $E(g(X)) = \sum g(x_k) p_k$

对于连续随机变量 X ,其概率密度函数为 $f(x)$, 则

$$E(g(X)) = \int_{-\infty}^{\infty} g(x) f(x) dx$$

上式在计算某些随机变量的数学期望时很有用. 如果 $Y=g(X)$, 我们不必求 Y 的概率密度函数 $f_y(y)$, 计算 $E(Y) = \int_{-\infty}^{\infty} y f_y(y) dy$, 而是直接得到 $E(Y) = E(g(X)) = \int_{-\infty}^{\infty} g(x) f(x) dx$

设有联合概率密度函数 $f(x_1, \cdots, x_n)$, $Y = g(X_1, \cdots, X_n)$, 则

$$E(Y) = \iint_{R^n} g(x_1, \cdots, x_n) f(x_1, \cdots, x_n) dx_1 \cdots dx_n$$

特别地有

$$E(X_i) = \iint_{R^n} x_i f(x_1, \cdots, x_n) dx_1 \cdots dx_n$$



4.1.3 数学期望的基本性质



(1) 设 C 为常数, 则有 $E(C) = C$

(2) 设 X 是一个随机变量, C 为常数, 则有 $E(CX) = CE(X)$

(3) 设 $X_1, X_2, \dots, X_n$ 是 n 个随机变量, $c_1, c_2, \dots, c_n$ 为实数, 则

$$E(c_1X_1 + c_2X_2 + \dots + c_nX_n) = c_1E(X_1) + c_2E(X_2) + \dots + c_nE(X_n)$$

(4) 设 X, Y 是相互独立的随机变量, 则有

$$E(XY) = E(X)E(Y)$$



Important. 方差可以看作是随机变量函数 $(X - E(X))^2$ 的数学期望，根据数学期望的定义，可写出方差的计算公式

$$\begin{aligned} Var(X) &= E(X - E(X))^2 \\ &= \int_{-\infty}^{\infty} (x - E(X))^2 f(x) dx \\ &= \int_{-\infty}^{\infty} \left\{ x^2 - 2xE(X) + [E(X)]^2 \right\} f(x) dx \\ &= \int_{-\infty}^{\infty} x^2 f(x) dx - 2E(X) \int_{-\infty}^{\infty} xf(x) dx + [E(X)]^2 \\ &= E(X^2) - [E(X)]^2 \end{aligned}$$

4.2.3 方差的性质



$$(1) \quad D(C) = 0; \quad (C \text{ 为常数})$$

$$(2) \quad D(aX + b) = a^2 D(X);$$

此式说明：

随机变量平移 $X+b$ 不影响方差；

随机变量的比例（尺度）变换 aX ，会比例放大方差。

(3) $X_1, \dots, X_n$ 为随机变量，如果 $X_1, \dots, X_n$ 相互独立，

$$c_1, \dots, c_n \text{ 为常数}, \quad D(c_1 X_1 + \dots + c_n X_n) = \sum_{j=1}^n c_i^2 D(X_i)$$

4.2.3 方差的性质



(4) $D(X)=0$ 的充分必要条件是X以概率1取得常数C, 即

$$P(X=C)=1$$

证明:

如果 $P(X=C)=1$

那么 $\mu=E(X)=C$

$$\begin{aligned} D(X) &= E(X - \mu)^2 \\ &= \int_{-\infty}^{+\infty} (x - C)^2 f(x) dx \\ &= 0 \end{aligned}$$

常见分布及其期望和方差列表



分布名称	数学期望 $E(X)$	方差 $D(X)$
0-1分布	p	pq
二项分布	np	npq
泊松分布	λ	λ
均匀分布	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
正态分布	μ	σ^2
指数分布	$\frac{1}{\lambda}$ (或 θ)	$\frac{1}{\lambda^2}$ (或 θ^2)



4.3 协方差与相关系数

4.3.1 协方差

单个随机变量的期望与方差分别反映了随机变量取值的平均水平 and 随机变量取值相对于均值的分散程度.

对于两个随机变量 X 、 Y ，他们之间的关系如何描述？

前面知道如果 X, Y 独立，则 $E(XY) = E(X)E(Y)$

$$\begin{aligned} & E[(X - E(X))(Y - E(Y))] \\ &= E[XY - XE(Y) - YE(X) + E(X)E(Y)] \\ &= E(XY) - E(X)E(Y) = 0 \end{aligned}$$

而当 X, Y 不独立， $E[(X - E(X))(Y - E(Y))]$ 其实也可以为0。



4.3 协方差与相关系数

4.3.1 协方差

[Definition] 设 (X, Y) 是二维随机变量, 如果 $E(X)$, $E(Y)$ 都存在, 且 $E(X - E(X))(Y - E(Y))$ 也存在, 则称之为 X 与 Y 的协方差, 记为 $\text{Cov}(X, Y)$

易见

$$(1) \text{Cov}(X, X) = D(X)$$

$$(2) \text{Cov}(X, Y) = \text{Cov}(Y, X).$$

4.3.1 协方差



$$\begin{aligned}(3) \quad Cov(X, Y) &= E[XY - XE(Y) - E(X)Y + E(X)E(Y)] \\ &= E(XY) - E(X)E(Y)\end{aligned}$$

$$(4) \quad D(X + Y) = D(X) + D(Y) + 2Cov(X, Y)$$

$$\begin{aligned}D(X + Y) &= E[(X + Y) - E(X + Y)]^2 \\ &= E(X - E(X))^2 + E(Y - E(Y))^2 + 2E(X - E(X))(Y - E(Y)) \\ &= D(X) + D(Y) + 2Cov(X, Y)\end{aligned}$$

性质:



(1) $Cov(X, C) = 0$; (C为任意常数)

(2) $Cov(a_1X_1 + a_2X_2, Y) = a_1Cov(X_1, Y) + a_2Cov(X_2, Y)$

$$\begin{aligned} Cov(a_1X_1 + a_2X_2, Y) &= E(a_1X_1 + a_2X_2 - E(a_1X_1 + a_2X_2))(Y - EY) \\ &= E(a_1(X_1 - EX_1) + a_2(X_2 - EX_2))(Y - EY) \\ &= E(a_1(X_1 - EX_1)(Y - EY) + a_2(X_2 - EX_2)(Y - EY)) \\ &= a_1Cov(X_1, Y) + a_2Cov(X_2, Y) \end{aligned}$$

(3) $Cov(aX, bY) = abCov(X, Y)$, (a, b为常数).

关于每个参数是线性的, 关于两个参数是双线性的。

4.3.2 相关系数



协方差虽在某种意义上表示了两个随机变量间的关系，但 $\text{Cov}(X, Y)$ 的取值大小与 X, Y 的量纲有关。我们考虑消除量纲，同时把这种关系归一化。

Definition 称下式为 X, Y 的相关系数 (correlation coefficient)。

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$$

Remark: ρ_{XY} 是无量纲的，它事实上是 X, Y 的标准化随机变量的协方差

$$\begin{aligned}\rho_{XY} &= \frac{\text{Cov}(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}} = E \left[\frac{(X - E(X))}{\sqrt{D(X)}} \frac{(Y - E(Y))}{\sqrt{D(Y)}} \right] \\ &= \text{Cov}(X^*, Y^*)\end{aligned}$$



[定理]: (1) $|\rho_{XY}| \leq 1$

(2) $|\rho_{XY}| = 1$ 的充分必要条件是, 存在常数 a, b 使得

$$P\{Y = aX + b\} = 1$$

Proof:

(1) 由 e 的非负性得到 $|\rho_{XY}| \leq 1$

(2) 如果 $|\rho_{XY}| = 1$, 则对于上述的 a^*, b^* 得到

$$E[(Y - a^*X - b^*)^2] = D(Y)(1 - \rho_{XY}^2) = 0$$

[定理] 对随机变量X和Y, 下列事实等价:



(1) $Cov(X, Y) = 0$

(2) X与Y不相关;

(3) $E(XY) = E(X)E(Y)$

(4) $D(X + Y) = D(X) + D(Y)$

对于正态分布情形, 独立与不相关是一致的。
这将在下面进行讨论

4.4 矩(moment)与协方差阵



Definition: 随机变量 X, Y

$E(X^k)$ ($k = 1, 2, \dots$) 称为 X 的 k 阶原点矩, 简称 k 阶矩。

$E[X - E(X)]^k$ ($k = 1, 2, \dots$) 称为 X 的 k 阶中心矩。

$E(X^k Y^l)$ ($k, l = 1, 2, \dots$) 称为 X, Y 的 $k+l$ 阶混合矩。

$E[X - E(X)]^k [Y - E(Y)]^l$ ($k, l = 1, 2, \dots$)

称为 X, Y 的 $k+l$ 阶混合中心矩。



Chpt.5 Law of Large Number & Central Limit

第五章 大数定理及中心极限定理



本章工作目标包括两个：

- [1] 对概率论中的一些结论作出严格的证明；
- [2] 为后面的统计作出准备。

概率论早期发展的目的：揭示由于大量随机因素产生影响而呈现的规律性.

概率与频率之间的关系 → 大数定律：研究无穷随机试验序列，刻画事件的概率与它发生的频率之间的关系。

大量的相互独立的随机因素的综合影响 → 中心极限定理：将观察的误差看作大量独立微小误差的累加，其分布渐近正态。

两个不等式



[马尔克夫不等式] 若 Y 只取非负数的随机变量, $E(Y)$ 存在, 那么 $\forall \varepsilon > 0$, 则有结论:

$$P\{Y \geq \varepsilon\} \leq \frac{E(Y)}{\varepsilon}$$

证明: 当 $y < 0$, $f(y) = 0$

$$\begin{aligned} E(Y) &= \int_{-\infty}^{+\infty} yf(y)dy = \int_0^{+\infty} yf(y)dy \\ &\geq \int_{\varepsilon}^{+\infty} yf(y)dy \\ &\geq \int_{\varepsilon}^{+\infty} \varepsilon f(y)dy \\ &= \varepsilon \int_{\varepsilon}^{+\infty} f(y)dy = \varepsilon P\{Y \geq \varepsilon\} \end{aligned}$$

所以: $E(Y) \geq \varepsilon P\{Y \geq \varepsilon\}$

两个不等式



[切比雪夫不等式] $E(X) = \mu$, $D(X) = \sigma^2$, 那么 $\forall \varepsilon > 0$, 则有结论:

$$P\{|X - \mu| \geq \varepsilon\} \leq \frac{\sigma^2}{\varepsilon^2}$$

$$P\{|X - \mu| < \varepsilon\} \geq 1 - \frac{\sigma^2}{\varepsilon^2}$$

证明: 令 $|X - \mu| = Y \geq 0$ (非负数)

$$E(Y^2) = E[(X - \mu)^2] = E\{[X - E(X)]^2\} = D(X) = \sigma^2$$

$$\begin{aligned} P\{|X - \mu| \geq \varepsilon\} &= P\{Y \geq \varepsilon\} \\ &= P\{Y^2 \geq \varepsilon^2\} \\ &\leq \frac{E(Y^2)}{\varepsilon^2} = \frac{\sigma^2}{\varepsilon^2} \end{aligned}$$

根据马尔科夫不等式

$$\text{所以: } P\{|X - \mu| \geq \varepsilon\} \leq \frac{\sigma^2}{\varepsilon^2}$$



[定理 (Bernoulli)] 设 n_A 是 n 次独立试验中事件A发生的次数, p 是事件A在一次试验中发生的概率, 则对任意的 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P\left\{\left|\frac{n_A}{n} - p\right| \leq \varepsilon\right\} = 1$$

Remark1: 一个随机变量的序列 $Y_1, Y_2, \dots, Y_n, \dots$ 如果对任意 $\varepsilon > 0$, 有 $\lim_{n \rightarrow \infty} P\{|Y_n - p| \leq \varepsilon\} = 1$, 则称序列依概率收敛到 p , 记为

$$Y_n \xrightarrow{p} p (n \rightarrow \infty)$$

Remark2 (大数定律含义之一): Bernoulli定理说明事件A发生的频率 n_A / n 依概率收敛到事件的概率 p 。以严格的数学形式表达了我们的直观看法。在实际应用中, 当试验次数足够大时, 便可以用事件的频率来代替事件的概率 p 。

感受什么是依概率收敛

$$\{X_n\} \rightarrow \underline{a}$$




Remark1: 一个随机变量的序列 $Y_1, Y_2, \dots, Y_n, \dots$ 如果对任意 $\varepsilon > 0$, 有 $\lim_{n \rightarrow \infty} P\{|Y_n - p| \leq \varepsilon\} = 1$, 则称序列依概率收敛到 p , 记为


$$Y_n \xrightarrow{p} p (n \rightarrow \infty)$$

例: 设 X 为抛硬币正面向上的频率, X_n 代表第 n 次试验正面向上的频率, 要求第 n 次试验抛 n 次, 做 10 万次该试验

	正	频	
100th	56	0.56	0.06
200th	120	0.6	0.1



大部分慢慢接近 0.5, 部分样本点脱离常规, 但是影响不了 $n \rightarrow \infty$ 时, 频率 $\rightarrow 0.5$ 的趋势





[定理（辛钦定理）] 设随机变量 $X_1, \dots, X_n, \dots$ 相互独立且同分布，具有相同的数学期望 $E(X_i) = \mu$ ，则对任意的 $\varepsilon > 0$ 有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} (X_1 + \dots + X_n) - \mu \right| \leq \varepsilon \right\} = 1$$

总结：

伯努力：频率依概率收敛于概率

辛钦的条件：独立；同分布；期望存在，对方差没有要求

5.2 中心极限定理



一般地我们考虑随机变量和的标准化形式

$$\frac{\sum_{k=1}^n X_K - \sum_{k=1}^n E(X_K)}{\sqrt{D(\sum_{k=1}^n X_K)}}$$

$$Y_n = \sum_{k=1}^n X_K$$

则上式可以写为

$$Z_n = \frac{Y_n - E(Y_n)}{\sqrt{D(Y_n)}}$$

可知 $E(Z_n) = 0$, $D(Z_n) = 1$, 标准化形式与 $\frac{1}{n} \sum_{k=1}^n X_i - \mu = Z_n$ 十分相似, 那么它的极限分布式什么呢?



[定理（独立同分布的中心极限定理）]

如随机变量 $X_1, \dots, X_n, \dots$ 相互独立服从同一分布，数学期望与方差 $E(X_i) = \mu$, $D(X_i) = \sigma^2$ ($i = 1, 2, \dots, n, \dots$) 记 $Y_n = \sum_{k=1}^n X_k$ ，其标准化变量 $Z_n = \frac{Y_n - E(Y_n)}{\sqrt{D(Y_n)}} = \frac{Y_n - n\mu}{\sqrt{n\sigma^2}}$ 之分布函数记为 $F_n(x) = P\{Z_n \leq x\}$ ，那么分布函数列的极限为

$$F(x) = \lim_{n \rightarrow \infty} F_n(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$

定理就是说，分布的极限为标准正态分布，则当n充分大时近似有

$$\frac{Y_n - n\mu}{\sqrt{n\sigma^2}} \sim N(0,1) \quad Y_n \sim N(n\mu, n\sigma^2)$$

$$\text{或者 } \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0,1), \text{ 或者 } \bar{X} \sim N(\mu, \sigma^2 / n)$$



也就是说均值为 μ ，方差为 σ^2 的独立同分布的随机变量 $X_1, X_2, \dots, X_n$ 的算术平均当 n 充分大时近似地服从均值为 μ 方差为 σ^2/n 的正态分布。

[定理2 (Lyapunov定理)] 如随机变量 $X_1, \dots, X_n, \dots$ 相互独立，数学期望 $E(X_i) = \mu_i$ 与方差 $D(X_i) = \sigma_i^2 \neq 0$ ($i = 1, 2, \dots, n, \dots$)，记 $Y_n = \sum_{k=1}^n X_k$

$$B_n^2 = D(Y_n) = \sum_{k=1}^n \sigma_k^2 \quad Z_n = \frac{Y_n - E(Y_n)}{B_n} = \frac{\sum_{k=1}^n X_k - E(\sum_{k=1}^n X_k)}{\sqrt{D(\sum_{k=1}^n X_k)}}$$

分布函数 $F_n(x) = P\{Z_n \leq x\}$ ，如果存在正数 $\delta > 0$ 使 $n \rightarrow \infty$ 时

$\frac{1}{B_n^{2+\delta}} \sum_{k=1}^n E\{(X_k - \mu_k)^{2+\delta}\} \rightarrow 0$ 那么分布函数列的极限为

$$F(x) = \lim_{n \rightarrow \infty} F_n(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$



上述定理说明，随机变量 $Z_n = \frac{Y_n - E(Y_n)}{B_n} = \frac{\sum_{k=1}^n X_k - E(\sum_{k=1}^n X_k)}{\sqrt{D(\sum_{k=1}^n X_k)}}$

当 n 充分大时近似地服从正态分布 $N(0,1)$ 。

由此当 n 很大时， $\sum_{k=1}^n X_k = B_n Z_n + \sum_{k=1}^n \mu_k$ 近似地服从 $N(\sum_{k=1}^n \mu_k, B_n^2)$

定理说明当 n 充分大时， n 个随机变量的和 $\sum_{k=1}^n X_k$ 近似地服从正态分布，而不管 X_k 本身是什么样的分布，只要满足一定的条件即可。由此我们可以看出上述定理的背景。



Example 设一次贝努里试验中成功的概率为 p ($0 < p < 1$), 令 S_n 表示 n 重贝努里试验中成功的次数, 那么 $S_n \sim B(n, p)$ 。在实际问题中, 人们常常对成功次数介于两整数 α 、 β 和之间($\alpha < \beta$)的概率感兴趣, 即要计算

$$P\{\alpha < S_n < \beta\} = \sum_{\alpha < k < \beta} B(k, n, p)$$

这一和式往往涉及很多项, 直接计算相当困难. 然而我们注意到

$S_n = X_1 + X_2 + \cdots + X_n$ (X_i 表示 n 重实验中第 i 次试验的结果), $E(X_i) = p$, $D(X_i) = p(1-p)$, 则 $E(S_n) = np$, $D(S_n) = np(1-p)$, 我们知道

$$\frac{S_n - E(S_n)}{\sqrt{D(S_n)}} = \frac{S_n - np}{\sqrt{np(1-p)}}$$

近似为 $N(0,1)$ 【德莫佛—拉普拉斯定理】

因此这个定理表示二项分布的标准化变量依分布收敛于标准正态分布. 简单地说是二项分布渐近正态分布.



Chpt.6 Sampling and Distribution

第六章 样本及抽样分布

6.1 样本概念--总体、个体



[定义]:

- 对某一数量（或几个）指标进行随机实验、观察，将试验的全部可能的观察值称为总体。
- 每个可能的观察值称为个体
- 总体中所包含的个体的总数称为总体的容量。容量有限的称为有限总体，容量为无限的称为无限总体。

总体是对对象某些指标的所有观察的值:

观察全校本科生的身高，得到12000个身高观测值；

扔硬币10000次，观察反正面的情况，得到10000个数值。

由此见到这些值有些会相同的，数目也可以是无限种的。

6.1 样本概念



从总体中抽取容量为 n 的样本，就是对代表总体的随机变量 X 随机地、独立地进行 n 次观测，**每次观测的结果仍可以看作一个随机变量。**

n 次观测的结果就是 n 个随机变量： $X_1, \dots, X_n$ ，它们相互独立，并与总体 X 服从相同的分布。

若将样本 $X_1, \dots, X_n$ 看作一个 n 维随机变量 $(X_1, \dots, X_n)$ ，则

(1) 当总体 X 是离散随机变量，且概率分布为 $p(x)$ 时， $(X_1, \dots, X_n)$ 的概率分布

$$p(x_1, \dots, x_n) = p(x_1)p(x_2) \cdots p(x_n)$$

(2) 当总体 X 是连续随机变量，且概率密度为 $f(x)$ 时， $(X_1, \dots, X_n)$ 的概率密度

$$f(x_1, \dots, x_n) = f(x_1)f(x_2) \cdots f(x_n)$$

常用统计量及其观测值：



(1) 样本均值 $\bar{X} = \frac{1}{n} \sum_{k=1}^n X_k$ 观测值为 $\bar{x} = \frac{1}{n} \sum_{k=1}^n x_k$

(2) 样本方差 $S^2 = \frac{1}{n-1} \sum_{k=1}^n (X_i - \bar{X})^2$

观测值为 $s^2 = \frac{1}{n-1} \sum_{k=1}^n (x_i - \bar{x})^2$

(3) 样本标准差 $S = \sqrt{S^2} = \sqrt{\frac{1}{n-1} \sum_{k=1}^n (X_i - \bar{X})^2}$

观测值为 $s = \sqrt{\frac{1}{n-1} \sum_{k=1}^n (x_i - \bar{x})^2}$

常用统计量及其观测值：



(4) 样本k阶原点矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$

观测值为 $a_k = \frac{1}{n} \sum_{i=1}^n x_i^k$

(5) 样本k阶中心矩 $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$

观测值为 $b_k = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k$

6.3 抽样分布



样本是随机变量

统计量是样本的函数，从而统计量也是随机变量

统计量的分布称为**抽样分布**

为什么要研究抽样分布：

- 一般而言，总体分布已知，抽样分布也是知道的，但是确切得到是困难的；
- 从另外一个角度，我们希望由统计量的分布（特别是在观测值得到后），估计、推断出总体的一些特征。我们希望研究统计分布，以便作出统计推断。

几类抽样分布



□ 样本均值分布 $\frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1)$

□ T分布 $t = \frac{\bar{X} - \mu}{S / \sqrt{n}} \sim t(n-1)$

□ χ^2 分布 $\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 \sim \chi^2(n) \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$

□ F分布 $\frac{S_1^2 / \sigma_1^2}{S_2^2 / \sigma_2^2} : F(n_1 - 1, n_2 - 1)$

注意： 以上是对 $X \sim N(\mu, \sigma^2)$ 而言的；取得 n 个样本

一. χ^2 分布



[定义6.1] 设随机变量 $X_1, \dots, X_n$ 是来自标准正态总体


$X \sim N(0,1)$ 的独立样本。则随机变量 $\chi^2 = X_1^2 + X_2^2 + \dots + X_n^2$ 服从自由度为 n 的 χ^2 分布，记为 $\chi^2(n)$ ，其概率密度：

$$f_{\chi^2}(x) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma\left(\frac{n}{2}\right)} x^{\frac{n}{2}-1} e^{-\frac{x}{2}}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

Remark 1: χ^2 分布具有可加性, 也就是说,

$\chi_1^2 \sim \chi^2(n_1), \chi_2^2 \sim \chi^2(n_2)$ 且它们相互独立,

则 $\chi_1^2 + \chi_2^2 \sim \chi^2(n_1 + n_2)$



Remark 2: $\chi^2 \sim \chi^2(n)$


则 $E(\chi^2) = n$, $D(\chi^2) = 2n$



对不同的自由度 n 及不同的数 $\alpha(0 < \alpha < 1)$ ，满足的

$$P\{\chi^2 > \chi_\alpha^2(n)\} = \int_{\chi_\alpha^2(n)}^{\infty} f(x)dx = \alpha$$

值 $\chi_\alpha^2(n)$ 称为 χ^2 分布的 α 分位数。





.....[定义6.2] 若随机变量 $X \sim N(0,1)$, $Y \sim \chi^2(n)$,

则 $t = \frac{X}{\sqrt{Y/n}} \sim t(n)$, 概率密度

$$f_t(t) = \frac{\Gamma(\frac{n+1}{2})}{\Gamma(\frac{n}{2})\sqrt{n\pi}} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}, \quad -\infty < t < +\infty$$

注意到： 此与前面的定义有相似之处。

前面定理说 $X \sim N(\mu, \sigma^2)$, 则 $t = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$

Problem: 两者有什么关系吗?

二. T分布



[定理三] 若总体服从正态分布 $X \sim N(\mu, \sigma^2)$, $\{X_i\}, S$

分别是来自总体的样本与样本标准差, $S^2 = \frac{1}{n-1} \sum_{k=1}^n (X_i - \bar{X})^2$

那么随机变量 $t = \frac{\bar{X} - \mu}{S/\sqrt{n}}$ 服从自由度为n-1的t分布, 记

为 $t \sim t(n-1)$, 其概率密度为:

$$f_t(t) = \frac{\Gamma\left(\frac{n}{2}\right)}{\Gamma\left(\frac{n-1}{2}\right)\sqrt{(n-1)\pi}} \left(1 + \frac{t^2}{n-1}\right)^{-\frac{n}{2}}, \quad -\infty < t < +\infty$$

分位点



[分位点] 随机变量 X , 对一个正数 α ($0 < \alpha < 1$), 满足

$P\{X > x_\alpha\} = \alpha$ 的值 x_α 称为 X 分布的 α 分位数.


对不同的自由度 n 及不同的数 α ($0 < \alpha < 1$), 满足

$$P\{t > t_\alpha(n)\} = \int_{t_\alpha(n)}^{\infty} f_t(t) dt = \alpha$$

的 $t_\alpha(n)$ 值称为 t 分布的 α 分位数。

由 $f_t(t)$ 的对称性知:

$$t_{1-\alpha}(n) = -t_\alpha(n)$$





[定理二] S^2 是来自正态总体 $X \sim N(\mu, \sigma^2)$ 的 n 个样本的方差，那么 $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$

四. 二个正态总体的统计量的分布



有时，需要比较来自两个总体的样本的方差， $F = S_1^2 / S_2^2$

[定理四] 如果 S_1^2 和 S_2^2 是两个 n_1, n_2 独立样本的方差，来自两个具有相同方差（但是未知）的独立正态总体，那么 S_1^2 / S_2^2 服从参数为 $n_1 - 1, n_2 - 1$ 的F分布，记为 $F \sim F(n_1 - 1, n_2 - 1)$

四. 二个正态总体的统计量的分布



[定义6.6] 若随机变量 $U \sim \chi^2(n_1), V \sim \chi^2(n_2)$, U 与 V 独立, 则


随机变量 $F = \frac{U/n_1}{V/n_2}$ 服从自由度为 (n_1, n_2) 的 F 分布, 记为 $F \sim F(n_1, n_2)$, 其概率密度为

$$f_F(z) = \begin{cases} \frac{\Gamma\left(\frac{n_1+n_2}{2}\right)}{\Gamma\left(\frac{n_1}{2}\right)\Gamma\left(\frac{n_2}{2}\right)} n_1^{\frac{n_1}{2}-1} n_2^{\frac{n_2}{2}-1} \frac{z^{\frac{n_1}{2}-1}}{(n_1 z + n_2)^{\frac{n_1+n_2}{2}}} & z > 0 \\ 0 & z \leq 0 \end{cases}$$

F分布



$F \sim F(n_1, n_2)$ 其中分子的自由度 n_1 为第一自由度；分母的自由度 n_2 为第二自由度。




Remark 1: 如果 $X \sim F(m, n)$, 则 $\frac{1}{X} \sim F(n, m)$ 。

F分布



满足 $\int_{F_\alpha(n_1, n_2)}^{\infty} f(x; n_1, n_2) dx = \alpha, \quad 0 < \alpha < 1$

称 $F_\alpha(n_1, n_2)$ 为F
分布的 α 分位点。



Remark 2:

$$F_\alpha(n_1, n_2) = \frac{1}{F_{1-\alpha}(n_2, n_1)}.$$



[定理四] 设 $X_1, X_2, \dots, X_{n_1}$ 与 $Y_1, Y_2, \dots, Y_{n_2}$ 分别是来自正态总体 $N(\mu_1, \sigma_1^2)$ 和 $N(\mu_2, \sigma_2^2)$ 的样本，且两个样本独立。

$$\bar{X} = \frac{1}{n_1} \sum_{i=1}^{n_1} X_i, \bar{Y} = \frac{1}{n_2} \sum_{j=1}^{n_2} Y_j \quad \text{分别是两个样本的样本均值}$$
$$S_1^2 = \frac{1}{n_1 - 1} \sum_{i=1}^{n_1} (X_i - \bar{X})^2, S_2^2 = \frac{1}{n_2 - 1} \sum_{j=1}^{n_2} (Y_j - \bar{Y})^2 \quad \text{是各样本方差}$$

则有：

$$[1] \quad \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0,1)$$



[2]

$$\frac{S_1^2 / \sigma_1^2}{S_2^2 / \sigma_2^2} = \frac{S_1^2}{\sigma_1^2} \cdot \frac{\sigma_2^2}{S_2^2} \sim F(n_1 - 1, n_2 - 1)$$

[3] 当 $\sigma_1 = \sigma_2 = \sigma$ 时

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$$

$$\text{其中 } S_w = \sqrt{\frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}}$$

证明:



[1] 由 $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$, $X_1, X_2, \dots, X_{n_1}$ 与

$Y_1, Y_2, \dots, Y_{n_2}$ 分别是来自两个总体的简单样本

$X_1, X_2, \dots, X_{n_1}$ 的线性组合 $\bar{X} = \frac{1}{n_1} \sum_{i=1}^{n_1} X_i$ 服从正态分布 $N(\mu_1, \frac{\sigma_1^2}{n_1})$

同理 $\bar{Y} \sim N(\mu_2, \frac{\sigma_2^2}{n_2})$

又由于 $\bar{X}, \bar{Y}$ 独立, 其组合是正态分布, 所以

$$\bar{X} - \bar{Y} \sim N(\mu_1 - \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2})$$

其标准化随机变量 $\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1)$



[2] $\chi_1^2 = \frac{(n_1 - 1)S_1^2}{\sigma_1^2} \sim \chi^2(n_1 - 1)$

$$\chi_2^2 = \frac{(n_2 - 1)S_2^2}{\sigma_2^2} \sim \chi^2(n_2 - 1)$$

由于 S_1^2 与 S_2^2 独立,

$$\frac{\chi_1^2 / (n_1 - 1)}{\chi_2^2 / (n_2 - 1)} \sim F(n_1 - 1, n_2 - 1)$$

$$\frac{S_1^2 / \sigma_1^2}{S_2^2 / \sigma_2^2} = \frac{S_1^2 / S_2^2}{\sigma_1^2 / \sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$$



[3] 随机变量 $U = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sigma \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim N(0,1)$, 由上知, 统计量

$$\chi_1^2 = \frac{(n_1 - 1)S_1^2}{\sigma^2} \sim \chi^2(n_1 - 1)$$

$$\chi_2^2 = \frac{(n_2 - 1)S_2^2}{\sigma^2} \sim \chi^2(n_2 - 1)$$

又由于 S_1^2 与 S_2^2 独立, 利用 χ^2 分布的可加性知随机变量

$$V = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{\sigma^2} \sim \chi^2(n_1 + n_2 - 2)$$



习题




2、设事件 A, B 相互独立, $P(A) = 0.3$, 且 $P(A + \bar{B}) = 0.7$, 则 $P(B) =$ _____。

3、设随机变量 X 的分布律为 $X \sim \begin{pmatrix} 0 & 1 & 2 \\ 2c & c & \frac{1}{4} \end{pmatrix}$, 则 $c =$ _____。

4、若随机变量 $X \sim N(2, \sigma^2)$, 且 $P(2 < X < 4) = 0.3$, 则 $P(X < 0) =$ _____。

答案:

2、 $3/7$ 3、 $1/4$ 4、 0.2



2、设 A, B 为任意两个不相容的事件且 $P(A) > 0$, $P(B) > 0$, 则下列结论正确的是 ()。

(A) $\bar{A}\bar{B} = \emptyset$

(B) $\bar{A}\bar{B} \neq \emptyset$

(C) $P(AB) = P(A)P(B)$

(D) $P(A - B) = P(A)$

3、设随机变量 $X_i \sim \begin{pmatrix} -1 & 0 & 1 \\ \frac{1}{4} & \frac{1}{2} & \frac{1}{4} \end{pmatrix}$ ($i = 1, 2$), 且满足 $P(X_1 X_2 = 0) = 1$, 则 $P(X_1 = X_2)$ 等于 ()。

(A) 0

(B) 1/4

(C) 1/2

(D) 1

4、设 X 为随机变量, $E(X) = \mu$, $D(X) = \sigma^2$, 则对任意常数 C 有 ()。

(A) $E[(X - C)^2] = E[(X - \mu)^2]$

(B) $E[(X - C)^2] \geq E[(X - \mu)^2]$

(C) $E[(X - C)^2] = E(X^2) - C^2$

(D) $E[(X - C)^2] < E[(X - \mu)^2]$

答案:

2、 D 3、 A 4、 B



设袋中有 5 个球，其中 3 个新球，2 个旧球，从中任取 3 个球，用 X 表示 3 个球中的新球个数，

- (1) X 的分布律； (2) X 的分布函数。

答案：

【解】 X 的可能取值为 1, 2, 3,

$$P(X=1) = \frac{C_2^2 C_3^1}{C_5^3} = \frac{3}{10}, \quad P(X=2) = \frac{C_2^1 C_3^2}{C_5^3} = \frac{6}{10}, \quad P(X=3) = \frac{C_2^0 C_3^3}{C_5^3} = \frac{1}{10},$$

$$\text{所以 } X \text{ 的分布律为 } X \sim \begin{pmatrix} 1 & 2 & 3 \\ \frac{3}{10} & \frac{6}{10} & \frac{1}{10} \end{pmatrix}, \text{ 分布函数为 } F_X(x) = \begin{cases} 0, & x < 1, \\ \frac{3}{10}, & 1 \leq x < 2, \\ \frac{9}{10}, & 2 \leq x < 3, \\ 1, & x \geq 3, \end{cases}$$

设 (X, Y) 的联合密度函数为 $f(x, y) = \begin{cases} axe^{-y}, & 0 < x < y, \\ 0, & \text{其他.} \end{cases}$

(1) 求 a ; (2) 求 X, Y 的边缘密度, 并判断其独立性; (3) 求 $f_{X|Y}(x|y)$ 。

【解】(1) 由 $\int_{-\infty}^{+\infty} dx \int_{-\infty}^{+\infty} f(x, y) dy = a \int_0^{+\infty} x dx \int_x^{+\infty} e^{-y} dy = a \int_0^{+\infty} x e^{-x} dx = 1$, 得 $a = 1$.

(2) 当 $x \leq 0$ 时, $f_X(x) = 0$;

当 $x > 0$ 时, $f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy = \int_x^{+\infty} x e^{-y} dy = x e^{-x}$.

于是 $f_X(x) = \begin{cases} x e^{-x}, & x > 0, \\ 0, & x \leq 0. \end{cases}$

当 $y \leq 0$ 时, $f_Y(y) = 0$; 当 $y > 0$ 时, $f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx = \int_0^y x e^{-y} dx = \frac{1}{2} y^2 e^{-y}$.

于是 $f_Y(y) = \begin{cases} \frac{1}{2} y^2 e^{-y}, & y > 0, \\ 0, & y \leq 0. \end{cases}$

因为 $f(x, y) \neq f_X(x) f_Y(y)$, 所以 X, Y 不独立.

(3) $f_{X|Y}(x | y) = \frac{f(x, y)}{f_Y(y)} = \begin{cases} \frac{2x}{y^2}, & 0 < x < y, \\ 0, & \text{其他.} \end{cases}$

14. 设随机变量 (X, Y) 的概率密度为

$$f(x, y) = \begin{cases} 1, & |y| < x, 0 < x < 1, \\ 0, & \text{其他.} \end{cases}$$

求条件概率密度 $f_{Y|X}(y|x), f_{X|Y}(x|y)$.

$$14. \text{ 当 } |y| < 1 \text{ 时, } f_{X|Y}(x|y) = \begin{cases} \frac{1}{1-|y|}, & |y| < x < 1, \\ 0, & x \text{ 取其他值.} \end{cases}$$

$$\text{当 } 0 < x < 1 \text{ 时, } f_{Y|X}(y|x) = \begin{cases} \frac{1}{2x}, & |y| < x, \\ 0, & y \text{ 取其他值.} \end{cases}$$



习题二



- 5、若随机变量 $X_1, X_2, \dots, X_n$ 相互独立同分布于 $N(\mu, 2^2)$ ，则根据切比雪夫不等式得 $P\{|\bar{X} - \mu| \geq 2\} \leq$ _____
- 6、设 $U \sim N(\mu, 1)$ ， $V \sim \chi^2(n)$ ，且 U, V 相互独立，则 $T = \frac{U - \mu}{\sqrt{V}} \sqrt{n}$ 服从_____分布。
- 7、设总体 X 的分布律为 $X \sim \begin{pmatrix} -1 & 1 & 2 \\ \theta & 1 - 2\theta & \theta \end{pmatrix}$ (θ 为正参数)， $-1, 2, -1, 1, 2$ 为样本观测值，则 θ 的极大似然估计值为_____。

答案：

$$5、1/n \quad 6、t(n) \quad 7、\hat{\theta} = 2/5$$

5、设 X, Y 都服从标准正态分布，则（ ）。

(A) $X + Y$ 服从正态分布

(B) $X^2 + Y^2$ 服从 χ^2 分布

(C) X^2, Y^2 都服从 χ^2 分布

(D) X^2/Y^2 服从 F 分布

6、随机变量 $X \sim F(m, m)$ ，令 $p = P(X \leq 1)$ ， $q = P(X \geq 1)$ ，则（ ）。

(A) $p < q$

(B) $p > q$

(C) $p = q$

(D) p, q 的大小与自由度 m 有关

7、设 (X, Y) 服从二维正态分布，则下列说法不正确的是（ ）。

(A) X, Y 一定相互独立

(B) X, Y 的任意线性组合 $l_1X + l_2Y$ 服从正态分布

(C) X, Y 都服从正态分布

(D) $\rho = 0$ 时， X, Y 相互独立

8、设 X, Y 为两个随机变量，若对任意非零常数 a, b 有 $D(aX + bY) = D(aX - bY)$ ，则下列结论正确的是（ ）。

(A) $D(XY) = D(X)D(Y)$

(B) X, Y 不相关

(C) X, Y 独立

(D) X, Y 不独立

答案：

5、 C

6、 C

7、 A

8、 B



一套设备由三大部件构成，在设备运转过程中各部件需要调整的概率分别为0.1、0.2、0.3，假设各部件的状态相互独立，以 X 表示同时需要调整的部件数，求 $E(X)$ ， $D(X)$ 。

答案：

解：【解】令 $A_i = \{\text{第 } i \text{ 个部件需要调整}\} (i = 1, 2, 3)$ ， X 的可能取值为 0, 1, 2, 3，

$$P(X=0) = P(\overline{A_1} \overline{A_2} \overline{A_3}) = 0.9 \times 0.8 \times 0.7 = 0.504,$$

$$P(X=1) = P(A_1 \overline{A_2} \overline{A_3}) + P(\overline{A_1} A_2 \overline{A_3}) + P(\overline{A_1} \overline{A_2} A_3) = 0.398,$$

$$P(X=3) = P(A_1 A_2 A_3) = 0.006,$$

$$P(X=2) = 1 - 0.504 - 0.398 - 0.006 = 0.092,$$

$$\text{所以 } X \text{ 的分布律为 } X \sim \begin{pmatrix} 0 & 1 & 2 & 3 \\ 0.504 & 0.398 & 0.092 & 0.006 \end{pmatrix}.$$


$$E(X) = 1 \times 0.398 + 2 \times 0.092 + 3 \times 0.006 = 0.6,$$

$$D(X) = E(X^2) - [E(X)]^2 = 1^2 \times 0.398 + 2^2 \times 0.092 + 3^2 \times 0.006 - 0.36 = 0.46.$$



设 $(X_1, X_2, \dots, X_9)$ 为总体 $X \sim N(0, 2^2)$ 的简单随机样本，
若 a, b, c 使
 $Y = a(X_1 + X_2)^2 + b(X_3 + X_4 + X_5)^2 + c(X_6 + X_7 + X_8 + X_9)^2$ 服从 χ^2 分布，

求 (1) a, b, c 的值；
(2) χ^2 分布的自由度。



(1) 解 由 $X_1, X_2, \dots, X_9$ 独立同分布, 且均服从 $N(0, 2^2)$, 故有

$$X_1 + X_2 \sim N(0, 2^2 + 2^2) = N(0, 8),$$
$$X_3 + X_4 + X_5 \sim N(0, 2^2 + 2^2 + 2^2) = N(0, 12),$$
$$X_6 + X_7 + X_8 + X_9 \sim N(0, 2^2 + 2^2 + 2^2 + 2^2) = N(0, 16),$$

从而

$$\frac{X_1 + X_2}{\sqrt{8}} \sim N(0, 1), \left(\frac{X_1 + X_2}{\sqrt{8}} \right)^2 \sim \chi^2(1),$$

$$\frac{X_3 + X_4 + X_5}{\sqrt{12}} \sim N(0, 1), \left(\frac{X_3 + X_4 + X_5}{\sqrt{12}} \right)^2 \sim \chi^2(1),$$

$$\frac{X_6 + X_7 + X_8 + X_9}{\sqrt{16}} \sim N(0, 1), \left(\frac{X_6 + X_7 + X_8 + X_9}{\sqrt{16}} \right)^2 \sim \chi^2(1).$$

由独立性及 χ^2 分布的可加性, 知

$$\frac{(X_1 + X_2)^2}{8} + \frac{(X_3 + X_4 + X_5)^2}{12} + \frac{(X_6 + X_7 + X_8 + X_9)^2}{16} \sim \chi^2(3),$$

故 $a = \frac{1}{8}, b = \frac{1}{12}, c = \frac{1}{16}$, 自由度 $n = 3$.