

第九章 人工智能安全

演讲人

2024-05-06



第九章 人工智能安全

主要内容

第一节 人工智能安全问题

第三节解决安全问题的策略



职业功能与专业能力要求

第二节 人工智能安全的要素

思考题

第九章 人工智能安全

主要内容

- ◆ 人工智能近年来得到飞速发展并广泛应用于各个领域，然而，驻足于提升人工智能系统的任务表现能力是远远不够的，人工智能的长期发展离不开安全可靠的保障。人工智能应用因存在风险而产生的安全事故层出不穷，如何分析并提升人工智能的安全性能成为亟待解决的问题。本章整合人工智能涉及的各种安全问题与要素，分析现有解决人工智能安全问题的策略，这些是人工智能安全研究与技术人员的必备知识。掌握分析和运用其中的方法论是研究人工智能安全的必备能力。

第九章 人工智能安全

职业功能与专业能力要求

■ 职业功能:人工智能安全相关内容

■ 工作内容:人工智能安全问题, 人工智能安全要素, 解决安全问题的策略

■ 专业能力要求:能够了解人工智能领域面临的安全风险, 学习人工智能安全涉及的核心要素的基本概念与分析方法, 在此基础上理解不同角度解决安全问题的策略并学会应用策略设计方法解决人工智能的安全问题, 为从事人工智能的安全领域研究打下基础。

■ 相关知识要求:人工智能安全问题包括内在安全隐患与外在驱动风险, 常见数据与算法安全问题, 以及人工智能应用产生的不安全效应;人工智能安全要素涉及泛化性、鲁棒性、可解释性公平性、隐私性、可验真性, 可问责性、可控性的基本概念及其与安全的关联性分析:解决安全问题的策略部分学习分析鲁棒机器学习、可解释人工智能、公平人工智能、隐私保护、安全监测与评估等提升人工智能安全性的技术

第九章 人工智能安全

第一节 人工智能安全问题

考核知识点及能力要求

二、人工智能驱动安全风险



一、人工智能内在安全隐患

考核知识点及能力要求

- 了解人工智能的内在安全隐患
- 熟悉常见人工智能数据、算法、网络安全问题表征与产生原因
- 了解人工智能应用产生的安全风险和信息传播风险
- 了解可能对社会和国家造成的危害。



一、人工智能内在安全隐患

(一)数据隐患

1

(二)算法隐患


2

(三)网络隐患

3

一、人工智能内在安全隐患

(一) 数据隐患



现代人工智能的发展依托大数据的保障，数据质量将直接影响人工智能模型的安全性能。人工智能数据隐患主要包括数据容量不足、数据分布差异、数据标注错误数据被污染等问题。

1. 数据容量不足

2. 数据分布差异


3. 数据标注错误

4. 数据被污染

一、人工智能内在安全隐患

(二) 算法隐患

除了数据隐患外，人工智能模型本身也存在算法性能低下、偏见与歧视、不可解释、面临对抗攻击的威胁等问题。



一、人工智能内在安全隐患

(三) 网络隐患

人工智能不可避免地会引入网络连接，许多网络安全问题也会给人工智能系统造成隐患，如开源导致的漏洞与后门风险、恶意软件等。

01

1. 开源框架漏洞与后门

02

2. 恶意软件

03

二、人工智能驱动安全风险

(一) 信息传播
风险

1

(二) 社会安全
风险

2

(三) 国家安全
风险

3

二、人工智能驱动安全风险

(一) 信息传播风险

1.信息隐私泄
露

1

2.不良信息推
荐

2

3.虚假信息生
成

3

二、人工智能驱动安全风险

(二) 社会安全风险

人工智能应用也会给社会安全带来挑战，例如会引发结构性失业问题，无人驾驶等技术安全性仍未达标，从而给人们的生活带来安全风险，甚至可能引发对伦理道德的冲击等

1. 结构性失业

2. 生活安全隐患

3. 伦理道德冲击

二、人工智能驱动安全风险

(三) 国家安全风险



未来人工智能作为世界各国的重点发展领域，必然会应用于国家重点项目当中此时，人工智能的风险不再停留在个人与社会层面，而是上升为国家安全风险。其中典型的是其对于政治意识形态的影响和在军事领域的威胁。



1. 影响政治意识形态



2. 威胁国家军事安全

第九章 人工智能安全

第二节 人工智能安全的要素

考核知识
点及能力
要求:

一、泛
化性

二、鲁
棒性


三、可
解释性

四、公
平性

五、隐
私性

第九章 人工智能安全

第二节 人工智能安全的要素



考核知识点及能力要求：

了解泛化性、鲁棒性、可解释性、公平性、隐私性、可验真性、可问责性、可控性的基本概念，及其与人工智能安全的联系；熟悉常见的自然噪声类型以及对抗噪声的基本原理；了解常见的对抗攻击算法；了解常见的增强可解释性的方法；熟悉常见的引发不公平的问题；熟悉常见的隐私性问题；了解“深度伪造”等技术的危害。

一、泛化性

(一) 概述



泛化性是指训练后的人工智能模型应用到与训练数据不同分布的数据上时，做出准确预测的能力的特性。



泛化性的核心关注点是智能模型对新数据开展判断时的泛化能力的理解和提升。



图9-4展示了模型泛化误差与网络容量的关系

(二) 泛化性与安全

- ▶ 在实际应用中，若模型无法泛化到测试数据上，就会在实际预测的过程中出现错误，给真实世界中部署的人工智能模型带来极大的安全隐患。
- ▶ 泛化性主要与模型和数据这两大因素相关。
- ▶ 首先，在实际场景中，训练数据和测试数据的分布有一定差异。
- ▶ 其次，复杂模型的可解释性缺乏，也间接影响了模型泛化性。



(二) 鲁棒性

鲁棒性是人工智能系统在各种环境运行时，当出现异常或者噪声时，保持其性能水平的特性。

人工智能系统的鲁棒性一般包括

- (1) 系统输入受到一个具体扰动时的鲁棒性
- (2) 系统输入发生难以具体刻画的变化时的鲁棒性



(二) 鲁棒性与安全

2. 自然噪声

真实世界中还存在一些非人为构造的、自然真实的噪声，称为自然噪声。

自然噪声数据集
ImageNet-C包含了15种不同的噪声类型

1. 对抗噪声

最早由塞格迪(Szegedy)等人提出，他们通过借助模型的梯度信息来生成微小的、人类不可见的噪声，并将其加在原图片上，从而严重扰乱深度神经网络等模型的正常识别。

常见的对抗攻击方法有FGSM、PCD、C&W、AutoAttack 等

按攻击者所能获得的信息分类，对抗攻击可分为黑盒攻击、灰盒攻击和白盒攻击



三、可解释性

人工智能的可解释性主要分为三大层次

- 第一，智能体要有自省及自辩的能力；
- 第二，智能体要有对人类的认知和适应能力；
- 第三，智能体要有发明模型的能力。

可解释性是指智能体以一种可解释、可理解、人机互动的方式，与人工智能系统的使用者、受影响者、决策者、开发者等，达成清晰而有效的交流沟通以取得人类信任、同时满足各类应用场景对智能体决策机制的监管要求。

三、可解释性

(二) 可解释性与安全

1. 建模前的
可解释

1

2. 建模过程
中的可解释

2

3. 事后可解
释

3

四、公平性

公平性是保证人工智能系统对待特定对象、人员或群体不出现系统性差别的特性

- ◆ 公平性与文化、地域和政治观点等因素有关

四、公平性

(二) 公平性与安全

(1)在数据收集与预处理阶段，开发人员可能会主观上或无意识地对不同群体收集不同分布的数据，同时在标注和预处理过程中可能会带有自己的主观偏见，从而向算法模型学习的特征中人为地注入了偏见。

(2)在算法模型构建上，开发人员可能更多关注准确率等产品直接利益相关的目标，而缺乏对公平性的考量，在设计之初没有重点关注到潜在的公平性风险

(3)在算法模型测试上，测试人员主要关注准确率、性能、速度等指标，而由于算法模型自身可解释性较差等因素，缺乏对算法模型公平性的缺陷检测。

(4)在人工智能系统应用中，人工智能算法作为互联网企业高效率运作并提供个性化服务的基础，逐渐成为侵害消费者权益的新工具，如大数据杀熟等。

五、隐私性

(一)概述

隐私性是指人工智能系统在运行时对数据中直接或间接隐含的、涉及个人或组织的、不宜公开的、需要在数据收集、数据存储、数据查询和分析、数据发布、使用等过程中加以保护的信息进行保密，防止其泄露的性质。

(二)隐私性与安全

隐私性是人工智能系统功能安全、伦理符合性的支柱，决定隐私保护的关键技术可以保护信息安全、鲁棒性等。因此，对于数据中的隐私保护也是值得研究的方向,它有助于保护用户隐私、保障人工智能的应用安全。

六、可验真性

(一)概述

可验真性是指人工智能模型对于深度伪造等伪造算法的检测、分辨能力。深度伪造技术是通过被称作“生成式对抗网络”(GAN)的机器学习模型将图片或视频合并、叠加到源图片或视频上,利用深度学习方法进行学习,拼接合成虚假声音、面部表情及身体动作的技术。观察者通常无法通过肉眼分辨合成信息的真伪。

(二)可验真性与安全

深度伪造技术的出现,严重威胁了国家安全和公共安全,深度伪造技术可能被不法分子利用,传播虚假乃至含有暴力与黄色内容的视频,扰乱社会治安,造成不良的社会影响。


开源的特性使得该技术可以被不法分子获得,进而可以利用用户的信息进行敲诈勒索等、提高社会的犯罪率。

深度伪造技术也会加剧现代社会的信任危机、大众难以区分真假信息从而对真实的信息抱有怀疑态度,使得良好意识形态建立的难度加大。

七、可问责性

(一) 概述

- ◆ 可问责性指人工智能系统及其利益相关方能为其行为责任(基于法律、协议或授权)作出解释、说明的特性;从监管角度,也可指监管部门的一种权力,即其可对人工智能系统或服务的提供方及使用方行使的监管权力。



(二) 可问责性与安全

1. 明确人工智能利益相关者的责任分配是应用人工智能时亟待解决的问题。
2. 可问责性的实现，可从技术层和管理层出发
3. 技术层主要表现在对人工智能应用过程的记录、相关数据和设施的信息安全，以及对系统行为的解释。
4. 管理层，主要体现在人工智能系统各利益相关方的权责划分和活动约束，及系统生命周期各阶段的管理要求

八、可控性

(一) 概述

- ◆ 可控性是人工智能系统作业可被外界的操作者(人或智能体)干预的特性。

(二) 可控性与安全

实现可控性的关键是要识别系统的运行状态观测及迁移的点

- ◆ 外部干预要求在人工智能系统与人或其他外部代理间进行控制移交
- ◆ 核心是在人工智能系统的设计和实现过程中考虑具体移交点。

第九章 人工智能安全

第三节解决安全问题的策略

考核知识点及能力要求:

一、鲁棒机器学习

二、可解释人工智能

三、公平人工智能

四、隐私保护

五、安全监管与评估

考核知识点及能力要求：

了解掌握鲁棒机器学习的内涵，熟悉数据质量提升与模型对抗训练；
了解掌握可解释人工智能的内涵，熟悉深度神经网络解释的常见维度；
了解掌握公平人工智能的内涵，熟悉公平人工智能设计与偏见发现的主要技术；
了解隐私保护的方向与方法；了解人工智能安全监管与评估的重要性。

一、鲁棒机器学习

(一) 数据层面鲁棒性提升

鲁棒性：模型对数据变化的容忍度

数据质量：对模型鲁棒性至关重要

检测与过滤：对抗样本与数据投毒


(二) 算法模型层面鲁棒性提升

增强方法：算法设计、选择与调优

对抗训练：引入对抗样本到训练过程

理论量化分析：精确方法与近似方法

二、可解释人工智能



二、可解释人工智能

(一) 神经网络特征可视化

最大激活响
应可视化



网络解剖



类别激活映
射(CAM)和
Grad-
CAM++





“

二、可解释人工智能

(二) 输入单元重要性归因

”

01

反向传播方法：导向反向传播、LRP等

02

输入处理方法：LIME等



二、可解释人工智能

（三）博弈交互解释性理论

- ◆ 输入样本中各单元之间的交互作用



二、可解释 人工智能

(四) 对神经网络特征质量解
构、解释和可视化



稳定性量化：衡
量学习表征的一
致性



复杂度量化：分
析神经网络表征
的复杂度

二、可解释人工智能

(五) 对表达结构的解释

◆代理模型：知识蒸馏

二、可解释人工智能

(六) 可解释的神经网络

胶囊网络

Beta-变分自编码器

可解释的卷积神经网络

可解释的组成卷积神经网络

三、公平人工智能

(一) 偏见发现

关联规则挖掘

k最邻近分类

概率因果网络

隐私攻击

基于深度学习方法

(二) 公平机器学习设计

预处理：训练数据预处理

中间处理：学习模型和算法
的处理

后处理：模型或模型预测的
数据处理

四、隐私保护

(一) 避免数据采集过度

(三) 数据标注过程保护

(五) 模型训练过程的隐私保护

(七) 模型部署过程的隐私保护

(二) 增强数据匿名化

(四) 数据浏览记录保护

(六) 模型推理过程的隐私保护

(八) 模型自身的隐私保护




五、安全监管与评估



第九章 人工智能安全

思考题



谢谢！

