

3.6 条件分布

在第一章中, 我们介绍了条件概率, 用来刻画一个事件的发生对另一事件发生可能性的影响. 基于同样的想法, 有时需要考虑在已知某随机变量取某值的条件下, 去研究另一随机变量的概率分布. 这就是下面我们所要研究的条件分布.

3.6.1 条件分布函数

假设给定二维随机变量 (X, Y) 的联合分布, 自然地, 若概率 $P(Y = y) > 0$, 称 x 的函数 $P(X \leq x|Y = y)$ 为在 $Y = y$ 的条件下 X 的条件分布函数. 为了避免 $P(Y = y) = 0$ (譬如, Y 为连续型随机变量)的情形, 我们有下面严格的定义.

定义3.6.1 设 (X, Y) 为二维随机变量, 且对任意的 $\Delta y > 0$, $P(y - \Delta y < Y \leq y) > 0$. 若对任意的实数 x , 极限

$$\lim_{\Delta y \rightarrow 0+} P(X \leq x|y - \Delta y < Y \leq y) = \lim_{\Delta y \rightarrow 0+} \frac{P(X \leq x, y - \Delta y < Y \leq y)}{P(y - \Delta y < Y \leq y)}$$

存在, 则称该极限为在 $Y = y$ 的条件下 X 的条件分布函数, 记为 $P(X \leq x|Y = y)$ 或 $F_{X|Y}(x|y)$.

注记3.6.1 $P(X \leq x|Y = y)$ 或 $F_{X|Y}(x|y)$ 只是一个记号, 且并非对所有的 y , 条件分布函数 $F_{X|Y}(x|y)$ 都存在.

下面我们分别就离散情形和连续情形来考虑条件分布.

3.6.2 条件分布列

设 (X, Y) 为二维离散型随机变量, 且其联合分布列为

$$P(X = x_i, Y = y_j) = p_{ij}, \quad i, j = 1, 2, \dots$$

当 $P(Y = y_j) > 0$ 时, 这里 $j = 1, 2, \dots$, 由条件概率的定义可知, 在 $Y = y_j$ 的条件下 X 的条件分布列为

$$P(X = x_i|Y = y_j) = \frac{P(X = x_i, Y = y_j)}{P(Y = y_j)} = \frac{p_{ij}}{\sum_k p_{kj}}, \quad i = 1, 2, \dots$$

例3.6.1 已知 (X, Y) 有联合分布列如下:

X \ Y	Y		
	0	1	2
0	1/2	1/8	1/4
1	1/16	1/16	0

求在 $X = 0$ 的条件下 Y 的条件分布列.

解 易求

$$P(X = 0) = \frac{1}{2} + \frac{1}{8} + \frac{1}{4} = \frac{7}{8}.$$

于是, 在 $X = 0$ 的条件下 Y 的条件分布列为

$$P(Y = 0|X = 0) = \frac{P(X = 0, Y = 0)}{P(X = 0)} = \frac{1/2}{7/8} = \frac{4}{7},$$

$$P(Y = 1|X = 0) = \frac{P(X = 0, Y = 1)}{P(X = 0)} = \frac{1/8}{7/8} = \frac{1}{7},$$

$$P(Y = 2|X = 0) = \frac{P(X = 0, Y = 2)}{P(X = 0)} = \frac{1/4}{7/8} = \frac{2}{7}. \quad \square$$

例3.6.2 设随机变量 X 与 Y 相互独立, 且 X 服从泊松分布 $P(\lambda)$, Y 服从泊松分布 $P(\mu)$. 求在 $X + Y = n$ 的条件下 X 的条件分布.

解 由泊松分布的可加性知, $X + Y$ 服从泊松分布 $P(\lambda + \mu)$. 于是,

$$P(X + Y = n) = \frac{(\lambda + \mu)^n}{n!} e^{-(\lambda + \mu)}.$$

由条件概率的定义和独立性知, 在 $X + Y = n$ 的条件下 X 的条件分布列为

$$\begin{aligned} P(X = k|X + Y = n) &= \frac{P(X = k, X + Y = n)}{P(X + Y = n)} = \frac{P(X = k)P(Y = n - k)}{P(X + Y = n)} \\ &= \frac{\frac{\lambda^k}{k!} e^{-\lambda} \frac{\mu^{n-k}}{(n-k)!} e^{-\mu}}{\frac{(\lambda + \mu)^n}{n!} e^{-(\lambda + \mu)}} = C_n^k \left(\frac{\lambda}{\lambda + \mu} \right)^k \left(\frac{\mu}{\lambda + \mu} \right)^{n-k}, k = 0, 1, \dots, n. \end{aligned}$$

即在 $X + Y = n$ 的条件下 X 的条件分布为二项分布 $b\left(n, \frac{\lambda}{\lambda + \mu}\right)$. $\square$

3.6.3 条件概率密度函数

设随机变量 (X, Y) 有联合概率密度函数 $p(x, y)$, X 与 Y 的边缘概率密度函数分别为 $p_X(x)$ 和 $p_Y(y)$, 且 $p_Y(y) > 0$. 注意到

$$P(X \leq x, y - \Delta y < Y \leq y) = \int_{-\infty}^x \int_{y-\Delta y}^y p(u, v) du dv = \int_{y-\Delta y}^y \left(\int_{-\infty}^x p(u, v) du \right) dv,$$

由微分中值定理知,

$$\lim_{\Delta y \rightarrow 0+} \frac{1}{\Delta y} P(X \leq x, y - \Delta y < Y \leq y) = \lim_{\Delta y \rightarrow 0+} \frac{1}{\Delta y} \int_{y-\Delta y}^y \left(\int_{-\infty}^x p(u, v) du \right) dv$$

$$= \int_{-\infty}^x p(u, y) du.$$

类似地, 我们有 $\lim_{\Delta y \rightarrow 0+} \frac{1}{\Delta y} P(y - \Delta y < Y \leq y) = p_Y(y)$.

于是由定义3.6.1知, 在 $Y = y$ 的条件下 X 的条件分布函数为

$$F_{X|Y}(x|y) = \int_{-\infty}^x \frac{p(u, y)}{p_Y(y)} du.$$

因此在 $Y = y$ 的条件下, X 的条件分布是连续型分布, 其概率密度函数为

$$\frac{p(x, y)}{p_Y(y)},$$

称之为在 $Y = y$ 的条件下 X 的条件概率密度函数, 记为 $p_{X|Y}(x|y)$. 即

$$p_{X|Y}(x|y) = \frac{p(x, y)}{p_Y(y)}.$$

读者应特别注意, 上式只有当 $p_Y(y) > 0$ 时才有意义.

例3.6.3 设 (X, Y) 服从二维正态分布 $N(\mu_1, \sigma_1^2; \mu_2, \sigma_2^2; \rho)$, 求在 $Y = y$ 条件下 X 的条件分布.

解 由定理3.2.4知, Y 的边缘分布为正态分布 $N(\mu_2, \sigma_2^2)$. 故在 $Y = y$ 条件下 X 的条件概率密度函数为

$$\begin{aligned} p_{X|Y}(x|y) &= \frac{p(x, y)}{p_Y(y)} = \frac{\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left[-\frac{1}{2(1-\rho^2)}\left(\frac{(x-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2}\right)\right]}{\frac{1}{\sqrt{2\pi}\sigma_2} \exp\left(-\frac{(y-\mu_2)^2}{2\sigma_2^2}\right)} \\ &= \frac{1}{\sqrt{2\pi}\sigma_1\sqrt{1-\rho^2}} \exp\left[-\frac{1}{2\sigma_1^2(1-\rho^2)}(x - (\mu_1 + \rho\sigma_1(y-\mu_2)/\sigma_2))^2\right] \end{aligned}$$

即在 $Y = y$ 条件下 X 的条件分布是正态分布 $N(\mu_1 + \rho\sigma_1(y-\mu_2)/\sigma_2, \sigma_1^2(1-\rho^2))$. $\square$

另解 记 $X^* = \frac{X - \mu_1}{\sigma_1}$, $Y^* = \frac{Y - \mu_2}{\sigma_2}$, 由定理3.4.16, (X^*, Y^*) 服从二维正态分布 $N(0, 1; 0, 1; \rho)$, 其联合概率密度函数为

$$p^*(x, y) = \frac{1}{2\pi\sqrt{1-\rho^2}} \exp\left(-\frac{1}{2(1-\rho^2)}(x^2 + y^2 - 2\rho xy)\right).$$

由定理3.2.4知, Y^* 的边缘分布为正态分布 $N(0, 1)$, 其概率密度函数为

$$p_{Y^*}^*(y) = \varphi(y) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{y^2}{2}\right).$$

故在 $Y^* = y$ 条件下 X^* 的条件概率密度函数为

$$\begin{aligned} p_{X^*|Y^*}^*(x|y) &= \frac{p^*(x, y)}{p_{Y^*}^*(y)} = \frac{\frac{1}{2\pi\sqrt{1-\rho^2}} \exp\left(-\frac{1}{2(1-\rho^2)}(x^2 + y^2 - 2\rho xy)\right)}{\frac{1}{\sqrt{2\pi}} \exp\left(-\frac{y^2}{2}\right)} \\ &= \frac{1}{\sqrt{2\pi}\sqrt{1-\rho^2}} \exp\left[-\frac{(x - \rho y)^2}{2(1-\rho^2)}\right] \end{aligned}$$

即 X^* 在给定 $Y^* = y$ 的条件下的条件分布为正态分布 $N(\rho y, 1 - \rho^2)$.

注意到 $X = \sigma_1 X^* + \mu_1$, $Y = y$ 当且仅当 $Y^* = \frac{y - \mu_2}{\sigma_2}$, 因而由正态分布的线性不变性知, X 在给定 $Y = y$ 时的条件分布为正态分布 $N(\mu_1 + \rho\sigma_1(y - \mu_2)/\sigma_2, \sigma_1^2(1 - \rho^2))$. $\square$

例3.6.4 设随机变量 (X, Y) 服从区域 $D = \{(x, y) : x^2 + y^2 \leq 1\}$ 上的均匀分布, 设 $|y| < 1$, 求在给定 $Y = y$ 条件下 X 的条件概率密度函数.

解 易知 (X, Y) 的联合概率密度函数为

$$p(x, y) = \begin{cases} \frac{1}{\pi}, & x^2 + y^2 \leq 1, \\ 0, & x^2 + y^2 > 1. \end{cases}$$

由例3.2.5知, Y 的边际概率密度函数为

$$p_Y(y) = \begin{cases} \frac{2\sqrt{1-y^2}}{\pi}, & |y| < 1, \\ 0, & |y| \geq 1. \end{cases}$$

于是, 当 $|y| < 1$ 时, 在给定 $Y = y$ 条件下 X 的条件概率密度函数为

$$\begin{aligned} p_{X|Y}(x|y) &= \frac{p(x, y)}{p_Y(y)} = \frac{p(x, y)}{2\sqrt{1-y^2}/\pi} = \begin{cases} \frac{1/\pi}{2\sqrt{1-y^2}/\pi}, & |x| \leq \sqrt{1-y^2}, \\ 0, & |x| > \sqrt{1-y^2} \end{cases} \\ &= \begin{cases} \frac{1}{2\sqrt{1-y^2}}, & |x| \leq \sqrt{1-y^2}, \\ 0, & |x| > \sqrt{1-y^2}. \end{cases} \end{aligned}$$

故当 $|y| < 1$ 时, 在给定 $Y = y$ 条件下 X 服从均匀分布 $U(-\sqrt{1-y^2}, \sqrt{1-y^2})$. □

例3.6.5 已知随机变量 (X, Y) 的概率密度函数为

$$p(x, y) = \begin{cases} \frac{e^{-x/y}e^{-y}}{y}, & x > 0, y > 0, \\ 0, & \text{其他.} \end{cases}$$

当 $y > 0$ 时, 求概率 $P(X > 1|Y = y)$.

解 容易求得 Y 的边际概率密度函数为

$$p_Y(y) = \int_{-\infty}^{\infty} p(x, y)dx = \begin{cases} \int_0^{\infty} \frac{e^{-x/y}e^{-y}}{y}dx, & y > 0, \\ 0, & y \leq 0 \end{cases} = \begin{cases} e^{-y}, & y > 0, \\ 0, & y \leq 0. \end{cases}$$

当 $y > 0$ 时, 在给定 $Y = y$ 条件下 X 的条件概率密度函数为

$$p_{X|Y}(x|y) = \frac{p(x, y)}{p_Y(y)} = \begin{cases} \frac{e^{-x/y}e^{-y}y^{-1}}{e^{-y}}, & x > 0, \\ 0, & x \leq 0 \end{cases} = \begin{cases} \frac{e^{-x/y}}{y}, & x > 0, \\ 0, & x \leq 0. \end{cases}$$

故当 $y > 0$ 时, 在给定 $Y = y$ 条件下 X 服从指数分布 $\text{Exp}\left(\frac{1}{y}\right)$, 从而所求条件概率为

$$P(X > 1|Y = y) = \int_1^{\infty} p_{X|Y}(x|y)dx = \int_1^{\infty} \frac{e^{-x/y}}{y}dx = e^{-1/y}. \quad \square$$

3.7 条件数学期望

正如条件概率是概率一样, 条件分布是一个概率分布, 因而可以考虑条件分布的数字特征.

3.7.1 关于随机事件的条件数学期望

条件分布的数学期望称为条件数学期望, 定义如下:

定义3.7.1 设 (X, Y) 为二维随机变量, 称

$$E(X|Y=y) = \begin{cases} \sum_i x_i P(X=x_i|Y=y), & \text{离散情形} \\ \int_{-\infty}^{\infty} x p_{X|Y}(x|y) dx, & \text{连续情形} \end{cases}$$

为在 $Y=y$ 的条件下 X 的**条件数学期望**.

注记3.7.1 在条件数学期望的定义中, 我们必须注意到

- (1) 只有当条件分布列 $P(X=x_i|Y=y)$ 或条件概率密度函数 $p_{X|Y}(x|y)$ 有意义时才有可能去考虑条件数学期望 $E(X|Y=y)$.
- (2) 条件数学期望可能不存在, 即上述求和或积分结果可能是无穷大.
- (3) 条件数学期望 $E(X|Y=y)$ 是 y 的函数.
- (4) 设在概率空间 $(\Omega, \mathcal{F}, P)$ 中有随机变量 X 和随机事件 B , 若 $P(B) \neq 0$, 我们可以定义随机变量 X 关于随机事件 B 的条件数学期望

$$E(X|B) = \frac{E(X \cdot 1_B)}{P(B)},$$

只要等式右边的数学期望存在.

例3.7.1 设 (X, Y) 服从二维正态分布 $N(\mu_1, \sigma_1^2; \mu_2, \sigma_2^2; \rho)$, 求在 $Y=y$ 条件下 X 的条件数学期望.

解 由例3.6.3知, 在 $Y=y$ 条件下 X 的条件分布为正态分布

$$N(\mu_1 + \rho\sigma_1(y - \mu_2)/\sigma_2, \sigma_1^2(1 - \rho^2)),$$

故在 $Y=y$ 条件下 X 的条件数学期望为 $E(X|Y=y) = \mu_1 + \rho\sigma_1(y - \mu_2)/\sigma_2$. $\square$

例3.7.2 设随机变量 (X, Y) 服从区域 $D = \{(x, y) : x^2 + y^2 \leq 1\}$ 上的均匀分布, $|y| \leq 1$, 求在给定 $Y=y$ 条件下 X 的条件数学期望.

解 由例3.6.4知, 当 $|y| \leq 1$ 时, 在给定 $Y = y$ 条件下 X 的条件分布为均匀分布

$$U(-\sqrt{1-y^2}, \sqrt{1-y^2}),$$

故由表4-1知, 在给定 $Y = y$ 条件下 X 的条件数学期望 $E(X|Y = y) = 0$. $\square$

例3.7.3 已知随机变量 (X, Y) 的联合概率密度函数为

$$p(x, y) = \begin{cases} \frac{e^{-x/y} e^{-y}}{y}, & x > 0, y > 0, \\ 0, & \text{其他.} \end{cases}$$

求当 $y > 0$ 时 X 的条件数学期望 $E(X|Y = y)$.

解 由例3.6.5知, 当 $y > 0$ 时, 在给定 $Y = y$ 条件下 X 服从指数分布 $\text{Exp}\left(\frac{1}{y}\right)$, 故由表2-1知, 在给定 $Y = y$ 条件下 X 的条件数学期望为 $E(X|Y = y) = y$. $\square$

3.7.2 关于随机变量的条件数学期望

既然条件数学期望 $E(X|Y = y)$ 是 y 的函数, 记为 $g(y)$. 我们可以考虑随机变量 Y 的函数 $g(Y)$, 即 $g(Y) = E(X|Y)$, 因而 $E(X|Y)$ 是随机变量, 当 $Y = y$ 时其取值为 $E(X|Y = y)$. 我们可以证明条件数学期望和数学期望有如下的关系.

定理3.7.1 重期望公式 设 (X, Y) 是二维随机变量, 且 EX 存在, 则

$$EX = E(E(X|Y)).$$

注记3.7.2 重期望公式的本质是全概率公式. 使用重期望公式的方法如下:

$$EX = \begin{cases} \sum_j E(X|Y = y_j)P(Y = y_j), & \text{离散情形,} \\ \int_{-\infty}^{\infty} E(X|Y = y)p_Y(y)dy, & \text{连续情形.} \end{cases}$$

例3.7.4 设随机变量 Y 服从均匀分布 $U(0, 1)$, 当 $Y = y(0 < y < 1)$ 时, X 服从均匀分布 $U(y, 1)$. 求数学期望 EX .

解 当 $Y = y(0 < y < 1)$ 时, X 的条件分布为均匀分布 $U(y, 1)$. 于是条件数学期望 $E(X|Y = y) = \frac{y+1}{2}$. 故 $E(X|Y) = \frac{Y+1}{2}$, 从而

$$EX = E(E(X|Y)) = E\left(\frac{Y+1}{2}\right) = \frac{3}{4}. \quad \square$$

例3.7.5 设某只母鸡下蛋数 N 服从Poisson分布 $P(\lambda)$, 每只鸡蛋相互独立地以概率 p 能被孵化为小鸡. 设 X 表示小鸡的数目, 求 EX , $E(X|N)$ 和 $E(N|X)$.

解 由已知, $N \sim P(\lambda)$, 故分布列为

$$P(N = n) = \frac{\lambda^n}{n!} e^{-\lambda}, \quad n = 0, 1, \dots$$

期望为 $EN = \lambda$.

在 $N = n$ 的条件下, $X \sim b(n, p)$, 故 $E(X|N = n) = np$, 进而 $E(X|N) = Np$, 由重期望公式, $EX = E(E(X|N)) = pEN = \lambda p$.

下求 $E(N|X)$. 由 Bayes 公式,

$$\begin{aligned} P(N = n|X = m) &= \frac{P(X = m|N = n)P(N = n)}{\sum_{j=m}^{\infty} P(X = m|N = j)P(N = j)} \\ &= \frac{C_n^m p^m (1-p)^{n-m} \cdot \frac{\lambda^n}{n!} e^{-\lambda}}{\sum_{j=m}^{\infty} C_j^m p^m (1-p)^{j-m} \cdot \frac{\lambda^j}{j!} e^{-\lambda}} \\ &= \frac{(\lambda(1-p))^{n-m}}{(n-m)!} e^{-\lambda(1-p)}, \quad n = m, m+1, \dots \end{aligned}$$

即在 $X = m$ 的条件下, $N - X \sim P(\lambda(1-p))$. 于是, $E(N|X = m) = m + \lambda(1-p)$, 进而 $E(N|X) = X + \lambda(1-p)$. $\square$

注记3.7.3 重期望公式是概率论中较为深刻的结果, 离散情形或连续情形由联合分布与条件分布之间的关系以及条件数学期望的定义即得, 其完整的证明需要用到实分析或测度论的知识, 这里从略.

类似地, 我们有条件方差的定义.

定义3.7.2 称

$$\text{Var}(X|Y = y) = E[(X - E(X|Y = y))^2|Y = y] = E(X^2|Y = y) - [E(X|Y = y)]^2$$

为在 $Y = y$ 的条件下 X 的**条件方差**, 如果存在的话. 同样, $\text{Var}(X|Y)$ 是随机变量 Y 的函数, 当 $Y = y$ 时其取值为 $\text{Var}(X|Y = y)$.

由条件数学期望和条件方差的定义, 我们不难得出

定理3.7.2 条件方差公式

$$\text{Var}X = E(\text{Var}(X|Y)) + \text{Var}(E(X|Y)).$$

证明 由定义知,

$$\text{Var}(X|Y) = E(X^2|Y) - (E(X|Y))^2,$$

于是,

$$E(\text{Var}(X|Y)) = E(E(X^2|Y) - (E(X|Y))^2) = E(E(X^2|Y)) - E((E(X|Y))^2).$$

又因为

$$\text{Var}(E(X|Y)) = E((E(X|Y))^2) - (E(E(X|Y)))^2,$$

故由重期望公式

$$\begin{aligned} &E(\text{Var}(X|Y)) + \text{Var}(E(X|Y)) \\ &= E(E(X^2|Y)) - E((E(X|Y))^2) + E((E(X|Y))^2) - (E(E(X|Y)))^2 \end{aligned}$$

$$= E(E(X^2|Y)) - (E(E(X|Y)))^2 = EX^2 - (EX)^2 = \text{Var} X. \quad \square$$

最后, 我们特别指出, 条件数学期望 $E(X|Y)$ 是使得 $E(X - f(Y))^2$ 取得最小值的 $f(Y)$, 证明参见Degroot and Schervish [15] Theorem 4.7.3.