

4.4 中心极限定理

中心极限定理是研究在何种条件下, 大量随机变量的和的分布渐近服从正态分布的一类定理. 我们从例子开始.

例4.4.1 设随机变量 X 服从二项分布 $b(n, p)$, 则其分布列为

$$P(X = k) = C_n^k p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n.$$

现固定 $p = 0.1$, 当 $n = 10, 20, 50, 100$ 时, 分别作出其概率直方图, 如图4-1所示.

由图可知, 随着 n 的增大, 图像变得越来越对称. 事实上, 当 n 充分大时, 我们可以用正态分布 $N(np, np(1-p))$ 来近似替代二项分布 $b(n, p)$.




图4-1 二项分布 $b(n, 0.1)$ 的概率直方图

例4.4.2 设 $X_1, \dots, X_n$ 独立同分布且都服从均匀分布 $U(0, 1)$, 记 $S_n = \sum_{i=1}^n X_i$, 理论上来说, 由卷积公式, S_n 的分布是可以求出的. 例如, S_1, S_2, S_3 的概率密度函数依次为

$$p_1(x) = \begin{cases} 1, & 0 < x < 1, \\ 0, & \text{其他.} \end{cases} \quad p_2(x) = \begin{cases} x, & 0 < x < 1, \\ 2-x, & 1 \leq x < 2, \\ 0, & \text{其他.} \end{cases}$$

$$p_3(x) = \begin{cases} \frac{1}{2}x^2, & 0 < x < 1, \\ \frac{1}{2}(x^2 - 3(x-1)^2), & 1 \leq x < 2, \\ \frac{1}{2}(x^2 - 3(x-1)^2 - 3(x-2)^2), & 2 \leq x < 3, \\ 0, & \text{其他.} \end{cases}$$

但是随着 n 的增大, S_n 的概率密度函数会越来越复杂,使用起来也不方便.这就迫使人们去寻找 S_n 的近似分布.中心极限定理告诉我们其近似分布为正态分布.

4.4.1 定义

定义4.4.1 设 $\{X_n, n \geq 1\}$ 为随机变量序列, $S_n = X_1 + \cdots + X_n, n \geq 1$,若数学期望 ES_n 和方差 $\text{Var}S_n$ 都存在,且 $S_n^* = \frac{S_n - ES_n}{\sqrt{\text{Var}S_n}}$ 依分布收敛于标准正态分布 $N(0, 1)$,则称随机变量序列 $\{X_n, n \geq 1\}$ 满足中心极限定理.

注记4.4.1 若随机变量序列 $\{X_n, n \geq 1\}$ 满足中心极限定理,则对任意的 $x \in \mathbb{R}$,

$$\lim_{n \rightarrow \infty} P\left(\frac{S_n - ES_n}{\sqrt{\text{Var}S_n}} \leq x\right) = \Phi(x),$$

这里 Φ 是标准正态分布 $N(0, 1)$ 的分布函数.

4.4.2 中心极限定理

中心极限定理有很多版本,本节我们仅介绍独立同分布情形下的经典中心极限定理.

定理4.4.1 (Lindeberg-Lévy中心极限定理)

设 $\{X_n, n \geq 1\}$ 为独立同分布的随机变量序列,数学期望为 μ ,方差为 σ^2 ,则随机变量序列 $\{X_n, n \geq 1\}$ 满足中心极限定理.

证明 不妨设 $\mu = 0, \sigma = 1$. 设 X_1 的特征函数为 $f(t)$,由连续性定理,只需证明 $f^n\left(\frac{t}{\sqrt{n}}\right) \rightarrow e^{-t^2/2}$. 因为

$$\begin{aligned} f(t) &= f(0) + f'(0)t + f''(0)\frac{t^2}{2} + o(t^2) \\ &= 1 - \frac{t^2}{2} + o(t^2) \end{aligned}$$

故

$$f^n\left(\frac{t}{\sqrt{n}}\right) = \left[1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right)\right]^n \rightarrow e^{-t^2/2}. \quad \square$$

注意到二项分布具有可加性,作为Lindeberg-Lévy中心极限定理的推论,我们有

定理4.4.2 (DeMoivre-Laplace中心极限定理) 设 Y_n 服从二项分布 $b(n, p)$, 则

$$\lim_{n \rightarrow \infty} P \left\{ \frac{Y_n - np}{\sqrt{np(1-p)}} \leq y \right\} = \Phi(y),$$

这里 Φ 为标准正态分布的分布函数.

证明 设 $X_n, n \geq 1$ 相互独立且都服从二项分布 $b(1, p)$, 则对任意的 $n \geq 1, Y_n = \sum_{k=1}^n X_k$ 服从二项分布 $b(n, p)$. 注意到 $EY_n = np, \text{Var}Y_n = np(1-p)$, 由Lindeberg-Lévy中心极限定理即得. $\square$

4.4.3 应用

中心极限定理有很多应用场景, 譬如近似计算, 误差分析, 随机数的产生等, 这里我们仅给出在近似计算方面的应用.

若随机变量序列 $\{X_n, n \geq 1\}$ 满足中心极限定理, 则我们有

$$P \left(a \leq \sum_{k=1}^n X_k \leq b \right) \approx \Phi \left(\frac{b - n\mu}{\sigma\sqrt{n}} \right) - \Phi \left(\frac{a - n\mu}{\sigma\sqrt{n}} \right).$$

例4.4.3 每袋味精的净重为随机变量, 平均重量为100克, 标准差为10克. 一箱内装200袋味精, 求一箱味精的净重大于20300克的概率.

解 设 X_k 表示第 k 袋味精的净重, $k = 1, \dots, 200, X_1, \dots, X_{200}$ 独立同分布. 由题意, $EX_1 = 100, \text{Var}X_1 = 10^2$. 由中心极限定理, 所求概率为

$$P \left(\sum_{k=1}^{200} X_k > 20300 \right) \approx 1 - \Phi \left(\frac{20300 - 200 \times 100}{10\sqrt{200}} \right) = 1 - 0.9830 = 0.0170. \quad \square$$

例4.4.4 设 X 为一次射击中命中的环数, X 取6、7、8、9、10的概率分别为0.03、0.02、0.05、0.1、0.8. 求100次射击中命中环数在900环到930环之间的概率.

解 易求 $EX = 9.3, \text{Var}X = 1.51$. 设 X_k 表示第 k 次射击时命中的环数, $k = 1, \dots, 100$, 则 $X_1, \dots, X_{100}$ 相互独立, 且都与 X 同分布. 于是, 由中心极限定理, 所求的概率为

$$\begin{aligned} P \left(900 \leq \sum_{k=1}^{100} X_k \leq 930 \right) &\approx \Phi \left(\frac{930 - 100 \cdot 9.3}{\sqrt{100 \cdot 1.51}} \right) - \Phi \left(\frac{900 - 100 \cdot 9.3}{\sqrt{100 \cdot 1.51}} \right) \\ &= \Phi(0) - \Phi(-2.44) = \frac{1}{2} - (1 - 0.9927) = 0.4927. \quad \square \end{aligned}$$

例4.4.5 设每颗炮弹命中目标的概率为0.01, 求500发炮弹中命中5发的概率.

解 设 X 表示命中的炮弹数, 则 $X \sim b(500, 0.01)$.

由二项分布的分布列直接计算可得,

$$P(X = 5) = C_{500}^5 \times 0.01^5 \times 0.99^{495} = 0.17635.$$

由中心极限定理近似计算可得,

$$P(X=5) = P(4.5 < X < 5.5) \approx \Phi\left(\frac{5.5-5}{\sqrt{4.95}}\right) - \Phi\left(\frac{4.5-5}{\sqrt{4.95}}\right) = 0.1742. \quad \square$$

注记4.4.2 二项分布是离散分布, 而正态分布是连续分布, 所以用正态分布作为二项分布的近似时, 可作如下修正:

$$\begin{aligned} P(k_1 \leq Y_n \leq k_2) &= P(k_1 - 0.5 < Y_n < k_2 + 0.5) \\ &\approx \Phi\left(\frac{k_2 + 0.5 - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{k_1 - 0.5 - np}{\sqrt{np(1-p)}}\right). \end{aligned}$$

例4.4.6 100个独立工作(工作的概率为0.9)的部件组成一个系统, 求系统中至少有85个部件工作的概率.

解 设 X 表示工作的部件数, 则由题意知, $X \sim b(100, 0.9)$. 由中心极限定理知, 所求概率为

$$P(X \geq 85) \approx 1 - \Phi\left(\frac{85 - 0.5 - 100 \cdot 0.9}{\sqrt{100 \cdot 0.9 \cdot (1-0.9)}}\right) = 1 - \Phi\left(-\frac{5.5}{3}\right) = \Phi(1.83) = 0.9664. \quad \square$$

例4.4.7 有200台独立工作(工作的概率为0.7)的机床, 每台机床工作时需15kw电力. 问共需多少电力, 才可有95%的可能性保证正常生产?

解 设 X 表示正常工作的机床数, 则由题意知, $X \sim b(200, 0.7)$. 设需 y 千瓦电力, 才可有95%的可能性保证正常生产, 则必有

$$P(15X \leq y) \geq 95\%.$$

由中心极限定理知, 我们有

$$0.95 \leq P(15X \leq y) \approx \Phi\left(\frac{y/15 + 0.5 - 200 \cdot 0.7}{\sqrt{200 \cdot 0.7 \cdot (1-0.7)}}\right).$$

查标准正态分布函数表, 得

$$\frac{y/15 + 0.5 - 200 \cdot 0.7}{\sqrt{200 \cdot 0.7 \cdot (1-0.7)}} \geq 1.645$$

解得 $y \geq 2252$. 即共需2252千瓦电力, 才可有95%的可能性保证正常生产. $\square$

例4.4.8 连续地掷多少次均匀的硬币, 方能使得出现正面的频率与 $1/2$ 的差异不超过0.1的概率至少为0.7?

解 设需要掷 n 次, X 表示出现的正面数, 则 $X \sim b(n, 1/2)$. 由题意, 必有

$$P\left(\left|\frac{X}{n} - \frac{1}{2}\right| \leq 0.1\right) \geq 0.7.$$

由Chebyshev不等式(推论2.5.1), $P\left(\left|\frac{X}{n} - \frac{1}{2}\right| \leq 0.1\right) \geq 1 - \frac{25}{n}$. 由此解得当 $n \geq 84$ 时, $1 - \frac{25}{n} \geq 0.7$.

但是由中心极限定理, $P\left(\left|\frac{X}{n} - \frac{1}{2}\right| \leq 0.1\right) = 2\Phi\left(\frac{\sqrt{n}}{5}\right) - 1$. 由此解得当 $n \geq 17$ 时, $2\Phi\left(\frac{\sqrt{n}}{5}\right) - 1 \geq 0.7$.

由二项分布的分布列直接计算可得, 当 $n = 15$ 时, $P\left(\left|\frac{X}{n} - \frac{1}{2}\right| \leq 0.1\right) = P(0.4n \leq X \leq 0.6n) = 0.7$. $\square$

例4.4.9 为确定某部电视剧的收视率 p , 现调查 n 个对象, 记其中的观众数为 X , 问 n 至少为多大才能保证 $\frac{X}{n}$ 与 p 的差异小于 0.01 的概率不小于 95%?

解 由题意, 必有

$$P\left(\left|\frac{X}{n} - p\right| \leq 0.01\right) \geq 0.95.$$

由Chebyshev不等式(推论2.5.1), $P\left(\left|\frac{X}{n} - p\right| \leq 0.01\right) \geq 1 - \frac{p(1-p)}{n} \times 10^4$.

注意到 $p(1-p) \leq 1/4$, 当 $n \geq 5 \times 10^4$ 时, $1 - \frac{p(1-p)}{n} \times 10^4 \geq 0.95$.

由中心极限定理, $P\left(\left|\frac{X}{n} - p\right| \leq 0.01\right) = 2\Phi\left(0.01\sqrt{\frac{n}{p(1-p)}}\right) - 1$. 当 $n \geq 9604$ 时, $2\Phi\left(0.01\sqrt{\frac{n}{p(1-p)}}\right) - 1 \geq 0.95$. $\square$

注记4.4.3 中心极限定理比直接用Chebyshev不等式(推论2.5.1)作近似计算精度更好.

4.4.4 独立不同分布情形

定义4.4.2 (Lindeberg-Feller条件) 设 $\{X_n, n \geq 1\}$ 是独立随机变量序列, 且 $EX_n = \mu_n$, $\text{Var}X_n = \sigma_n^2 < \infty$. 记 $s_n = \sqrt{\sum_{i=1}^n \sigma_i^2}$, 若对任意的 $\epsilon > 0$,

$$\frac{1}{s_n^2} \sum_{i=1}^n E(X_i - \mu_i)^2 1_{\{|X_i - \mu_i| > \epsilon s_n\}} \longrightarrow 0,$$

则称 $\{X_n, n \geq 1\}$ 满足Lindeberg-Feller条件.

定理4.4.3 (Lindeberg-Feller中心极限定理) 设独立随机变量序列 $\{X_n, n \geq 1\}$ 满足Lindeberg-Feller条件, 则对任意的 $x \in \mathbb{R}$,

$$\lim_{n \rightarrow \infty} P\left(\frac{\sum_{i=1}^n (X_i - \mu_i)}{s_n} \leq x\right) = \Phi(x),$$

其中 Φ 为标准正态分布的分布函数.

Lindeberg-Feller中心极限定理的证明比较繁琐, 有兴趣的读者可以参阅Billingsley [10]. 尽管Lindeberg-Feller条件一般, 但验证起来比较困难. 下面的Lyapunov定理较Lindeberg-Feller定理更为常用, 因为相对来说其条件比较容易验证.

定理4.4.4 (Lyapunov定理) 设 $\{X_n, n \geq 1\}$ 是独立随机变量序列, 且 $EX_n = \mu_n$, $\text{Var}X_n = \sigma_n^2 < \infty$. 记 $s_n = \sqrt{\sum_{i=1}^n \sigma_i^2}$, 若存在 $\delta > 0$, 满足

$$\lim_{n \rightarrow \infty} \frac{1}{s_n^{2+\delta}} \sum_{i=1}^n E|X_i - \mu_i|^{2+\delta} = 0,$$

则对任意的 $x \in \mathbb{R}$,

$$\lim_{n \rightarrow \infty} P\left(\frac{\sum_{i=1}^n (X_i - \mu_i)}{s_n} \leq x\right) = \Phi(x),$$

其中 Φ 为标准正态分布的分布函数.

证明 Lyapunov定理的证明可以参阅Sen and Singer [17], 也可直接验证Lindeberg-Feller条件.

事实上,

$$\begin{aligned} \frac{1}{s_n^2} \sum_{i=1}^n E(X_i - \mu_i)^2 1_{\{|X_i - \mu_i| > \epsilon s_n\}} &= \sum_{i=1}^n E\left[\left|\frac{X_i - \mu_i}{s_n}\right|^2 \cdot 1_{\{|X_i - \mu_i| > \epsilon s_n\}}\right] \\ &\leq \sum_{i=1}^n E\left[\left|\frac{X_i - \mu_i}{s_n}\right|^2 \cdot \left|\frac{X_i - \mu_i}{\epsilon s_n}\right|^\delta \cdot 1_{\{|X_i - \mu_i| > \epsilon s_n\}}\right] \\ &\leq \frac{1}{\epsilon^\delta} \frac{1}{s_n^{2+\delta}} \sum_{i=1}^n E|X_i - \mu_i|^{2+\delta} \rightarrow 0, \end{aligned}$$

当 $n \rightarrow \infty$. □

注记4.4.4 实际使用Lyapunov定理时, 为了运算方便, 经常尝试 $\delta = 1$ 或 2 的情形.

推论4.4.1 (Bernoulli分布的中心极限定理) 设 $\{X_n, n \geq 1\}$ 是独立随机变量序列, 且对任意的 $n \geq 1$, $X_n \sim b(1, p_n)$, 记 $Y_n = \frac{\sum_{i=1}^n (X_i - p_i)}{\sqrt{\sum_{i=1}^n p_i(1 - p_i)}}$, 若 $\sum_{n=1}^\infty p_n(1 - p_n) = \infty$, 则对任意的 $x \in \mathbb{R}$,

$$\lim_{n \rightarrow \infty} P(Y_n \leq x) = \Phi(x),$$

其中 Φ 为标准正态分布的分布函数.

证明 注意到对任意的 $n \geq 1$, $X_n \sim b(1, p_n)$, 于是 $EX_n = p_n$, $\text{Var}X_n = p_n(1 - p_n)$, 且

$$E|X_n - EX_n|^3 = E|X_n - p_n|^3 = p_n(1 - p_n)(p_n^2 + (1 - p_n)^2) \leq p_n(1 - p_n).$$

对 $\delta = 1$ 验证Lyapunov定理的条件: 当 $n \rightarrow \infty$ 时,

$$\frac{\sum_{i=1}^n E|X_i - EX_i|^3}{[\sum_{i=1}^n p_i(1 - p_i)]^{3/2}} \leq \frac{1}{[\sum_{i=1}^n p_i(1 - p_i)]^{1/2}} \rightarrow 0.$$

即Lyapunov定理的条件成立, 故得证. □

例4.4.10 某份试卷由99个题目构成, 学生至少答对60个方能通过考试. 假设某考生答对第 i 题的概率为 $1 - \frac{i}{100}$, 且回答各题是相互独立的, 试利用中心极限定理估计该生通过考试的概率.

解 设 $p_i = 1 - \frac{i}{100}$, $X_i = 1$ 表示考生答对第 i 题, $X_i = 0$ 表示考生答错第 i 题, 则 $X_i \sim b(1, p_i)$, $i = 1, \dots, 99$. 由题目假设, 诸 X_i 相互独立. 容易计算得,

$$\sum_{i=1}^{99} p_i = 49.5, \quad \sum_{i=1}^{99} p_i(1 - p_i) = 16.665.$$

由中心极限定理知, 考生答对的题目数 $\sum_{i=1}^{99} X_i$ 渐近服从均值为 49.5 方差为 16.665 的正态分布. 故考生通过考试的概率为

$$P\left(\sum_{i=1}^{99} X_i \geq 60\right) = P\left(\frac{\sum_{i=1}^{99} X_i - 49.5}{\sqrt{16.665}} \geq \frac{60 - 49.5}{\sqrt{16.665}}\right) \simeq 0.005.$$

□

4.4.5 Delta 方法

中心极限定理告诉我们, 若随机变量序列 $X_1, \dots, X_n, \dots$ 满足某些条件, $S_n = \sum_{k=1}^n X_k$, 则当 $n \rightarrow \infty$ 时, S_n 渐近服从正态分布. 若 f 是一次函数, 由正态分布的线性不变性, S_n 的线性变换 $f(S_n)$ 也渐近服从正态分布. 我们的问题是, 如果 f 是其他类型的函数, $f(S_n)$ 的渐近分布是什么? 本节我们将介绍 Delta 方法来回答这个问题.

定理 4.4.5 (Delta 定理) 设 $\{Y_n, n \geq 1\}$ 为随机变量序列, F^* 为连续的分布函数, θ 为实数, 数列 $\{a_n, n \geq 1\}$ 满足 $0 < a_n \uparrow \infty$, 且使得

$$a_n(Y_n - \theta) \xrightarrow{d} F^*.$$

若 $\alpha(\theta)$ 是 θ 的函数, 且有连续的导函数 $\alpha'(\theta) \neq 0$, 则

$$\frac{a_n(\alpha(Y_n) - \alpha(\theta))}{\alpha'(\theta)} \xrightarrow{d} F^*.$$

即 $\frac{a_n(\alpha(Y_n) - \alpha(\theta))}{\alpha'(\theta)}$ 具有和 $a_n(Y_n - \theta)$ 相同的渐近分布 F^* .

在证明 Delta 定理之前, 我们来看看它的应用. Delta 定理常用的是下面的推论.

推论 4.4.2 设随机变量序列 $\{X_n, n \geq 1\}$ 独立同分布, 具有数学期望 μ 和方差 σ^2 , 记 $\bar{X}_n = \frac{1}{n} \sum_{k=1}^n X_k$. 设 $\alpha(\mu)$ 为 μ 的函数且有连续的导函数 $\alpha'(\mu) \neq 0$, 则

$$\frac{\sqrt{n}}{\sigma \cdot \alpha'(\mu)} (\alpha(\bar{X}_n) - \alpha(\mu)) \xrightarrow{d} N(0, 1).$$

证明 由中心极限定理,

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0, 1).$$

记 $Y_n = \bar{X}_n$, $a_n = \frac{\sqrt{n}}{\sigma}$, $\theta = \mu$, 由 Delta 定理,

$$\frac{\sqrt{n}}{\sigma \cdot \alpha'(\mu)} (\alpha(\bar{X}_n) - \alpha(\mu)) \xrightarrow{d} N(0, 1).$$

□

例4.4.11 在一个排队系统中, 假设每个顾客被服务的时间构成独立同分布的随机变量序列 $\{X_n, n \geq 1\}$, 且有期望 μ 和方差 σ^2 , 则服务效率 $\frac{1}{\bar{X}_n}$ 近似服从均值为 $\frac{1}{\mu}$, 方差为 $\frac{\sigma^2}{n\mu^4}$ 的正态分布.

证明 记 $\alpha(x) = \frac{1}{x}$, 则 $\alpha'(x) = -\frac{1}{x^2}$. 由推论4.4.2知,

$$-\frac{\sqrt{n}\mu^2}{\sigma} \left(\frac{1}{\bar{X}_n} - \frac{1}{\mu} \right) \xrightarrow{d} N(0, 1).$$

即 $\frac{1}{\bar{X}_n}$ 近似服从均值为 $\frac{1}{\mu}$, 方差为 $\frac{\sigma^2}{n\mu^4}$ 的正态分布. $\square$

下面我们来给出Delta定理的证明. 证明需要使用Baby Skorohod 定理(其证明读者可参阅 [18], Theorem 8.3.2).

定理4.4.6 (Baby Skorohod 定理) 设 $\{X_n, n \geq 0\}$ 是概率空间 $(\Omega, \mathcal{F}, P)$ 中的随机变量序列, 且 $X_n \xrightarrow{d} X_0$, 则在Lebesgue概率空间 $([0, 1], \mathcal{B}([0, 1]), m)$ (其中 m 为Lebesgue测度) 中存在随机变量序列 $\{X_n^*, n \geq 0\}$, 使得对每个 $n \geq 0$, X_n^* 与 X_n 同分布, 且 $X_n^* \rightarrow X_0^*$ 关于Lebesgue测度 m 几乎处处成立.

Delta定理的证明 由Baby Skorohod 定理, 在概率空间 $([0, 1], \mathcal{B}([0, 1]), m)$ 中存在随机变量序列 $\{Z_n^*, n \geq 0\}$, 使得对每个 $n \geq 1$, Z_n^* 与 $a_n(Y_n - \theta)$ 同分布, Z_0^* 具有分布 F^* , 且 $Z_n^* \xrightarrow{a.s.} Z_0^*$.

于是, $\frac{Z_n^*}{a_n} \xrightarrow{a.s.} 0$, 从而由已知,

$$\frac{a_n}{\alpha'(\theta)} \left(\alpha \left(\theta + \frac{Z_n^*}{a_n} \right) - \alpha(\theta) \right) = \frac{\alpha \left(\theta + \frac{Z_n^*}{a_n} \right) - \alpha(\theta)}{Z_n^*/a_n} \cdot \frac{Z_n^*}{\alpha'(\theta)} \xrightarrow{d} \alpha'(\theta) \cdot \frac{Z_0^*}{\alpha'(\theta)} = Z_0^*.$$

又因为 Y_n 与 $\theta + \frac{Z_n^*}{a_n}$ 同分布, 从而 $\frac{a_n(\alpha(Y_n) - \alpha(\theta))}{\alpha'(\theta)}$ 的渐近分布也为 F^* . $\square$