



Y3706039

分类号 _____

UDC _____

学 号 MX120170250

密 级 _____



硕 士 学 位 论 文

(全日制学术学位)

偏对称正态分布的理论及应用

学 院: 数学科学学院

专 业: 统计学

姓 名: 陈超

指 导 教 师: 宗序平 教授

答辩委员会主席: 刘金林 教授

答 辩 日 期: 2020 年 06 月 07 日



The Theory and Application of Skew Symmetric Normal Distribution

A thesis submitted to
Yangzhou University
in partial fulfillment of the requirements
for the degree of
Master of Science

By
Chao Chen
Supervisor: Prof. Xuping Zong
Co-supervisor: Prof. Xuping Zong
Statistics
June 2020

扬州大学学位论文原创性声明和版权使用授权书

学位论文原创性声明

本人声明：所呈交的学位论文是在导师指导下独立进行研究工作所取得的研究成果。除文中已经标明引用的内容外，本论文不包含其他个人或集体已经发表的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本声明的法律结果由本人承担。

作者签名：陈超

签字日期：2020年6月7日

学位论文版权使用授权书

本人完全了解学校有关保留、使用学位论文的规定，即：学校有权保留并向国家有关部门或机构送交学位论文的复印件和电子文档，允许论文被查阅和借阅。本人授权扬州大学可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。同时授权中国科学技术信息研究所将本学位论文收录到《中国学位论文全文数据库》，并通过网络向社会公众提供信息服务。

本学位论文属于（请在以下相应方框内打“√”）：

- 1、保密□，在____年解密后适用本授权书。
- 2、不保密☒。

作者签名：陈超

导师签名：

宗序平

签字日期：2020年6月7日

签字日期：2020年6月7日

目 录

摘 要.....	III
Abstract.....	V
第 1 章 绪论.....	1
1.1 课题研究背景.....	1
1.2 国内外研究现状.....	2
1.3 主要研究内容及创新.....	3
第 2 章 偏对称正态分布.....	5
2.1 偏对称正态分布定义及若干性质.....	5
2.2 若干偏对称正态分布.....	6
2.2.1 偏正态分布.....	6
2.2.2 偏 Logistic 正态分布.....	7
2.2.3 偏均匀正态分布.....	8
2.2.4 偏 t 正态分布.....	10
2.2.5 偏 Laplace 正态分布.....	11
2.2.6 偏 Triangular 正态分布.....	12
2.2.7 其它相关分布.....	13
2.3 基于 Gauss–Newton 迭代法的极大似然估计	14
2.3.1 一般的 Gauss–Newton 迭代法	14
2.3.2 改进的 Gauss–Newton 迭代法	16
2.3.3 蒙特卡罗数值模拟分析.....	17
第 3 章 偏正态多元线性回归.....	19
3.1 偏正态多元线性回归的参数估计.....	19
3.2 偏正态多元线性回归参数的假设检验.....	20
3.2.1 回归系数的显著性检验.....	20
3.2.2 尺度参数的齐次性检验.....	22
3.2.3 偏度参数的齐次性检验.....	23
3.3 蒙特卡罗数值模拟分析.....	24
3.4 实例分析.....	28

第 4 章 偏 Logistic 正态多元线性回归	31
4.1 偏 Logistic 正态多元线性回归的参数估计	31
4.2 偏 Logistic 正态多元线性回归参数的假设检验	33
4.2.1 回归系数的显著性检验	33
4.2.2 尺度参数的齐次性检验	35
4.2.3 偏度参数的齐次性检验	37
4.3 蒙特卡罗数值模拟分析	38
4.4 实例分析	41
第 5 章 总结与展望	43
参考文献	44
攻读学位期间取得的研究成果	46
致谢	47

摘要

在工程科学、生物医学、社会科学、气候科学、金融经济、以及社会生产等实践活动中产生的数据的分布未必具有严格的对称性，可能是偏态分布，这类数据如果使用正态分布等对称概率统计模型来拟合，就无法正确的描述数据的分布规律，而使用偏态分布来拟合可以更加准确地刻画这类数据的分布规律，因此对偏态分布的研究有着重要的意义。自 Azzalini 提出了偏正态分布以来，越来越多的学者开始研究偏态分布，相继提出了偏对称分布、偏正态 t 分布、 α -偏正态分布模型等，并研究了它们的性质，为进一步研究它们在偏态分布数据下的应用，提供了理论基础。基于这样的考虑，本文提出了一种新的偏态分布-偏对称正态分布，为偏态分布下的数据提供了新的拟合模型，并研究了它的相关性质及其在回归方面的应用，包括参数估计，回归系数的显著性检验，尺度参数和偏度参数的齐次性检验等，并进行了数值模拟研究和实例分析。主要研究内容包括以下四个方面：

1.提出了偏对称正态分布，并研究了它的相关性质，列举了若干偏对称正态分布，包括偏正态分布、偏 Logistic 正态分布、偏均匀正态分布、偏 t 正态分布、偏 Laplace 正态分布，偏三角正态分布等，讨论了它们的数字特征及若干性质，推导了利用一般的和改进的 Gauss-Newton 迭代法求解偏对称正态分布参数极大似然估计的过程及相关表达式，并通过蒙特卡罗数值模拟分析进行了验证。

2.介绍了改进的 Gauss-Newton 迭代法求解偏正态多元线性回归模型参数极大似然估计的方法，推导了相关信息矩阵的解析表达式。研究了似然比检验和 Score 检验在偏正态多元线性回归模型系数的显著性检验、偏度参数和尺度参数的齐次性检验方面的应用，推导了相关检验统计量的解析表达式，并通过蒙特卡罗数值模拟分析进行了说明。

3.给出了偏 Logistic 正态多元线性回归模型参数 ML 估计的求解方法，推导出了其对数似然函数的二阶偏导数矩阵的解析表达式。研究了似然比检验和 Score 检验在偏 Logistic 正态多元线性回归模型系数的显著性检验、偏度参数和尺度参数的齐次性检验方面的应用，推导了相关检验统计量的解析表达式，并通过蒙特卡罗数值模拟分析进行了验证。

4.分别利用正态、偏正态、偏 Logistic 正态多元线性回归模型拟合了关于波士顿房价的实例数据。介绍了模型参数极大似然估计的求解、回归系数的显著性检验、偏度参

数和尺度参数的齐次性检验的方法在实例数据上的应用。并利用赤池信息准则(AIC)和贝叶斯信息准则(BIC)评价了不同的回归模型在实例数据上的适用性。

关键词：偏对称正态分布；极大似然估计；显著性检验；齐次性检验

Abstract

The distribution of data generated in practical activities such as engineering sciences, biomedicine, social sciences, climate science, financial economics, and social production is not necessarily strictly symmetrical, it may be skew distribution. If this kind of data is fitted with a symmetrical probability statistical model like normal distribution, the distribution characteristics of data can not be described correctly. However, the distribution characteristics of these data can be described more accurately by skew distribution fitting. Therefore, the study of skew distribution is of great significance. Since Azzalini proposed the skew normal distribution, more and more scholars began to study the skew distribution, and successively proposed the skew-symmetric-distribution, skew-normal-t-distribution, α -skew-normal-distribution models, etc., and studied their properties, providing a theoretical basis for further study of their applications in different types of skewness distribution data. Based on this consideration, this paper defines a new kind of skewness distribution - skew symmetric normal distribution. This paper provides a new fitting model for the data under the skewed distribution, and studies its related properties and its application in regression, including parameter estimation, significance test of regression coefficient, homogeneity test of scale parameters and skewness parameters, etc. The main research contents include the following four aspects:

Firstly, the skew-symmetric-normal-distribution is proposed, and its related properties is studied. Some skew-symmetric-normal-distributions are enumerated, including a skew normal distribution, skew Logistic normal distribution and skew uniform normal distribution, skew t normal distribution, skew Laplace normal distribution, skew triangle normal distribution, etc. The numerical characteristics and some properties of them are discussed, and the process of solving the maximum likelihood estimation of skew symmetric normal distribution parameters by using the general and improved gauss-newton iterative method and the related expressions are derived, which are verified by Monte Carlo numerical simulation analysis.

Secondly, an improved gauss-newton iterative method for maximum likelihood estimation of the parameters of a skew normal multiple linear regression model is introduced. This paper studies the application of likelihood ratio test and Score test in the significance test of coefficient, the homogeneity test of skewness parameter and scale parameter of skew

normal multivariate linear regression model, deduces the analytical expression of correlation test statistic, and explains it by Monte Carlo numerical simulation.

Thirdly, the method of Maximum likelihood estimation for parameters of skew Logistic normal multiple linear regression model is given, and the analytical expression of the second skew derivative matrix of its log-likelihood function is derived. This paper studies the application of likelihood ratio test and Score test in the significance test of coefficient of skew Logistic normal multivariate linear regression model, the homogeneity test of skewness parameter and scale parameter, deduces the analytical expression of correlation test statistic, and verifies it by Monte Carlo numerical simulation analysis.

Fourthly, the case data of housing price in Boston are fitted with the multivariate linear regression models of normal, skew normal and skew Logistic normal. The paper introduces the method of solving maximum likelihood estimation of model parameters, significance test of regression coefficient, homogeneity test of skewness parameter and scale parameter on example data. The Akaike information criterion (AIC) and Bayesian information criterion (BIC) were used to evaluate the applicability of different regression models on instance data.

Key Words: Skew symmetric normal distribution; Maximum likelihood estimation; Significance test; Homogeneity test

第1章 绪论

1.1 课题研究背景

正态分布、Laplace 分布、t 分布等概率统计模型，已经广泛的应用于社会的各个领域，用于描述具有对称性分布特点的一类数据的分布规律，但是在工程科学、生物医学、社会科学、气候科学、金融经济、以及社会生产等实践活动中产生的数据的分布并不一定具有严格的对称性，而是带有一定程度的偏斜。此时，如果使用正态分布，Laplace 分布，Logistic 分布等对称概率统计模型来拟合这类数据，显然是不科学的。而利用非对称性的偏态分布来研究这类数据，可以更加准确地刻画它们的分布规律，因此对偏态分布概率统计模型的构建和研究是具有重要意义的。

Azzalini^[1]于 1985 年在正态分布模型的基础上进行推广，提出了偏正态分布概率统计模型，并研究了它的若干性质。随后越来越多的统计学者开始研究偏态分布模型。Arnold^[2]等提出了偏 Cauchy 分布，并讨论了其在多元情况下的边际分布、条件分布和参数估计；Gupta^[3]等提出了一类偏对称分布模型，包括偏均匀分布、偏 t 分布、偏 Laplace 分布等，并研究了它们的相关性质及数字特征；Nadarajah^[4]等在偏对称分布模型的基础上，提出了偏正态 t 分布，偏正态 Laplace 分布，偏正态 Cauchy 分布等，并推导出了它们的特征函数和 n 阶距的解析表达式；Fang^[5]等提出了一类偏 Elliptical 分布，并研究了它的基本性质及二次型；Wang^[6]等提出了多元偏 Slash 分布，并介绍了它的若干性质；Elal-Olivero^[7]等提出了 α -偏正态分布，并研究了它的数字特征、参数估计及信息矩阵的奇异性；Harandi^[8]等提出了 α -偏 Laplace 分布，研究了它的相关性质及参数估计，并利用实例数据进行了说明；Hazarika^[9]等提出了 α -偏 Logistic 分布，并介绍了利用对数似然、AIC、BIC 的值来评价模型适用性的方法。不同类型的偏态分布模型的提出和研究，为讨论不具有对称性分布特点的一类数据的分布规律，提供了理论支持。

在此基础上，本文提出了一类偏对称正态分布，进一步扩充了偏态分布概率统计模型，并研究了它的若干性质，以及其在多元线性回归上的应用，包括参数估计、回归系数的显著性检验、尺度参数和偏度参数的齐次性检验等内容，为偏态分布的研究提供了有效的思路。

1.2 国内外研究现状

国内外已经有许多的学者研究了偏态分布的性质及应用, 相关的成果也已经很多, 下面通过两个方面进行介绍。

在偏正态分布方面, Arellano-Valle^[10]等研究了偏正态线性混合模型, 介绍了使用 EM 类型的算法求解参数 ML 估计的过程, 并给出了模型在仿真研究和实际数据集上应用的结果; Monti^[11]等研究了偏正态分布的参数估计, 提出了一种最小卡方方法和渐进等价极大似然法来处理小样本偏正态模型的参数估计, 与一般的 ML 估计相比, 这个方法得出的结果更加令人满意; 谢锋昌^[12]等研究了偏正态非线性回归模型的齐次性检验的方法, 采用 Score 检验的方法对模型的尺度参数和偏度参数进行了齐次性检验, 运用蒙特卡罗数值模拟的方法研究了 Score 检验的有效性, 并利用实例数据说明了检验方法; Cancho^[13]等研究了偏正态误差下的非线性回归模型, 介绍了利用 EM 算法来求解 ML 估计的过程, 以及贝叶斯推断的方法, 并介绍了它们在实例数据集上的应用; Garay^[14]等研究了基于偏正态混合尺度分布的非线性回归模型, 提出了一种简单的 EM 类型的算法, 用来计算模型参数的 ML 估计, 并推导出了观测信息矩阵的解析表达式; Lachos^[15]等研究了基于偏正态混合尺度分布的异方差非线性回归模型, 介绍了利用 EM 类型的算法求解参数 ML 估计的过程, 并进行了模拟研究和实例分析; Labra^[16]等研究了基于偏正态混合尺度分布的异方差非线性回归模型的估计与诊断, 介绍了参数估计和局部影响的诊断方法; 万文^[17]等研究了偏正态分布下的联合位置和尺度模型统计诊断的方法, 通过数值模拟研究说明了该方法的有效性, 并进行了实例分析; Abdullah^[18]等介绍了利用遗传算法来求解偏正态分布参数 ML 估计的过程, 比较了使用遗传算法与使用其他迭代技术, 例如牛顿-拉夫森(NR)、尼尔德-米德(NM)和迭代重权算法(IRA)得到的模型参数 ML 估计的效果; 吴刘仓^[19]等研究了偏正态分布下的联合位置与尺度混合专家的回归模型, 利用 MM 算法计算了回归模型参数的 ML 估计, 通过模拟研究验证了回归模型和方法的有效性, 并进行了实例分析。

在其他偏态分布方面, 林金官^[20]等研究了偏 t 正态非线性回归的统计诊断, 考虑了病例删除模型(COM), 推导并讨论了几种诊断措施, 此外, 讨论了偏 t 正态非线性回归模型方差齐次性的 Score 检验, 并通过蒙特卡罗数值模拟方法研究了检验统计量的性质; Nadarajah^[21]等研究了偏 Logistic 分布, 推导出了一系列的数学性质, 包括分布函数、矩母函数、特征函数、Renyi 熵、Shannon 熵、次序统计量等, 并讨论了逻辑回归的应用; Azzalini^[22]等研究了偏 t 分布的最大惩罚似然估计; 吴刘仓^[23]等研究了缺失

偏 t 正态分布的数据下线性回归模型的统计推断, 提出一种适合缺失偏 t 正态分布数据下的线性回归模型的修正随机回归插补方法, 并通过与随机回归插补, 多重随机回归插补方法进行比较, 来说明该方法的有效性; Ferreira^[24]等研究了偏尺度混合正态分布的非线性回归模型, 介绍了使用 EM 类型的算法求解参数 ML 估计的过程, 并给出了模型在模拟研究和实际数据集上应用的效果; Kahrari^[25]等研究了尺度混合的偏正态 Cauchy 分布, 讨论了一种用于求解参数 ML 估计的 EM 类型的算法; 宗序平^[26]等研究了双参数离散偏拉普拉斯分布模型, 讨论了该模型的若干性质及参数估计的方法, 并通过实例分析说明了该模型能很好的拟合实例数据。

这些成果为研究偏态分布下的数据提供了有效的方法。在此基础上, 本文提出了一类新的概率统计模型: 偏对称正态分布, 并研究了它的一些性质, 及其在多元线性回归上的应用。

1.3 主要研究内容及创新

本文主要在偏正态分布的基础上进行扩展, 提出了偏对称正态分布, 列举了若干偏对称正态分布, 研究了它们的数字特征及若干性质, 讨论了偏对称正态分布参数 ML 估计的求解方法, 并介绍了偏对称正态分布在多元线性回归方面的应用。本文主要研究内容如下:

第一章主要介绍了课题研究背景、意义以及国内外的研究状况, 同时还介绍了本文的主要研究内容及创新。

第二章给出了偏对称正态分布的定义及相关性质, 列举了若干偏对称正态分布, 包括偏正态分布、偏 Logistic 正态分布、偏均匀正态分布、偏 t 正态分布、偏 Laplace 正态分布、偏三角正态分布等, 并讨论了它们的数字特征及相关性质, 此外, 还介绍了利用一般的和改进的高斯牛顿迭代法求解偏对称正态分布参数 ML 估计的过程, 并通过蒙特卡罗数值模拟研究进行了验证。

第三章研究了偏正态多元线性回归模型, 介绍了该模型参数 ML 估计的求解方法, 基于对数似然函数的表达式, 求解出了 Fisher 信息矩阵的解析表达式, 讨论了该模型系数的显著性检验、以及尺度参数和偏度参数齐次性检验的方法, 并进行了模拟研究和实例分析。

第四章研究了偏 Logistic 正态多元线性回归模型, 介绍了模型参数 ML 估计的求解、回归系数显著性检验、以及尺度参数和偏度参数齐次性检验的方法, 并通过蒙特卡

罗数值模拟研究进行了验证，介绍了这些方法在实例数据集上的应用，同时利用 AIC 和 BIC 评价了不同的回归模型拟合实例数据的优劣性。

第五章是本文的总结和展望。

创新之处：本文提出了一类新的偏态分布：偏对称正态分布，列举了若干偏对称正态分布，并推导出了它们的数字特征及相关性质，介绍了偏对称正态分布参数 ML 估计的求解过程；研究了偏正态和偏 Logistic 正态多元线性回归模型，介绍了该模型参数 ML 估计的求解方法，同时基于对数似然函数的表达式，求解出了 Fisher 信息矩阵的解析表达式，由此推导出了似然比检验和 Score 检验的统计量，用于检验这两个偏对称正态多元线性回归模型系数的显著性、以及尺度参数和偏度参数的齐次性。

第2章 偏对称正态分布

2.1 偏对称正态分布定义及若干性质

定义 2.1 设 $f(y)$ 为随机变量 Y 的概率密度函数, 且为偶函数, 其定义域为 $(-\infty, +\infty)$, $\Phi(\cdot)$ 是标准正态分布函数, 若随机变量 X 的概率密度函数为

$$g(x; \mu, \sigma, \lambda) = \frac{2}{\sigma} f\left(\frac{x-\mu}{\sigma}\right) \Phi\left(\lambda \frac{x-\mu}{\sigma}\right), \quad (2-1)$$

其中 λ 是偏度参数 (可取任意实数), μ 是位置参数, σ 是尺度参数, 则称随机变量 X 服从偏对称正态分布。特别地,

- (i) $\mu=0, \sigma=1$ 时, $g(x; \mu, \sigma, \lambda) = 2f(x)\Phi(\lambda x)$, 称 X 服从标准偏对称正态分布;
- (ii) $\mu=0, \sigma=1, \lambda \rightarrow +\infty$ 时, $g(x; \mu, \sigma, \lambda) = 2f(x)\Phi(\lambda x)$ 趋向于 $|Y|$ 的概率密度函数;
- (iii) $\mu=0, \sigma=1, \lambda \rightarrow -\infty$ 时, $g(x; \mu, \sigma, \lambda) = 2f(x)\Phi(\lambda x)$ 趋向于 $-|Y|$ 的概率密度函数;
- (iv) $\mu=0, \sigma=1, \lambda=0$ 时, $g(x; \mu, \sigma, \lambda) = f(x)$ 等于 Y 的概率密度函数。

性质 2.1 若随机变量 X, Y 的概率密度函数为定义 2.1 中的 $g(x; \mu, \sigma, \lambda), f(y)$, 则

- (i) X 的偶数阶距与 Y 的偶数阶距相等, 与 λ 的大小无关。
- (ii) X^2 和 Y^2 的分布函数是相同的。
- (iii) X 的概率密度函数在其定义域 $(-\infty, +\infty)$ 上的积分为 1。

证明: 令 $\varphi_X(t)$ 为 X 的特征函数, $\varphi_Y(t)$ 为 Y 的特征函数, 则

$$\begin{aligned} \varphi_X(-t) &= \int_{-\infty}^{+\infty} e^{-itx} \left[\frac{2}{\sigma} f\left(\frac{x-\mu}{\sigma}\right) \Phi\left(\lambda \frac{x-\mu}{\sigma}\right) \right] dx \\ &= \int_{-\infty}^{+\infty} e^{-itx} [2f(x)\Phi(\lambda x)] dx, \end{aligned}$$

令 $x = -z$, 得到

$$\begin{aligned} \varphi_X(-t) &= \int_{+\infty}^{-\infty} -e^{itz} [2f(-z)\Phi(-\lambda z)] dz \\ &= \int_{-\infty}^{+\infty} e^{itz} \{2f(x)[1 - \Phi(\lambda x)]\} dx \\ &= 2 \int_{-\infty}^{+\infty} e^{itx} f(x) dx - \int_{-\infty}^{+\infty} e^{itx} [2f(x)\Phi(\lambda x)] dx, \end{aligned}$$

所以

$$\varphi_X(-t) + \varphi_X(t) = 2\varphi_Y(t). \quad (2-2)$$

设 n 为任意的正整数, 等式(2-2)的两边对 t 求 $2n$ 阶导数, 可以得到

$$(-1)^{(2n)} \varphi_X^{(2n)}(-t) + \varphi_X^{(2n)}(t) = 2\varphi_Y^{(2n)}(t),$$

所以

$$\varphi_X^{(2n)}(0) = \varphi_Y^{(2n)}(0),$$

所以

$$E(X^{2n}) = (i)^{-2n} \varphi_X^{(2n)}(0) = (i)^{-2n} \varphi_Y^{(2n)}(0) = E(Y^{2n}), \quad (2-3)$$

由式(2-3)可以得到, X 的偶数阶距与 Y 的偶数阶距相等, 与 λ 的大小无关, 即结论 (i) 成立。

由结论 (i) 可知, X^2 与 Y^2 的 n 阶距相等, 所以 X^2 与 Y^2 的分布函数相同, 即结论 (ii) 成立。

令(2-2) 式中的 $t=0$, 得到

$$\varphi_X(0) + \varphi_X(0) = 2\varphi_Y(0),$$

所以

$$\int_{-\infty}^{+\infty} 2f(x)\Phi(\lambda x)dx = \varphi_X(0) = \varphi_Y(0) = 1,$$

即结论 (iii) 成立。

2.2 若干偏对称正态分布

2.2.1 偏正态分布

定义 2.2 设 $\phi(\cdot)$, $\Phi(\cdot)$ 分别为标准正态分布的概率密度函数与分布函数, 若随机变量 X 的概率密度函数为

$$g(x; \mu, \sigma, \lambda) = \frac{2}{\sigma} \phi\left(\frac{x-\mu}{\sigma}\right) \Phi\left(\lambda \frac{x-\mu}{\sigma}\right), \quad (2-4)$$

其中 λ 是偏度参数 (可取任意实数), μ 是位置参数, σ 是尺度参数, 则称随机变量 X 服从偏正态分布, 记作 $X \sim SN(\mu, \sigma^2, \lambda)$, 这与 Azzalini^[1]在 1985 年提出的偏正态分布是相同的。当 $\mu=0$, $\sigma=1$ 时, $g(x; \lambda) = 2\phi(x)\Phi(\lambda x)$, 称 X 服从标准偏正态分布, 图 2-1 是用 MATLAB 软件画出的 λ 在取不同值下的标准偏正态分布的概率密度函数图像。




图 2-1 标准偏正态分布的概率密度函数图

性质 2.2 若随机变量 $X \sim SN(X; 0, 1, \lambda)$, 则 $X^2 \sim \chi^2(1)$.

性质 2.3 ^[3]若随机变量 $X \sim SN(X; 0, 1, \lambda)$, $M(t)$ 为随机变量 X 的矩母函数, 则

$$M(t) = 2e^{\frac{1}{2}t^2} \Phi\left(\frac{\lambda t}{\sqrt{1+\lambda^2}}\right), \quad (2-5)$$

由式(2-5), 可以得到

$$E(X) = \sqrt{\frac{2}{\pi}} \frac{\lambda}{\sqrt{1+\lambda^2}}, \quad Var(X) = 1 - \frac{2}{\pi} \frac{\lambda^2}{1+\lambda^2},$$

进一步, 可以得到

$$\gamma_1 = \frac{1}{2}(4-\pi)\text{sign}(\lambda)\left[\frac{E^2(X)}{Var(X)}\right]^{\frac{3}{2}}, \quad \gamma_2 = 2(\pi-3)\left[\frac{E^2(X)}{Var(X)}\right]^2,$$

其中 γ_1, γ_2 分别为随机变量 X 的偏度系数与峰度系数。

2.2.2 偏 Logistic 正态分布

定义 2.3 设随机变量 Y 服从标准 Logistic 分布, 概率密度函数为

$$f(y) = \frac{e^{-y}}{(1+e^{-y})^2},$$

$\Phi(\cdot)$ 是标准正态分布的分布函数, 若随机变量 X 的概率密度函数为

$$g(x; \mu, \sigma, \lambda) = \frac{2}{\sigma} f\left(\frac{x-\mu}{\sigma}\right) \Phi\left(\lambda \frac{x-\mu}{\sigma}\right), \quad (2-6)$$

其中 λ 是偏度参数 (可取任意实数), μ 是位置参数, σ 是尺度参数, 则称 X 服从偏 Logistic 正态分布, 记 $X \sim SLN(\mu, \sigma^2, \lambda)$, 当 $\mu=0, \sigma=1$ 时, $g(x; \mu, \sigma, \lambda) = 2f(x)\Phi(\lambda x)$, 则称随机变量 X 服从标准偏 Logistic 正态分布。图 2-2 是用 MATLAB 软件画出的 λ 在取不同值下的标准偏 Logistic 正态分布的概率密度函数图像。




图 2-2 标准偏 Logistic 正态分布的概率密度函数图

性质 2.4 若随机变量 $X \sim SLN(0,1,\lambda)$, $T = X^2$, 且 T 的概率密度函数为 $f(t)$, 则

$$f(t) = \begin{cases} \frac{e^{-\sqrt{t}}}{\sqrt{t}(1+e^{-\sqrt{t}})^2}, & t > 0, \\ 0, & t \leq 0. \end{cases} \quad (2-7)$$

由式(2-7), 可以得到

$$E(T) = \frac{1}{3}\pi^2, \quad E(T^2) = \frac{7}{15}\pi^4.$$

2.2.3 偏均匀正态分布

定义 2.4 设随机变量 Y 服从标准均匀分布, 其概率密度函数为

$$f(y) = \frac{1}{2}I(-1 \leq y \leq 1),$$

$\Phi(\cdot)$ 是标准正态分布函数, 随机变量 X 的概率密度函数为

$$g(x; \mu, \sigma, \lambda) = \frac{2}{\sigma} f\left(\frac{x-\mu}{\sigma}\right) \Phi\left(\lambda \frac{x-\mu}{\sigma}\right) = \frac{1}{\sigma} \Phi\left(\lambda \frac{x-\mu}{\sigma}\right) I(-1 \leq \frac{x-\mu}{\sigma} \leq 1), \quad (2-8)$$

其中 λ 是偏度参数 (可取任意实数), μ 是位置参数, σ 是尺度参数, 则称 X 服从偏均匀正态分布, 记 $X \sim SUN(\mu, \sigma^2, \lambda)$, 当 $\mu = 0, \sigma = 1$ 时, $g(x; \mu, \sigma, \lambda) = \Phi(\lambda x)I(-1 \leq x \leq 1)$, 则称 X 服从标准偏均匀正态分布。图 2-3 是用 MATLAB 软件画出的 λ 在取不同值下的标准偏均匀正态分布的概率密度函数图像。




图 2-3 标准偏均匀正态分布的概率密度函数图

性质 2.5 若随机变量 $X \sim SUN(X; 0, 1, \lambda)$, $M(t)$ 为 X 的矩母函数, 则

$$M(t) = \frac{1}{t} e^t \Phi(\lambda) - \frac{1}{t} e^{-t} \Phi(-\lambda) - \frac{1}{t} e^{\frac{t^2}{2\lambda^2}} \Phi(\lambda - \frac{t}{\lambda}) + \frac{1}{t} e^{\frac{t^2}{2\lambda^2}} \Phi(-\lambda - \frac{t}{\lambda}).$$

证明:

$$\begin{aligned} M(t) &= \int_{-\infty}^{+\infty} e^{tx} g(x; \lambda) dx \\ &= \int_{-1}^1 e^{tx} \Phi(\lambda t) dx \\ &= \frac{1}{t} [e^{tx} \Phi(\lambda x) \Big|_{-1}^1 - \int_{-1}^1 e^{tx} \phi(\lambda t) d\lambda x] \\ &= \frac{1}{t} e^t \Phi(\lambda) - \frac{1}{t} e^{-t} \Phi(-\lambda) - \frac{1}{t} e^{\frac{t^2}{2\lambda^2}} \int_{-1}^1 \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(\lambda x - \frac{t}{\lambda})^2} d\lambda x, \end{aligned}$$

令 $z = \lambda x - \frac{t}{\lambda}$, 可以得到

$$M(t) = \frac{1}{t} e^t \Phi(\lambda) - \frac{1}{t} e^{-t} \Phi(-\lambda) - \frac{1}{t} e^{\frac{t^2}{2\lambda^2}} \int_{-\lambda - \frac{t}{\lambda}}^{\lambda - \frac{t}{\lambda}} \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}z^2} dz,$$

所以

$$M(t) = \frac{1}{t} e^t \Phi(\lambda) - \frac{1}{t} e^{-t} \Phi(-\lambda) - \frac{1}{t} e^{\frac{t^2}{2\lambda^2}} \Phi(\lambda - \frac{t}{\lambda}) + \frac{1}{t} e^{\frac{t^2}{2\lambda^2}} \Phi(-\lambda - \frac{t}{\lambda}), \quad (2-9)$$

由式(2-9), 可以求出

$$E(X) = -\frac{1}{2\lambda^2} \Phi(\lambda) + \frac{1}{2\lambda^2} \Phi(-\lambda) + \frac{1}{2} \Phi(\lambda) - \frac{1}{2} \Phi(-\lambda) + \frac{1}{\lambda\sqrt{2\pi}} e^{\frac{1}{2\lambda^2}},$$

$$Var(X) = \frac{1}{3} - E^2(X).$$

2.2.4 偏 t 正态分布

定义 2.5 设随机变量 Y 服从自由度为 n 的标准 t 分布, 其概率密度函数为

$$f(y; n) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi}\Gamma(\frac{n}{2})} (1 + \frac{y^2}{n})^{-\frac{n+1}{2}},$$

$\Phi(\cdot)$ 是标准正态分布函数, 随机变量 X 的概率密度函数为

$$g(x; \mu, \sigma, \lambda, n) = \frac{2}{\sigma} f\left(\frac{x-\mu}{\sigma}\right) \Phi\left(\lambda \frac{x-\mu}{\sigma}\right) = \frac{2\Gamma(\frac{n+1}{2})}{\sigma\sqrt{n\pi}\Gamma(\frac{n}{2})} \left[1 + \frac{(x-\mu)^2}{n\sigma^2}\right]^{-\frac{n+1}{2}} \Phi\left(\lambda \frac{x-\mu}{\sigma}\right), \quad (2-10)$$

其中 λ 是偏度参数 (可取任意实数), μ 是位置参数, σ 是尺度参数, 则称 X 服从偏 t 正态分布, 记作 $X \sim STN(\mu, \sigma^2, \lambda, n)$, 当 $\mu=0, \sigma=1$ 时, $g(x; \mu, \sigma, \lambda, n) = 2f(x; n)\Phi(\lambda x)$, 则称 X 服从标准偏 t 正态分布。图 2-4 是用 MATLAB 软件画出了自由度 $n=1$ 时, λ 取不同值的标准偏 t 正态分布的概率密度函数图像。




图 2-4 标准偏 t 正态分布的概率密度函数图 ($n=1$)

性质 2.6 ^[24] 若随机变量 $X \sim STN(0, 1, \lambda, n)$, $M(t)$ 是 X 的矩母函数, 则

$$M(t) = \int_0^{+\infty} 2e^{\frac{t^2}{2u}} \Phi\left(\frac{\lambda t}{\sqrt{u^2 + \lambda^2 u}}\right) dH(u), \quad (2-11)$$

其中 u 为积分变量, $H(\cdot)$ 为 $\Gamma(\frac{n}{2}, \frac{n}{2})$ 的概率分布函数。

由式(2-11), 可以求出

$$E(X) = \lambda \sqrt{\frac{n}{\pi}} \frac{\Gamma(\frac{n-1}{2})}{\Gamma(\frac{n}{2})} E_v[(v + \lambda^2)^{\frac{1}{2}}],$$

$$\text{Var}(X) = \frac{n}{n-2} - \frac{\lambda^2 n}{\pi} \left(\frac{\Gamma(\frac{n-1}{2})}{\Gamma(\frac{n}{2})} \right)^2 E_v^2[(v + \lambda^2)^{\frac{1}{2}}],$$

其中 $v \sim \Gamma\left(\frac{n-1}{2}, \frac{n}{2}\right)$.

2.2.5 偏 Laplace 正态分布

定义 2.6 设随机变量 Y 服从标准 Laplace 分布, 其概率密度函数为

$$f(y) = \frac{1}{2} e^{-|y|},$$

$\Phi(\cdot)$ 是标准正态分布函数, 随机变量 X 的概率密度函数为

$$g(x; \mu, \sigma, \lambda) = \frac{2}{\sigma} f\left(\frac{x-\mu}{\sigma}\right) \Phi\left(\lambda \frac{x-\mu}{\sigma}\right) = \frac{e^{-\frac{|x-\mu|}{\sigma}}}{\sigma} \Phi\left(\lambda \frac{x-\mu}{\sigma}\right), \quad (2-12)$$

其中 λ 是偏度参数 (可取任意实数), μ 是位置参数, σ 是尺度参数, 则称 X 服从偏 Laplace 正态分布。当 $\mu=0, \sigma=1$ 时, $g(x; \mu, \sigma, \lambda) = e^{-|x|} \Phi(\lambda x)$ 时, 称 X 服从标准偏 Laplace 正态分布。图 2-5 是用 MATLAB 软件画出的 λ 在取不同值下的标准偏 Laplace 正态分布的概率密度函数图像。




图 2-5 标准偏 Laplace 正态分布的概率密度函数图

性质 2.7 若随机变量 X 服从标准偏 Laplace 正态分布, 且偏度参数 $\lambda > 0$, $M(t)$ 是

X 的矩母函数, 则当 $-1 < t < 1$ 时,

$$M(t) = \frac{1}{1-t^2} - \frac{1}{1+t} e^{\frac{(t+1)^2}{2\lambda^2}} \Phi\left(-\frac{t+1}{\lambda}\right) - \frac{1}{t-1} e^{\frac{(t-1)^2}{2\lambda^2}} [1 - \Phi\left(-\frac{t-1}{\lambda}\right)].$$

证明:

$$\begin{aligned} M(t) &= \int_{-\infty}^{+\infty} e^{tx} [2f(x)\Phi(\lambda x)] dx \\ &= \int_{-\infty}^0 e^{(t+1)x} \Phi(\lambda x) dx + \int_0^{+\infty} e^{(t-1)x} \Phi(\lambda x) dx \\ &= \frac{1}{t+1} [e^{(t+1)x} \Phi(\lambda x)]_{-\infty}^0 - \int_{-\infty}^0 e^{(t+1)x} \varphi(\lambda x) d\lambda x + \frac{1}{t-1} [e^{(t-1)x} \Phi(\lambda x)]_0^{+\infty} - \int_0^{+\infty} e^{(t-1)x} \varphi(\lambda x) d\lambda x \\ &= \frac{1}{1-t^2} - \frac{1}{1+t} e^{\frac{(t+1)^2}{2\lambda^2}} \int_{-\infty}^0 \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(\lambda x - \frac{t+1}{\lambda})^2} d\lambda x - \frac{1}{t-1} e^{\frac{(t-1)^2}{2\lambda^2}} \int_0^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(\lambda x - \frac{t-1}{\lambda})^2} d\lambda x \\ &= \frac{1}{1-t^2} - \frac{1}{1+t} e^{\frac{(t+1)^2}{2\lambda^2}} \Phi\left(-\frac{t+1}{\lambda}\right) - \frac{1}{t-1} e^{\frac{(t-1)^2}{2\lambda^2}} [1 - \Phi\left(-\frac{t-1}{\lambda}\right)], \quad (-1 < t < 1). \end{aligned} \quad (2-13)$$

由式(2-13), 可以求出

$$E(X) = 2e^{\frac{1}{2\lambda^2}} \Phi\left(-\frac{1}{\lambda}\right) - \frac{2}{\lambda^2} e^{\frac{1}{2\lambda^2}} \Phi\left(-\frac{1}{\lambda}\right) + \frac{2}{\lambda} e^{\frac{1}{2\lambda^2}} \phi\left(\frac{1}{\lambda}\right),$$

$$Var(X) = 2 - E^2(X).$$

2.2.6 偏 Triangular 正态分布

定义 2.7 设随机变量 Y 服从 Triangular 分布, 其概率密度函数为

$$f(y) = \begin{cases} 0, & y < -1, \\ y+1, & -1 \leq y < 0, \\ -y+1, & 0 \leq y < 1, \\ 0, & y \geq 1. \end{cases}$$

$\Phi(\cdot)$ 是标准正态分布函数, 随机变量 X 的概率密度函数为

$$g(x; \mu, \sigma, \lambda) = \frac{2}{\sigma} f\left(\frac{x-\mu}{\sigma}\right) \Phi\left(\lambda \frac{x-\mu}{\sigma}\right), \quad (2-14)$$

其中 λ 是偏度参数 (可取任意实数), μ 是位置参数, σ 是尺度参数, 则称 X 服从偏 Triangular 正态分布。当 $\mu=0$, $\sigma=1$ 时, $g(x; \mu, \sigma, \lambda) = 2f(x)\Phi(\lambda x)$, 则称 X 服从标准偏 Triangular 正态分布。图 2-6 是用 MATLAB 软件画出的 λ 在取不同值下的标准偏 Triangular 正态分布的概率密度函数图像。




图 2-6 标准偏 Triangular 正态分布的概率密度函数图

性质 2.8 若随机变量 X 服从标准偏 Triangular 正态分布, 数学期望为 $E(X)$, 方差为 $Var(X)$, 则

$$E(X) = -\frac{1}{3} + \frac{1}{\lambda^2} + \frac{2}{3} \Phi(\lambda) - \frac{2}{\lambda^2} \Phi(\lambda) + \frac{8}{3\sqrt{2\pi}\lambda^3} + \frac{2}{3\sqrt{2\pi}\lambda} e^{-\frac{\lambda^2}{2}} - \frac{8}{3\sqrt{2\pi}\lambda^3} e^{-\frac{\lambda^2}{2}},$$

$$Var(X) = \frac{1}{6} - E^2(X).$$

2.2.7 其它相关分布

定义 2.8 设随机变量 Y 服从标准 Cauchy 分布, 其概率密度函数为

$$f(y) = \frac{1}{\pi} \frac{1}{1+y^2},$$

$\Phi(\cdot)$ 是标准正态分布函数, 随机变量 X 的概率密度函数为

$$g(x; \mu, \sigma, \lambda) = \frac{2}{\pi\sigma} \frac{1}{1 + \left(\frac{x-\mu}{\sigma}\right)^2} \Phi\left(\lambda \frac{x-\mu}{\sigma}\right), \quad (2-15)$$

其中 λ 是偏度参数 (可取任意实数), μ 是位置参数, σ 是尺度参数, 则称 X 服从偏 Cauchy 正态分布。当 $\mu=0, \sigma=1$ 时, $g(x; \mu, \sigma, \lambda) = 2f(x)\Phi(\lambda x)$, 则称 X 服从标准偏 Cauchy 正态分布。

定义 2.9 设随机变量 Y 服从 Slash 分布, 其概率密度函数为

$$f(y) = \begin{cases} \frac{\phi(0) - \phi(y)}{y^2}, & y \neq 0, \\ \frac{1}{2\sqrt{2\pi}}, & y = 0, \end{cases}$$

$\phi(\cdot)$ 与 $\Phi(\cdot)$ 是标准正态分布的概率密度函数与分布函数, 随机变量 X 的概率密度函数为

$$g(x; \mu, \sigma, \lambda) = \frac{2}{\sigma} f\left(\frac{x-\mu}{\sigma}\right) \Phi\left(\lambda \frac{x-\mu}{\sigma}\right), \quad (2-16)$$

其中 λ 是偏度参数(可取任意实数), μ 是位置参数, σ 是尺度参数, 则称 X 服从偏 Slash 正态分布。当 $\mu=0, \sigma=1$ 时, $g(x; \mu, \sigma, \lambda) = 2f(x)\Phi(\lambda x)$, 则称 X 服从标准偏 Slash 正态分布。

2.3 基于 Gauss-Newton 迭代法的极大似然估计

2.3.1 一般的 Gauss-Newton 迭代法

设随机变量 $X = (X_1, X_2, \dots, X_n)^T$, $\theta = (\mu, \sigma^2, \lambda)^T$, 其中 $X_1, X_2, \dots, X_n$ 独立同分布, X_1 服从偏对称正态分布, 其概率密度函数为

$$g(x_1; \mu, \sigma, \lambda) = \frac{2}{\sigma} f\left(\frac{x_1-\mu}{\sigma}\right) \Phi\left(\lambda \frac{x_1-\mu}{\sigma}\right), \quad (2-17)$$

其中 $f(\cdot)$ 为概率密度函数且为偶函数, 其定义域为 $(-\infty, +\infty)$ 。

由式(2-17)可知, 似然函数

$$l(\theta) = \prod_{i=1}^n \frac{2}{\sigma} f\left(\frac{x_i-\mu}{\sigma}\right) \Phi\left(\lambda \frac{x_i-\mu}{\sigma}\right),$$

所以对数似然函数

$$L(\theta) = n \log 2 - \frac{n}{2} \log \sigma^2 + \sum_{i=1}^n \log f\left(\frac{x_i-\mu}{\sigma}\right) + \sum_{i=1}^n \log \Phi\left(\lambda \frac{x_i-\mu}{\sigma}\right),$$

所以

$$\frac{\partial L(\theta)}{\partial \mu} = -\sum_{i=1}^n \frac{f'\left(\frac{x_i-\mu}{\sigma}\right)}{\sigma f\left(\frac{x_i-\mu}{\sigma}\right)} - \sum_{i=1}^n \frac{\lambda \phi(b_i)}{\sigma \Phi(b_i)},$$

$$\frac{\partial L(\theta)}{\partial \sigma^2} = -\frac{n}{2\sigma^2} - \sum_{i=1}^n \frac{(x_i-\mu) f'\left(\frac{x_i-\mu}{\sigma}\right)}{2\sigma^3 f\left(\frac{x_i-\mu}{\sigma}\right)} - \sum_{i=1}^n \frac{\lambda (x_i-\mu) \phi(b_i)}{2\sigma^3 \Phi(b_i)},$$

$$\frac{\partial L(\theta)}{\partial \lambda} = \sum_{i=1}^n \frac{(x_i-\mu) \phi(b_i)}{\sigma \Phi(b_i)},$$

$$\frac{\partial^2 L(\theta)}{\partial \mu^2} = \sum_{i=1}^n \left(\frac{f'(\frac{x_i - \mu}{\sigma}) f(\frac{x_i - \mu}{\sigma}) - (f'(\frac{x_i - \mu}{\sigma}))^2}{\sigma^2 f^2(\frac{x_i - \mu}{\sigma})} + \frac{\lambda^2 (\phi'(b_i) \Phi(b_i) - \phi^2(b_i))}{\sigma^2 \Phi^2(b_i)} \right),$$

$$\begin{aligned} \frac{\partial^2 L(\theta)}{\partial \mu \partial \sigma^2} &= \sum_{i=1}^n \left(\frac{f'(\frac{x_i - \mu}{\sigma})}{2\sigma^3 f(\frac{x_i - \mu}{\sigma})} + \frac{(x_i - \mu) [f'(\frac{x_i - \mu}{\sigma}) f(\frac{x_i - \mu}{\sigma}) - (f'(\frac{x_i - \mu}{\sigma}))^2]}{2\sigma^4 f^2(\frac{x_i - \mu}{\sigma})} + \frac{\lambda \phi(b_i)}{2\sigma^3 \Phi(b_i)} \right) \\ &\quad + \sum_{i=1}^n \frac{\lambda^2 (x_i - \mu) [\phi'(b_i) \Phi(b_i) - \phi^2(b_i)]}{2\sigma^4 \Phi^2(b_i)}, \end{aligned}$$

$$\frac{\partial^2 L(\theta)}{\partial \mu \partial \lambda} = - \sum_{i=1}^n \frac{\phi(b_i)}{\sigma \Phi(b_i)} - \sum_{i=1}^n \frac{\lambda (x_i - \mu) [\phi'(b_i) \Phi(b_i) - \phi^2(b_i)]}{\sigma^2 \Phi^2(b_i)},$$

$$\begin{aligned} \frac{\partial^2 L(\theta)}{\partial (\sigma^2)^2} &= \frac{n}{2\sigma^4} + \sum_{i=1}^n \frac{3(x_i - \mu) f'(\frac{x_i - \mu}{\sigma})}{4\sigma^5 f(\frac{x_i - \mu}{\sigma})} + \sum_{i=1}^n \frac{\lambda^2 (x_i - \mu)^2 [\phi'(b_i) \Phi(b_i) - \phi^2(b_i)]}{4\sigma^6 \Phi^2(b_i)} \\ &\quad + \sum_{i=1}^n \frac{3\lambda (x_i - \mu) \phi(b_i)}{4\sigma^5 \Phi(b_i)} + \sum_{i=1}^n \frac{(x_i - \mu)^2 [f'(\frac{x_i - \mu}{\sigma}) f(\frac{x_i - \mu}{\sigma}) - (f'(\frac{x_i - \mu}{\sigma}))^2]}{4\sigma^6 f^2(\frac{x_i - \mu}{\sigma})}, \end{aligned}$$

$$\frac{\partial^2 L(\theta)}{\partial \sigma^2 \partial \lambda} = - \sum_{i=1}^n \frac{(x_i - \mu) \phi(b_i)}{2\sigma^3 \Phi(b_i)} - \sum_{i=1}^n \frac{\lambda (x_i - \mu)^2 [\phi'(b_i) \Phi(b_i) - \phi^2(b_i)]}{2\sigma^4 \Phi^2(b_i)},$$

$$\frac{\partial^2 L(\theta)}{\partial \lambda^2} = \sum_{i=1}^n \frac{(x_i - \mu)^2 [\phi'(b_i) \Phi(b_i) - \phi^2(b_i)]}{\sigma^2 \Phi^2(b_i)},$$

其中 $b_i = \lambda \frac{y_i - \mu}{\sigma}$, $i = 1, 2, \dots, n$.

由上述结果得到 $\dot{L}(\theta)$, $\ddot{L}(\theta)$ 的解析表达式

$$\dot{L}(\theta) = \left(\frac{\partial L(\theta)}{\partial \mu}, \frac{\partial L(\theta)}{\partial \sigma^2}, \frac{\partial L(\theta)}{\partial \lambda} \right)^T,$$

$$\ddot{L}(\theta) = \begin{pmatrix} \frac{\partial^2 L}{\partial \mu^2} & \frac{\partial^2 L}{\partial \mu \partial \sigma^2} & \frac{\partial^2 L}{\partial \mu \partial \lambda} \\ \frac{\partial^2 L}{\partial \mu \partial \sigma^2} & \frac{\partial^2 L}{\partial (\sigma^2)^2} & \frac{\partial^2 L}{\partial \sigma^2 \partial \lambda} \\ \frac{\partial^2 L}{\partial \mu \partial \lambda} & \frac{\partial^2 L}{\partial \sigma^2 \partial \lambda} & \frac{\partial^2 L}{\partial \lambda^2} \end{pmatrix}.$$

若 θ 的极大似然估计为 $\hat{\theta} = \hat{\theta}(X)$, 则 $\dot{L}(\hat{\theta}) = 0$, 将其在某点 $\theta^{(0)}$ 处展开可得

$$\dot{L}(\hat{\theta}) = \dot{L}(\theta^{(0)}) + \ddot{L}(\theta^{(0)})(\hat{\theta} - \theta^{(0)}) + o(\|\hat{\theta} - \theta^{(0)}\|) = 0,$$

$$\hat{\theta} = \theta^{(0)} + [-\ddot{L}(\theta^{(0)})]^{-1}[\dot{L}(\theta^{(0)})] + \text{余项}.$$

若 $\theta^{(0)}$ 为初值, 则迭代过程如下

$$\theta^{(1)} = \theta^{(0)} + [-\ddot{L}(\theta^{(0)})]^{-1}[\dot{L}(\theta^{(0)})],$$

$$\theta^{(2)} = \theta^{(1)} + [-\ddot{L}(\theta^{(1)})]^{-1}[\dot{L}(\theta^{(1)})],$$

.....

$$\theta^{(i+1)} = \theta^{(i)} + [-\ddot{L}(\theta^{(i)})]^{-1}[\dot{L}(\theta^{(i)})],$$

当 $\|\theta^{(i+1)} - \theta^{(i)}\|^2 \leq \delta$ 时, 迭代结束, 其中 δ 可取充分小的正数, 例如 $\delta = 10^{-8}$, 此时选择 $\theta^{(i+1)}$ 作为极大似然估计 $\hat{\theta}$ 的近似值。

2.3.2 改进的 Gauss-Newton 迭代法

迭代法的收敛速度对于数值计算是很重要, 而想要加快迭代法的收敛速度, 即增加 $L(\theta)$ 逼近最大值 $L(\hat{\theta})$ 的速度。直观上, 应当要求 $L(\theta^{(i)})$ 关于 i 单调递增, 直到逼近 $L(\hat{\theta})$ 为止。显然, 一般的 Gauss-Newton 迭代法不一定满足这样的要求, 而在改进的牛顿迭代法中, 取适当的 $\eta^{(i)}$, 带入到 $\theta^{(i+1)} = \theta^{(i)} + \eta^{(i)}[-\ddot{L}(\theta^{(i)})]^{-1}[\dot{L}(\theta^{(i)})]$, 可以使得 $L(\theta^{(i+1)}) \geq L(\theta^{(i)})$ 成立, 这样就保证 $L(\theta^{(i)})$ 关于 i 单调递增, 下面定理证明了这样的 $\eta^{(i)}$ 是存在的。

定理 2.1^[27] 若 $-\ddot{L}(\theta^{(i)}) > 0$, $\dot{L}(\theta^{(i)}) \neq 0$, 则必定存在 $\eta^{(i)} > 0$, 使得

$$\theta^{(i+1)} = \theta^{(i)} + \eta^{(i)}[-\ddot{L}(\theta^{(i)})]^{-1}[\dot{L}(\theta^{(i)})] \text{ 时, } L(\theta^{(i+1)}) > L(\theta^{(i)}).$$

证明: 令 $p(\eta^{(i)}) = L(\theta^{(i+1)}) = L(\theta^{(i)} + \eta^{(i)}[-\ddot{L}(\theta^{(i)})]^{-1}[\dot{L}(\theta^{(i)})])$, 则根据微分公式可以得到

$$L(\theta^{(i+1)}) - L(\theta^{(i)}) = p(\eta^{(i)}) - p(0) = \dot{p}(0)\eta^{(i)} + \alpha\eta^{(i)} = [\dot{p}(0) + \alpha]\eta^{(i)},$$

且当 $\eta^{(i)} \rightarrow 0$ 时, $\alpha \rightarrow 0$. 向量的第 m 个分量用其下标表示, 则 $\dot{p}(0)$ 可表示为

$$\dot{p}(0) = \sum_{m=1}^3 \left[\frac{\partial L(\theta^{(i)})}{\partial (\theta^{(i)})_m} \frac{d(\theta^{(i)} + \eta^{(i)}[-\ddot{L}(\theta^{(i)})]^{-1}[\dot{L}(\theta^{(i)})])_m}{d\eta^{(i)}} \right]_{\eta^{(i)}=0} = [L(\theta^{(i)})]^T [-\ddot{L}(\theta^{(i)})]^{-1} [\dot{L}(\theta^{(i)})] > 0,$$

所以当 $\eta^{(i)}$ 为充分小正数时, 有 $\dot{p}(0) + \alpha > 0$, 此时,

$$L(\theta^{(i+1)}) - L(\theta^{(i)}) = [\dot{p}(0) + \alpha]\eta^{(i)} > 0, \quad \text{证毕}.$$

由上述定理得到改进后的 Gauss-Newton 迭代过程如下, 取初值为 $\theta^{(0)}$, 存在 $\eta^{(0)}$, 使得

$$L(\theta^{(1)}) = L(\theta^{(0)} + \eta^{(0)}[-\ddot{L}(\theta^{(0)})]^{-1}[\dot{L}(\theta^{(0)})]) = \max_{0 < \eta \leq 1} L(\theta^{(0)} + \eta[-\ddot{L}(\theta^{(0)})]^{-1}[\dot{L}(\theta^{(0)})]) > L(\theta^{(0)}),$$

取

$$\theta^{(1)} = \theta^{(0)} + \eta^{(0)}[-\ddot{L}(\theta^{(0)})]^{-1}[\dot{L}(\theta^{(0)})],$$

存在 $\eta^{(1)}$, 使得

$$L(\theta^{(2)}) = L(\theta^{(1)} + \eta^{(1)}[-\ddot{L}(\theta^{(1)})]^{-1}[\dot{L}(\theta^{(1)})]) = \max_{0 < \eta \leq 1} L(\theta^{(1)} + \eta[-\ddot{L}(\theta^{(1)})]^{-1}[\dot{L}(\theta^{(1)})]) > L(\theta^{(1)}),$$

取

$$\theta^{(2)} = \theta^{(1)} + \eta^{(1)}[-\ddot{L}(\theta^{(1)})]^{-1}[\dot{L}(\theta^{(1)})],$$

.....

如此进行, 则必满足

$$L(\theta^{(0)}) < L(\theta^{(1)}) < L(\theta^{(2)}) < \cdots < L(\theta^{(i)}) < L(\theta^{(i+1)}) < \cdots,$$

当 $\|\theta^{(i+1)} - \theta^{(i)}\|^2 \leq \delta$ 时, 迭代结束, 其中 δ 可取充分小的正数, 例如 $\delta=10^{-8}$, 此时选择 $\theta^{(i+1)}$ 作为极大似然估计 $\hat{\theta}$ 的近似值。

2.3.3 蒙特卡罗数值模拟分析

本节利用蒙特卡罗数值模拟方法生成的服从偏对称正态分布的数据, 来进行研究。

不妨取 2.2.1 节中的 $f(\cdot)$ 为 $\phi(\cdot)$, 且 $(\mu, \sigma^2, \lambda)^T$ 的值为 $(1, 1, -1)^T$ 来进行模拟分析, 此时 $X_1 \sim SN(1, 1, -1)$. 使用 MATLAB 软件产生基于偏正态分布 $SN(1, 1, -1)$ 的模拟数据, 样本量 n 分别取 300, 600, 900; 最后运用 2.3.2 节中改进的 Gauss-Newton 法计算得到 $(\mu, \sigma^2, \lambda)^T$ 的极大似然估计, 并与真值进行比较, 模拟 1000 次。参数估计的准确性使用标准差 (STD)、均方误差 (MSE) 和平均绝对误差 (MAE) 来衡量。

$$STD = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{\alpha}_i - \bar{\hat{\alpha}})^2},$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (\alpha_i - \hat{\alpha}_i)^2,$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |\alpha_i - \hat{\alpha}_i|,$$

其中 α_i 和 $\hat{\alpha}_i$ 分别为第 i 次数值模拟中参数的真实值和估计值, $\bar{\hat{\alpha}}$ 为 n 次模拟的参数估计

值的平均数。当标准差 (*STD*)、均方误差 (*MSE*) 和平均绝对误差 (*MAE*) 越接近 0 时，所得的参数估计的大小越准确。相应结果如下：

表 2-1 样本容量 $n = 300$ 时，参数的极大似然估计的结果

参数	实际值	估计值	<i>STD</i>	<i>MSE</i>	<i>MAE</i>
μ	1	0.8635	0.3737	0.1583	0.2664
σ^2	1	0.9736	0.2405	0.0579	0.1969
λ	-1	-0.8206	0.7335	0.5702	0.5491

表 2-2 样本容量 $n = 600$ 时，参数的极大似然估计的结果

参数	实际值	估计值	<i>STD</i>	<i>MSE</i>	<i>MAE</i>
μ	1	0.9090	0.2893	0.0920	0.1835
σ^2	1	0.9858	0.1748	0.0307	0.1422
λ	-1	-0.8693	0.5517	0.3214	0.3781

表 2-3 样本容量 $n = 900$ 时，参数的极大似然估计的结果

参数	实际值	估计值	<i>STD</i>	<i>MSE</i>	<i>MAE</i>
μ	1	0.9456	0.1891	0.0387	0.1257
σ^2	1	0.9968	0.1525	0.0240	0.1230
λ	-1	-0.9228	0.3734	0.1454	0.2669

从上述表格中的结果可以得到，随着样本量不断地增加，位置参数 μ 、尺度参数 σ 、偏度参数 λ 的极大似然估计值的大小越来越接近真实值，标准差、均方误差和平均绝对误差在不断地减小，参数估计值越来越准确。综上所述，随着样本量的增加，利用改进的高斯牛顿迭代法得到的极大似然估计与真实值也越来越接近，准确性越来越高。

第3章 偏正态多元线性回归

3.1 偏正态多元线性回归的参数估计

设变量 $x = (x_1, \dots, x_n)^T$, $y = (y_1, \dots, y_n)^T$, 偏正态多元线性回归模型

$$y_i = x_i^T \beta + \varepsilon_i, \quad i=1, 2, \dots, n,$$

其中自变量和因变量分别为 $x_i = (x_{i1}, \dots, x_{iq})^T$ 和 y_i , 回归系数为 $\beta = (\beta_1, \dots, \beta_q)^T$, 随机误差项 $\varepsilon_i \sim SN(0, \sigma^2, \lambda)$.

由性质 2.3, 可以得到

$$E(y_i) = x_i^T \beta + \sqrt{\frac{2}{\pi}} \frac{\lambda}{\sqrt{1+\lambda^2}}, \quad \text{Var}(y_i) = (1 - \frac{2}{\pi} \frac{\lambda^2}{1+\lambda^2}) \sigma^2,$$

令 $\theta = (\beta^T, \sigma^2, \lambda)^T$, 则对数似然函数

$$L(\theta) = n \log 2 - \frac{n}{2} \log 2\pi - \frac{n}{2} \log \sigma^2 - \sum_{i=1}^n \frac{(y_i - x_i^T \beta)^2}{2\sigma^2} + \sum_{i=1}^n \log \Phi(\lambda \frac{y_i - x_i^T \beta}{\sigma}), \quad (3-1)$$

由式(3-1), 可以求出

$$\begin{aligned} \dot{L}(\theta) &= \left(\frac{\partial L(\theta)}{\partial \beta^T}, \frac{\partial L(\theta)}{\partial \sigma^2}, \frac{\partial L(\theta)}{\partial \lambda} \right)^T \\ &= \sum_{i=1}^n \left(\frac{y_i x_i^T - x_i^T \beta x_i^T}{\sigma^2} - \frac{\lambda \phi(b_i) x_i^T}{\sigma \Phi(b_i)}, \frac{(y_i - x_i^T \beta)^2}{2\sigma^4} - \frac{\lambda (y_i - x_i^T \beta)}{2\sigma^3} \frac{\phi(b_i)}{\Phi(b_i)} - \frac{1}{2\sigma^2}, \frac{y_i - x_i^T \beta}{\sigma} \frac{\phi(b_i)}{\Phi(b_i)} \right)^T, \end{aligned}$$

以及关于 θ 的 Fisher 信息矩阵

$$I(\theta) = \sum_{i=1}^n \begin{pmatrix} \frac{1+a_0 \lambda^2}{\sigma^2} x_i x_i^T & \sqrt{\frac{1}{2\pi}} \frac{\lambda x_i}{\sigma^3} \left(\frac{1+2\lambda^2}{(1+\lambda^2)^{\frac{3}{2}}} + \sqrt{\frac{\pi}{2}} a_1 \right) & \sqrt{\frac{2}{\pi}} \frac{x_i}{\sigma} \left(\frac{1}{(1+\lambda^2)^{\frac{3}{2}}} - \sqrt{\frac{\pi}{2}} a_1 \right) \\ \sqrt{\frac{1}{2\pi}} \frac{\lambda x_i^T}{\sigma^3} \left(\frac{1+2\lambda^2}{(1+\lambda^2)^{\frac{3}{2}}} + \sqrt{\frac{\pi}{2}} a_1 \right) & \frac{2+a_2}{4\sigma^4} & -\frac{a_2}{2\sigma^2 \lambda} \\ \sqrt{\frac{2}{\pi}} \frac{x_i^T}{\sigma} \left(\frac{1}{(1+\lambda^2)^{\frac{3}{2}}} - \sqrt{\frac{\pi}{2}} a_1 \right) & -\frac{a_2}{2\sigma^2 \lambda} & \frac{a_2}{\lambda^2} \end{pmatrix},$$

其中 $a_j = E\left(\frac{\phi^2(b_i)}{\Phi^2(b_i)} b_i^j\right)$, $j=0, 1, 2$; $b_i = \lambda \frac{y_i - x_i^T \beta}{\sigma}$, $i=1, 2, \dots, n$.

取初值为 $\theta^{(0)}$, 由 2.3.2 节改进的 Gauss-Newton 迭代法, 可以得到迭代过程如下, 存在 $\eta^{(0)}$, 使得

$$L(\theta^{(1)}) = L(\theta^{(0)} + \eta^{(0)}[-\ddot{L}(\theta^{(0)})]^{-1}[\dot{L}(\theta^{(0)})]) = \max_{0 < \eta \leq 1} L(\theta^{(0)} + \eta[-\ddot{L}(\theta^{(0)})]^{-1}[\dot{L}(\theta^{(0)})]) > L(\theta^{(0)}),$$

取

$$\theta^{(1)} = \theta^{(0)} + \eta^{(0)}[-\ddot{L}(\theta^{(0)})]^{-1}[\dot{L}(\theta^{(0)})],$$

存在 $\eta^{(1)}$, 使得

$$L(\theta^{(2)}) = L(\theta^{(1)} + \eta^{(1)}[-\ddot{L}(\theta^{(1)})]^{-1}[\dot{L}(\theta^{(1)})]) = \max_{0 < \eta \leq 1} L(\theta^{(1)} + \eta[-\ddot{L}(\theta^{(1)})]^{-1}[\dot{L}(\theta^{(1)})]) > L(\theta^{(1)}),$$

取

$$\theta^{(2)} = \theta^{(1)} + \eta^{(1)}[-\ddot{L}(\theta^{(1)})]^{-1}[\dot{L}(\theta^{(1)})],$$

.....

如此进行, 则必满足

$$L(\theta^{(0)}) < L(\theta^{(1)}) < L(\theta^{(2)}) < \dots < L(\theta^{(i)}) < L(\theta^{(i+1)}) < \dots,$$

当 $\|\theta^{(i+1)} - \theta^{(i)}\|^2 \leq \delta$ 时, 迭代结束, 其中 δ 可取充分小的正数, 例如 $\delta = 10^{-8}$, 此时选择 $\theta^{(i+1)}$ 作为极大似然估计 $\hat{\theta}$ 的近似值。迭代过程中, 正定矩阵 $[-\ddot{L}(\theta)]$ 用 Fisher 信息矩阵 $I(\theta)$ 代替。

3.2 偏正态多元线性回归参数的假设检验

3.2.1 回归系数的显著性检验

设变量 $x = (x_1, \dots, x_n)^T$, $y = (y_1, \dots, y_n)^T$, 偏正态多元线性回归模型

$$y_i = x_i^T \beta + \varepsilon_i, \quad i = 1, 2, \dots, n,$$

其中自变量和因变量分别为 $x_i = (x_{i1}, \dots, x_{iq})^T$ 和 y_i , 随机误差项 $\varepsilon_i \sim SN(0, \sigma^2, \lambda)$, 回归系数为 $\beta = (\beta_1, \dots, \beta_q)^T$, 其第 j 个分量的显著性检验为

$$H_0: \beta_j = 0 \quad \text{vs} \quad H_1: \beta_j \neq 0,$$

其中 j 可取 $1, 2, \dots, q$. 不妨以 $j=1$ 为例进行说明, 其他情况相同。令 $v = (\beta_2, \beta_3, \dots, \beta_q)^T$, $\xi = (\beta_1, v^T, \sigma^2, \lambda)^T$, $\xi^{(1)} = (v^T, \sigma^2, \lambda)^T$, 由式(3-1), 可知

$$L(\xi) = n \log 2 - \frac{n}{2} \log 2\pi - \frac{n}{2} \log \sigma^2 - \sum_{i=1}^n \frac{(y_i - x_i^T \beta)^2}{2\sigma^2} + \sum_{i=1}^n \log \Phi\left(\lambda \frac{y_i - x_i^T \beta}{\sigma}\right). \quad (3-2)$$

设 $\hat{\xi} = (\hat{\beta}_1, \hat{\xi}^{(1)T})^T$ 为 ξ 极大似然估计; $\hat{\xi}_0 = (0, \hat{\xi}_0^{(1)T})^T$, 其中 $\hat{\xi}_0^{(1)}$ 为 $\beta_1 = 0$ 时, $\xi^{(1)}$ 的极大似然估计, 由子集参数似然比检验的性质^[27], 可以得到似然比检验统计量

$$LR_1 = 2\{L(\hat{\xi}) - L(\hat{\xi}_0)\} \xrightarrow{L} \chi^2(1),$$

另一方面, 由式(3-2), 可以得到

$$I_{\beta_1\beta_1} = E\left(-\frac{\partial^2 L(\xi)}{\partial \beta_1^2}\right) = \sum_{i=1}^n \frac{1+a_0\lambda^2}{\sigma^2} x_{i1}^2,$$

$$I_{\beta_1\nu} = E\left(-\frac{\partial^2 L(\xi)}{\partial \beta_1 \partial \nu^T}\right) = \sum_{i=1}^n \frac{1+a_0\lambda^2}{\sigma^2} x_{i1} x_i^{T(1)},$$

$$I_{\beta_1\sigma^2} = E\left(-\frac{\partial^2 L(\xi)}{\partial \beta_1 \partial \sigma^2}\right) = \sum_{i=1}^n \sqrt{\frac{1}{2\pi}} \frac{\lambda}{\sigma^3} \left(\frac{1+2\lambda^2}{(1+\lambda^2)^{\frac{3}{2}}}\right) + \sqrt{\frac{\pi}{2}} a_1 x_{i1},$$

$$I_{\beta_1\lambda} = E\left(-\frac{\partial^2 L(\xi)}{\partial \beta_1 \partial \lambda}\right) = \sum_{i=1}^n \sqrt{\frac{2}{\pi}} \frac{x_i}{\sigma} \left(\frac{1}{(1+\lambda^2)^{\frac{3}{2}}} - \sqrt{\frac{\pi}{2}} a_1\right) x_{i1},$$

$$I_{\nu\nu} = E\left(-\frac{\partial^2 L(\xi_0)}{\partial \nu \partial \nu^T}\right) = \sum_{i=1}^n \frac{1+a_0\lambda^2}{\sigma^2} x_i^{(1)} x_i^{T(1)},$$

$$I_{\nu\sigma^2} = E\left(-\frac{\partial^2 L(\xi)}{\partial \nu \partial \sigma^2}\right) = \sum_{i=1}^n \sqrt{\frac{1}{2\pi}} \frac{\lambda}{\sigma^3} \left(\frac{1+2\lambda^2}{(1+\lambda^2)^{\frac{3}{2}}} + \sqrt{\frac{\pi}{2}} a_1\right) x_i^{(1)},$$

$$I_{\nu\lambda} = E\left(-\frac{\partial^2 L(\xi)}{\partial \nu \partial \lambda}\right) = \sum_{i=1}^n \sqrt{\frac{2}{\pi}} \frac{x_i}{\sigma} \left(\frac{1}{(1+\lambda^2)^{\frac{3}{2}}} - \sqrt{\frac{\pi}{2}} a_1\right) x_i^{(1)},$$

其中 $a_j = E\left(\frac{\phi^2(b_j)}{\Phi^2(b_j)} b_j'\right)$, $j=0,1,2$; $b_i = \lambda \frac{y_i - x_i^T \beta}{\sigma}$, $x_i^{(1)} = (x_{i2}, x_{i3}, \dots, x_{iq})^T$, $i=1,2,\dots,n$,

所以可以求出关于 ξ 的 Fisher 信息矩阵的解析表达式

$$I(\xi) = \begin{bmatrix} I_{\beta_1\beta_1} & I_{\beta_1\xi^{(1)}} \\ I_{\beta_1\xi^{(1)}}^T & I_{\xi^{(1)}\xi^{(1)}} \end{bmatrix},$$

$$\text{其中 } I_{\beta_1\xi^{(1)}} = [I_{\beta_1\nu}, I_{\beta_1\sigma^2}, I_{\beta_1\lambda}], \quad I_{\xi^{(1)}\xi^{(1)}} = \begin{bmatrix} I_{\nu\nu} & I_{\nu\sigma^2} & I_{\nu\lambda} \\ I_{\sigma^2\nu} & I_{\sigma^2\sigma^2} & I_{\sigma^2\lambda} \\ I_{\lambda\nu} & I_{\lambda\sigma^2} & I_{\lambda\lambda} \end{bmatrix},$$

由式(3-2), 可以得到

$$\frac{\partial L(\xi)}{\partial \beta_1} = \sum_{i=1}^n \left\{ \frac{(y_i - x_i^T \beta) x_{i1}}{\sigma^2} - \frac{\phi(b_i)}{\Phi(b_i)} \frac{\lambda x_{i1}}{\sigma} \right\},$$

令 $K = (K_1, K_2, \dots, K_n)^T$, $K_i = \frac{(y_i - x_i^T \beta)}{\sigma^2} - \frac{\phi(b_i)}{\Phi(b_i)} \frac{\lambda}{\sigma}$, $x_{.1} = (x_{11}, x_{21}, \dots, x_{n1})^T$, $\hat{\xi}_0 = (0, \hat{\xi}_0^{(1)T})^T$, 则

Score 检验统计量为

$$SC_1 = \left\{ x_{.1}^T K (I_{\beta_1 \beta_1} - I_{\beta_1 \xi^{(1)}} I_{\xi^{(1)} \xi^{(1)}}^{-1} I_{\xi^{(1)} \beta_1}^T)^{-1} K^T x_{.1} \right\}_{\xi = \hat{\xi}_0} \xrightarrow{L} \chi^2(1).$$

3.2.2 尺度参数的齐次性检验

令 $\sigma_i^2 = \sigma^2 \omega(x_i, \rho)$, $i = 1, 2, \dots, n$, 其中 $\omega(x_i, \rho)$ 是关于 x_i 和 ρ 的函数, ρ 是 q_1 维向量,

假定存在着唯一的 ρ_0 使得 $\omega(x_i, \rho_0) \equiv 1$, $\forall i = 1, 2, \dots, n$, [28] 则尺度参数齐次性检验

$$\begin{aligned} H_0: \sigma_i^2 &= \sigma^2 \quad \text{vs} \quad H_1: \sigma_i^2 \neq \sigma^2, \quad \forall i = 1, 2, \dots, n, \\ &\Downarrow \\ H_0: \rho &= \rho_0 \quad \text{vs} \quad H_1: \rho \neq \rho_0. \end{aligned}$$

令 $\xi = (\rho^T, \theta^T)^T$, 则对数似然函数

$$L(\xi) = n \log 2 - \frac{n}{2} \log 2\pi - \frac{n}{2} \log \sigma^2 - \frac{1}{2} \sum_{i=1}^n \log \omega_i - \sum_{i=1}^n \frac{(y_i - x_i^T \beta)^2}{2\sigma^2 \omega_i} + \sum_{i=1}^n \log \Phi\left(\lambda \frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}\right). \quad (3-3)$$

设 $\hat{\xi} = (\hat{\rho}^T, \hat{\theta}^T)^T$ 为 ξ 极大似然估计, $\hat{\xi}_0 = (\rho_0^T, \hat{\theta}_0^T)^T$, 其中 $\hat{\theta}_0$ 为 $\rho = \rho_0$ 时, θ 的极大似然估计, 由子集参数似然比检验的性质 [27], 可以得到似然比检验统计量

$$LR_2 = 2\{L(\hat{\xi}) - L(\hat{\xi}_0)\} \xrightarrow{L} \chi^2(q_1).$$

另一方面, 在 H_0 成立的情况下, 由式(3-3), 可以得到

$$I_{\rho\rho} = E\left(-\frac{\partial^2 L(\xi)}{\partial \rho \partial \rho^T}\right) = \frac{2+a_2}{4} W^T W,$$

$$I_{\rho\beta} = E\left(-\frac{\partial^2 L(\xi)}{\partial \rho \partial \beta^T}\right) = \sqrt{\frac{2}{\pi}} \frac{\lambda}{2\sigma} \left(\frac{1+2\lambda^2}{(1+\lambda^2)^{\frac{3}{2}}} + \sqrt{\frac{\pi}{2}} a_1 \right) W^T x,$$

$$I_{\rho\sigma^2} = E\left(-\frac{\partial^2 L(\xi)}{\partial \rho \partial \sigma^2}\right) = \frac{2+a_2}{4\sigma^2} W^T I_n,$$

$$I_{\rho\lambda} = E\left(-\frac{\partial^2 L(\xi)}{\partial \rho \partial \lambda}\right) = -\frac{a_2}{2\lambda} W^T I_n,$$

其中 $W^T = (W_1^T, W_2^T, \dots, W_n^T)$, $W_i = \frac{\partial \omega_i}{\partial \rho^T}$, $i = 1, 2, \dots, n$.

所以可以求出关于 ξ 的 Fisher 信息矩阵解析表达式

$$I(\xi) = \begin{bmatrix} I_{\rho\rho} & I_{\rho\theta} \\ I_{\rho\theta}^T & I(\theta) \end{bmatrix},$$

其中 $I_{\rho\theta} = [I_{\rho\beta}, I_{\rho\sigma^2}, I_{\rho\lambda}]$.

由式(3-3), 可以得到

$$\frac{\partial L(\xi)}{\partial \rho} = \sum_{i=1}^n \left(-\frac{1}{2} \frac{1}{\omega_i} \frac{\partial \omega_i}{\partial \rho} + \frac{(y_i - x_i^T \beta)^2}{2\sigma^2 \omega_i^2} \frac{\partial \omega_i}{\partial \rho} + \frac{\phi(b_i^*)}{\Phi(b_i^*)} \frac{\partial b_i^*}{\partial \rho} \right),$$

$$\text{其中 } b_i^* = \frac{\lambda(y_i - x_i^T \beta)}{\sigma \omega_i^{\frac{1}{2}}}, \quad \frac{\partial b_i^*}{\partial \rho} = -\frac{1}{2} \frac{\lambda}{\sigma \omega_i^{\frac{3}{2}}} (y_i - x_i^T \beta) \frac{\partial \omega_i}{\partial \rho}.$$

令 $t = (t_1, t_2, \dots, t_n)^T$, $t_i = -\frac{1}{2} + \frac{(y_i - x_i^T \beta)^2}{2\sigma^2} - \frac{b_i \phi(b_i)}{2 \Phi(b_i)}$, $\hat{\xi}_0 = (\rho_0^T, \hat{\theta}_0^T)^T$, 则齐次性检验

Score 统计量为

$$SC_2 = \left\{ t^T W (I_{\rho\rho} - I_{\rho\theta} I^{-1}(\theta) I_{\rho\theta}^T)^{-1} W^T t \right\}_{\xi=\hat{\xi}_0} \xrightarrow{L} \chi^2(q_1).$$

3.2.3 偏度参数的齐次性检验

令 $\lambda_i = \lambda m(x_i, \gamma)$, $i=1, 2, \dots, n$, 其中 $m(x_i, \gamma)$ 是关于 x_i 和 γ 的函数, γ 是 q_2 维向量, 假定存在着唯一的 γ_0 使得 $m(x_i, \gamma_0) \equiv 1, \forall i=1, 2, \dots, n$, [28] 则偏度参数的齐次性检验

$$\begin{aligned} H_0: \lambda_i = \lambda \quad \text{vs} \quad H_1: \lambda_i \neq \lambda, \quad \forall i=1, 2, \dots, n, \\ \Downarrow \\ H_0: \gamma = \gamma_0 \quad \text{vs} \quad H_1: \gamma \neq \gamma_0, \end{aligned}$$

令 $\xi = (\gamma^T, \theta^T)^T$, 则对数似然函数

$$L(\xi) = n \log 2 - \frac{n}{2} \log 2\pi - \frac{n}{2} \log \sigma^2 - \sum_{i=1}^n \frac{(y_i - x_i^T \beta)^2}{2\sigma^2} + \sum_{i=1}^n \log \Phi(\lambda m_i \frac{y_i - x_i^T \beta}{\sigma}), \quad (3-4)$$

设 $\hat{\xi} = (\hat{\gamma}^T, \hat{\theta}^T)^T$ 为 ξ 极大似然估计, $\hat{\xi}_0 = (\gamma_0^T, \hat{\theta}_0^T)^T$, 其中 $\hat{\theta}_0$ 为 $\gamma = \gamma_0$ 时, θ 的极大似然估计, 由子集参数似然比检验的性质 [27], 可以得到似然比统计量

$$LR_3 = 2\{L(\hat{\xi}) - L(\hat{\xi}_0)\} \xrightarrow{L} \chi^2(q_2).$$

另一方面, 在 H_0 成立的情况下, 由式(3-4), 可以得到

$$I_{\gamma\gamma} = E\left(-\frac{\partial^2 L(\xi)}{\partial \gamma \partial \gamma^T}\right) = a_2 M^T M,$$

$$I_{\gamma\beta} = E\left(-\frac{\partial^2 L(\xi)}{\partial \gamma \partial \beta^T}\right) = \sqrt{\frac{2}{\pi}} \frac{\lambda}{\sigma} \left(\frac{1}{(1+\lambda^2)^{\frac{3}{2}}} - \sqrt{\frac{\pi}{2}} a_1\right) M^T x,$$

$$I_{\gamma\sigma^2} = E\left(-\frac{\partial^2 L(\xi)}{\partial \gamma \partial \sigma^2}\right) = -\frac{a_2}{2\sigma^2} M^T I_n,$$

$$I_{\gamma\lambda} = E\left(-\frac{\partial^2 L(\xi)}{\partial \gamma \partial \lambda}\right) = \frac{a_2}{\lambda} M^T I_n,$$

其中 $M^T = (M_1^T, M_2^T, \dots, M_n^T)$, $M_i = \frac{\partial m_i}{\partial \gamma^T}$, $i = 1, 2, \dots, n$.

所以可以求出关于 ξ 的 Fisher 信息矩阵解析表达式

$$I(\xi) = \begin{bmatrix} I_{\gamma\gamma} & I_{\gamma\theta} \\ I_{\gamma\theta}^T & I(\theta) \end{bmatrix},$$

其中 $I_{\gamma\theta} = [I_{\gamma\beta}, I_{\gamma\sigma^2}, I_{\gamma\lambda}]$.

由式(3-4), 可以得到

$$\frac{\partial L(\xi)}{\partial \gamma} = \sum_{i=1}^n \frac{\phi(\lambda m_i \frac{y_i - x_i^T \beta}{\sigma})}{\Phi(\lambda m_i \frac{y_i - x_i^T \beta}{\sigma})} \frac{\lambda(y_i - x_i^T \beta)}{\sigma} \frac{\partial m_i}{\partial \gamma},$$

令 $h = (h_1, h_2, \dots, h_n)^T$, $h_i = \frac{\phi(\lambda m_i \frac{y_i - x_i^T \beta}{\sigma})}{\Phi(\lambda m_i \frac{y_i - x_i^T \beta}{\sigma})} \frac{\lambda(y_i - x_i^T \beta)}{\sigma}$, $\hat{\xi}_0 = (\gamma_0^T, \hat{\theta}_0^T)^T$, 则齐次性检验的

Score 统计量为

$$SC_3 = \left\{ h^T M (I_{\gamma\gamma} - I_{\gamma\theta} I^{-1}(\theta) I_{\gamma\theta}^T)^{-1} M^T h \right\}_{\xi=\hat{\xi}_0} \xrightarrow{L} \chi^2(q_2).$$

3.3 蒙特卡罗数值模拟分析

本节将 3.1 和 3.2 节所提出的参数估计和假设检验的方法, 在通过 Monte Carlo 数值模拟分析得到的数据集上进行验证。

设 $x = (x_1, \dots, x_n)^T$, $y = (y_1, \dots, y_n)^T$, 偏正态多元线性回归模型为

$$y_i = x_i^T \beta + \varepsilon_i, i = 1, 2, \dots, n,$$

其中自变量和因变量分别为 $x_i = (1, x_{i1}, \dots, x_{iq})^T$ 和 y_i , 回归系数为 $\beta = (\beta_0, \beta_1, \dots, \beta_q)^T$, 随机误差 $\varepsilon_i \sim SN(0, \sigma^2, \lambda)$.

不妨以 $\beta = (\beta_0, \beta_1, \beta_2)^T = (1, 1, 1)^T$, $(\sigma^2, \lambda)^T = (1, -1)^T$ 的情况为例, β_0 为截距项。样本量 n 分别取 300, 600, 900; 然后使用 MATLAB 软件产生相应的模拟数据, 最后运用 3.1 中改进的 Gauss-Newton 法得到 $(\beta_0, \beta_1, \beta_2, \sigma^2, \lambda)^T$ 的极大似然估计, 并与真值进行比较, 模拟 1000 次。其中参数估计的准确性使用标准差 (STD)、均方误差 (MSE) 和平均绝对误差 (MAE) 来衡量。

$$STD = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{\alpha}_i - \bar{\alpha})^2},$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (\alpha_i - \hat{\alpha}_i)^2,$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |\alpha_i - \hat{\alpha}_i|,$$

其中 α_i 和 $\hat{\alpha}_i$ 分别为第 i 次数值模拟中参数的真实值和估计值, $\bar{\alpha}$ 为 n 次模拟的参数估计值的平均数。当标准差 (STD)、均方误差 (MSE) 和平均绝对误差 (MAE) 越接近 0 时, 所得的参数估计的大小越准确。相应结果如下:

表 3-1 样本容量 $n = 300$ 时, 参数的极大似然估计的结果

参数	实际值	估计值	STD	MSE	MAE
β_0	1	0.8943	0.3216	0.1146	0.2517
β_1	1	1.0008	0.0328	0.0011	0.0262
β_2	1	1.0003	0.0333	0.0011	0.0270
σ^2	1	0.9718	0.2513	0.0640	0.2087
λ	-1	-0.8929	0.6149	0.3896	0.4916

表 3-2 样本容量 $n = 600$ 时，参数的极大似然估计的结果

参数	实际值	估计值	<i>STD</i>	<i>MSE</i>	<i>MAE</i>
β_0	1	0.9512	0.2367	0.0584	0.1713
β_1	1	0.9992	0.0242	0.0006	0.0191
β_2	1	0.9993	0.0228	0.0005	0.0183
σ^2	1	0.9861	0.1900	0.0363	0.1539
λ	-1	-0.9422	0.4436	0.2001	0.3315

表 3-3 样本容量 $n = 900$ 时，参数的极大似然估计的结果

参数	实际值	估计值	<i>STD</i>	<i>MSE</i>	<i>MAE</i>
β_0	1	0.9522	0.1947	0.0402	0.1422
β_1	1	1.0007	0.0191	0.0004	0.0151
β_2	1	1.0013	0.0196	0.0004	0.0157
σ^2	1	0.9864	0.1591	0.0255	0.1279
λ	-1	-0.9484	0.3618	0.1336	0.2699

从上述表格中的结果可以看出，随着样本量不断地增加，回归系数 $(\beta_0, \beta_1, \beta_2)$ 、尺度参数 σ 、偏度参数 λ 的 ML 估计的标准差、均方误差和平均绝对误差也在不断地减小，参数估计值准确性越来越高；回归系数 $(\beta_0, \beta_1, \beta_2)$ 、尺度参数 σ 、偏度参数 λ 越来越接近真值。综上所述，随着样本量的增加，利用改进的高斯牛顿迭代法得到的极大似然估计准确性在不断地提高，估计值与真实值也越来越接近。

下面利用上述模拟分析得到的数据集来说明 3.2 节中回归参数假设检验的效果，选取 3.2.2 小节中的 $\omega(x_i, \rho) = \exp(\rho_1 x_{i1} + \rho_2 x_{i2})$ ，3.2.3 小节中的 $m(x_i, \gamma) = \exp(\gamma_1 x_{i1} + \gamma_2 x_{i2})$ ，由模拟分析可知， β_1 的真实值为 1， σ^2 和 λ 均为齐次性的，所以可以得到 $\rho = (\rho_1, \rho_2)^T$ 的真实值为 $\rho_0 = (0, 0)^T$ ， $\gamma = (\gamma_1, \gamma_2)^T$ 的真实值为 $\gamma_0 = (0, 0)^T$ ，假设检验的结果如下

表 3-4 样本容量 $n=300$ 时, 参数的假设检验结果

原假设 H_0	备择假设 H_1	LR 值	P 值
$\beta_1 = 0$	$\beta_1 \neq 0$	425.29	<0.0001
$\rho = \rho_0$	$\rho \neq \rho_0$	2.0202	0.3642
$\gamma = \gamma_0$	$\gamma \neq \gamma_0$	2.1626	0.3392

表 3-5 样本容量 $n=600$ 时, 参数的假设检验结果

原假设 H_0	备择假设 H_1	LR 值	P 值
$\beta_1 = 0$	$\beta_1 \neq 0$	845.84	<0.0001
$\rho = \rho_0$	$\rho \neq \rho_0$	2.0650	0.3561
$\gamma = \gamma_0$	$\gamma \neq \gamma_0$	2.2594	0.3231

表 3-6 样本容量 $n=900$ 时, 参数的假设检验结果

原假设 H_0	备择假设 H_1	LR 值	P 值
$\beta_1 = 0$	$\beta_1 \neq 0$	1264.32	<0.0001
$\rho = \rho_0$	$\rho \neq \rho_0$	1.9528	0.3767
$\gamma = \gamma_0$	$\gamma \neq \gamma_0$	2.0326	0.3619

从上述结果可以看出, 取置信水平 $\alpha=0.05$ 的情况下, 不同样本量下的模拟数据得出的假设检验的结论相同。(1) $H_0: \beta_1 = 0$ vs $H_1: \beta_1 \neq 0$ 的假设检验的 P 值小于 0.05, 所以拒绝 H_0 , 接受 H_1 , 得到 $\beta_1 \neq 0$; (2) $H_0: \rho = \rho_0$ vs $H_1: \rho \neq \rho_0$ 的假设检验的 P 值大于 0.05, 所以不拒绝 H_0 , 得到 $\rho = \rho_0$; (3) $H_0: \gamma = \gamma_0$ vs $H_1: \gamma \neq \gamma_0$ 的假设检验的 P 值大于 0.05, 所以不拒绝 H_0 , 得到 $\gamma = \gamma_0$; 由此可以看出, 检验结果与真实情况是一致的。

3.4 实例分析

本节主要通过波士顿房价的数据集^[29]，来介绍 3.1 节参数估计和 3.2 节假设检验的方法在实例中的应用。并对比了正态和偏正态多元线性回归模型在这个数据集上的适用性。其中回归模型的适用性利用 AIC 和 BIC 的值来进行评价。AIC 为赤池信息准则，是由统计学家赤池弘次提出的，是评价数据拟合优良性的一种有效的方法，其公式为

$$AIC = 2k - 2\ln(l), \tag{3-5}$$

其中 k 表示估计参数的数量， l 表示估计模型似然函数的最大值；而 BIC 为贝叶斯信息准则，它克服了 AIC 准则在样本个数为无穷大时，不收敛于真实模型的缺点，其公式为

$$BIC = k \ln(n) - 2\ln(l), \tag{3-6}$$

其中 k 和 l 的含义与上面是相同的， n 表示样本的容量。无论是 AIC 准则，还是 BIC 准则，它们在选择模型时都是值越小，表明模型的适用性越好。

本节使用的波士顿房价数据集包含了 20 世纪 70 年代，美国人口普查局收集到的波士顿郊区住房价格的相关信息，共 506 个观测数据，包含了 14 个指标，如下所示

表 3-7 波士顿房价数据集结构

指标	含义	指标	含义
x1	城镇人均犯罪率	x8	到波士顿五个就业中心的加权距离
x2	超过 25000 ft ² 的住宅占地比率	x9	径向高速公路的便利指数
x3	城镇中非零售业务的比率	x10	每 10000 美元的不动产税率
x4	哑变量（1：位于查尔斯河边，0：其他）	x11	城镇学生/教师的比率
x5	二氧化氮的浓度	x12	1000(Bk-0.63) ² (Bk: 城镇黑人比例)
x6	每间住宅中房间的平均数量	x13	低教育程度的人口占比
x7	1940 年前建造的自住单位比率	y	住房价格的中位数

为了防止量纲大小对回归结果的影响，回归模型中使用的指标均进行了标准化处理。以 y 为因变量， x_1 、 x_2 、...、 x_{13} 为自变量， ε 为随机误差，建立多元线性回归模型，首先讨论随机误差项服从正态分布的情况。

设多元线性回归模型的随机误差项 $\varepsilon_i \sim N(0, \sigma^2)$ ，利用 MATLAB 软件计算出逐步

回归法的结果,逐步回归从变量个数为 0 的初始状态开始进行,整个过程中未出现剔除变量的情况,每一步均添加一个新的变量。步数与均方根误差(RMSE)关系如下图所示:




图 3-1 逐步回归结果

从上图可以看出,当选取变量为 x_6 、 x_{13} 后,随着变量个数的增加,均方根误差(RMSE)的变化很小。为了选择简单有效的模型,本节选取最重要的两个指标 x_6 : 每间住宅中房间的平均数量、 x_{13} : 低教育程度的人口占比,来建立正态多元线性回归模型。

设多元线性回归模型为

$$y_i = x_i^T \beta + \varepsilon_i, \quad i = 1, 2, \dots, n, \quad (3-7)$$

其中因变量 y_i 为自有住房价格的中位数,自变量 $x_i = (1, x_{i1}, x_{i2})^T$, x_{i1} 为每间住宅中房间的平均数量、 x_{i2} 为低教育程度的人口占比,回归系数 $\beta = (\beta_0, \beta_1, \beta_2)^T$, β_0 为截距项, ε_i 为随机误差项。

取 $\varepsilon_i \sim N(0, \sigma^2)$, 计算得到正态多元线性回归模型的参数 ML 估计, 以及对应的 AIC 和 BIC 的值, 相应的结果见表 3-8。

为了使正态和偏正态多元线性回归模型拟合的数据集是相同的, 不改变回归模型 (3-7) 中选取的自变量 x_i 和因变量 y_i , 取 $\varepsilon_i \sim SN(0, \sigma^2, \lambda)$, 计算得到偏正态多元线性回归模型的参数 ML 估计, 以及对应的 AIC 和 BIC 的值, 相应的结果见表 3-8。

表 3-8 正态和偏正态下回归模型参数估计的结果

回归类型	β_0	β_1	β_2	σ^2	λ	AIC	BIC
正态多元线性	0	0.3893	-0.4988	0.3607	-	928.03	944.93
偏正态多元线性	-0.6649	0.2531	-0.5789	0.8144	3.4744	838.30	859.44

从上表可以得到, 正态多元线性回归模型 AIC 的值为 928.03, BIC 的值为 944.93; 而偏正态下的多元线性回归模型 AIC 的值为 838.30, BIC 的值为 859.44, 均小于正态多元线性回归模型对应的值, 因而偏正态多元线性回归模型在波士顿房价数据集上具有更好地适用性。

另一方面, 利用 3.2 节的方法, 对回归系数 β_1 的显著性、尺度参数和偏度参数的齐次性进行检验, 分别得到 $LR_1 = 59.0319$ 、 $LR_2 = 33.6515$ 和 $LR_3 = 32.8070$, 对应的 P 值均小于 0.05, 所以得到回归系数 β_1 值不为 0, 尺度参数 σ^2 和偏度参数 λ 均是非齐次性的。为了进一步说明结论的准确性, 接下来选择尺度参数非齐次性下的偏正态多元线性回归模型来拟合数据。

取 $\varepsilon_i \sim SN(0, \sigma^2 \omega(x_i, \rho), \lambda)$, $\omega(x_i, \rho) = \exp(\rho_1 x_{i1} + \rho_2 x_{i2})$, 可以计算得到相应的极大似然估计、AIC、BIC 的值, 结果见表 3-9。

表 3-9 尺度参数非齐次性下的回归模型参数估计的结果

	ρ_1	ρ_2	β_0	β_1	β_2
回归类型	σ^2	λ	AIC	BIC	-
偏正态多元线性回归	0.3468	0.0692	-0.6818	0.0983	-0.5564
$(\sigma_i^2 = \sigma^2 \omega(x_i, \rho))$	1.0505	3.7480	810.65	844.46	-

从上表可以看出, 尺度参数非齐次性下的偏正态线性回归模型 AIC 的值为 810.65, BIC 的值为 844.46, 均小于齐次性下的偏正态线性回归模型的值, 说明尺度参数非齐次性下的偏正态线性回归模型优于齐次性下的偏正态线性回归模型, 而齐次性检验的结果也表明尺度参数是非齐次性的。

第4章 偏 Logistic 正态多元线性回归

4.1 偏 Logistic 正态多元线性回归的参数估计

设变量 $x = (x_1, \dots, x_n)^T$, $y = (y_1, \dots, y_n)^T$, 偏 Logistic 正态多元线性回归模型为

$$y_i = x_i^T \beta + \varepsilon_i, \quad i = 1, 2, \dots, n,$$

其中自变量为 x_i , 因变量为 y_i , 回归系数 $\beta = (\beta_1, \dots, \beta_q)^T$, 随机误差 $\varepsilon_i \sim SLN(0, \sigma^2, \lambda)$.

令 $\theta = (\beta^T, \sigma^2, \lambda)^T$, 关于 θ 的似然函数

$$l(\theta) = \prod_{i=1}^n \frac{2}{\sigma} \frac{e^{-\frac{y_i - x_i^T \beta}{\sigma}}}{(1 + e^{-\frac{y_i - x_i^T \beta}{\sigma}})^2} \Phi\left(\lambda \frac{y_i - x_i^T \beta}{\sigma}\right) = \prod_{i=1}^n \frac{2}{\sigma} \frac{e^{\frac{y_i - x_i^T \beta}{\sigma}}}{(1 + e^{\frac{y_i - x_i^T \beta}{\sigma}})^2} \Phi\left(\lambda \frac{y_i - x_i^T \beta}{\sigma}\right),$$

所以对数似然函数

$$L(\theta) = n \log 2 - \frac{n}{2} \log \sigma^2 + \sum_{i=1}^n \frac{y_i - x_i^T \beta}{\sigma} - 2 \sum_{i=1}^n \log(1 + e^{\frac{y_i - x_i^T \beta}{\sigma}}) + \sum_{i=1}^n \log \Phi\left(\lambda \frac{y_i - x_i^T \beta}{\sigma}\right), \quad (4-1)$$

由式(4-1), 可得

$$\frac{\partial L(\theta)}{\partial \beta} = -\sum_{i=1}^n \frac{x_i}{\sigma} + \sum_{i=1}^n \frac{2x_i e^{\frac{y_i - x_i^T \beta}{\sigma}}}{\sigma(1 + e^{\frac{y_i - x_i^T \beta}{\sigma}})} - \sum_{i=1}^n \frac{\lambda x_i \phi(b_i)}{\sigma \Phi(b_i)},$$

$$\frac{\partial L(\theta)}{\partial \sigma^2} = -\frac{n}{2\sigma^2} - \sum_{i=1}^n \frac{y_i - x_i^T \beta}{2\sigma^3} + \sum_{i=1}^n \frac{(y_i - x_i^T \beta) e^{\frac{y_i - x_i^T \beta}{\sigma}}}{\sigma^3(1 + e^{\frac{y_i - x_i^T \beta}{\sigma}})} - \sum_{i=1}^n \frac{\lambda (y_i - x_i^T \beta) \phi(b_i)}{2\sigma^3 \Phi(b_i)},$$

$$\frac{\partial L(\theta)}{\partial \lambda} = \sum_{i=1}^n \frac{y_i - x_i^T \beta}{\sigma} \frac{\phi(b_i)}{\Phi(b_i)},$$

$$\frac{\partial^2 L(\theta)}{\partial \beta \partial \beta^T} = \sum_{i=1}^n \left(\frac{-2e^{\frac{y_i - x_i^T \beta}{\sigma}}}{\sigma^2(1 + e^{\frac{y_i - x_i^T \beta}{\sigma}})^2} + \frac{\lambda^2 (\Phi(b_i) \phi'(b_i) - \phi^2(b_i))}{\sigma^2 \Phi^2(b_i)} \right) x_i x_i^T,$$

$$\begin{aligned} \frac{\partial^2 L(\theta)}{\partial \beta \partial \sigma^2} &= \sum_{i=1}^n \frac{x_i}{2\sigma^3} - \sum_{i=1}^n \frac{x_i e^{\frac{y_i - x_i^T \beta}{\sigma}}}{\sigma^3(1 + e^{\frac{y_i - x_i^T \beta}{\sigma}})} - \sum_{i=1}^n \frac{x_i (y_i - x_i^T \beta) e^{\frac{y_i - x_i^T \beta}{\sigma}}}{\sigma^4(1 + e^{\frac{y_i - x_i^T \beta}{\sigma}})^2} + \sum_{i=1}^n \frac{\lambda x_i \phi(b_i)}{2\sigma^3 \Phi(b_i)} \\ &\quad + \sum_{i=1}^n \frac{\lambda^2 x_i (y_i - x_i^T \beta) (\phi'(b_i) \Phi(b_i) - \phi^2(b_i))}{2\sigma^4 \Phi^2(b_i)}, \end{aligned}$$

$$\begin{aligned}
 \frac{\partial^2 L(\theta)}{\partial \beta \partial \lambda} &= -\sum_{i=1}^n \left(\frac{\phi(b_i) x_i}{\sigma \Phi(b_i)} + \frac{\lambda x_i (y_i - x_i^T \beta) (\Phi(b_i) \phi'(b_i) - \phi^2(b_i))}{\sigma^2 \Phi^2(b_i)} \right), \\
 \frac{\partial^2 L(\theta)}{\partial (\sigma^2)^2} &= \frac{n}{2\sigma^4} + \sum_{i=1}^n \frac{3(y_i - x_i^T \beta)}{4\sigma^5} - \sum_{i=1}^n \frac{3(y_i - x_i^T \beta) e^{\frac{y_i - x_i^T \beta}{\sigma}}}{2\sigma^5 (1 + e^{\frac{y_i - x_i^T \beta}{\sigma}})} - \sum_{i=1}^n \frac{(y_i - x_i^T \beta)^2 e^{\frac{y_i - x_i^T \beta}{\sigma}}}{2\sigma^6 (1 + e^{\frac{y_i - x_i^T \beta}{\sigma}})^2} \\
 &\quad + \sum_{i=1}^n \frac{3\lambda (y_i - x_i^T \beta) \phi(b_i)}{4\sigma^5 \Phi(b_i)} + \sum_{i=1}^n \frac{\lambda^2 (y_i - x_i^T \beta)^2 (\phi'(b_i) \Phi(b_i) - \phi^2(b_i))}{4\sigma^6 \Phi^2(b_i)}, \\
 \frac{\partial^2 L(\theta)}{\partial \sigma^2 \partial \lambda} &= -\sum_{i=1}^n \frac{\lambda (y_i - x_i^T \beta)^2 (\phi'(b_i) \Phi(b_i) - \phi^2(b_i))}{2\sigma^4 \Phi^2(b_i)} - \sum_{i=1}^n \frac{(y_i - x_i^T \beta) \phi(b_i)}{2\sigma^3 \Phi(b_i)}, \\
 \frac{\partial^2 L(\theta)}{\partial \lambda^2} &= \sum_{i=1}^n \frac{(y_i - x_i^T \beta)^2 (\phi'(b_i) \Phi(b_i) - \phi^2(b_i))}{\sigma^2 \Phi^2(b_i)},
 \end{aligned}$$

其中 $b_i = \lambda \frac{y_i - x_i^T \beta}{\sigma}$, $i = 1, 2, \dots, n$.

由上述结果得到 $\dot{L}(\theta)$, $\ddot{L}(\theta)$ 的解析表达式如下

$$\begin{aligned}
 \dot{L}(\theta) &= \left(\frac{\partial L(\theta)}{\partial \beta^T}, \frac{\partial L(\theta)}{\partial \sigma^2}, \frac{\partial L(\theta)}{\partial \lambda} \right)^T, \\
 \ddot{L}(\theta) &= \begin{pmatrix} \frac{\partial^2 L}{\partial \beta \partial \beta^T} & \frac{\partial^2 L}{\partial \beta \partial \sigma^2} & \frac{\partial^2 L}{\partial \beta \partial \lambda} \\ \frac{\partial^2 L}{\partial \beta^T \partial \sigma^2} & \frac{\partial^2 L}{\partial (\sigma^2)^2} & \frac{\partial^2 L}{\partial \sigma^2 \partial \lambda} \\ \frac{\partial^2 L}{\partial \beta^T \partial \lambda} & \frac{\partial^2 L}{\partial \sigma^2 \partial \lambda} & \frac{\partial^2 L}{\partial \lambda^2} \end{pmatrix}.
 \end{aligned}$$

取初值为 $\theta^{(0)}$, 由 2.3.2 节改进的 Gauss-Newton 迭代法, 可以得到迭代过程如下,

存在 $\eta^{(0)}$, 使得

$$L(\theta^{(1)}) = L(\theta^{(0)}) + \eta^{(0)} [-\ddot{L}(\theta^{(0)})]^{-1} [\dot{L}(\theta^{(0)})] = \max_{0 < \eta \leq 1} L(\theta^{(0)}) + \eta [-\ddot{L}(\theta^{(0)})]^{-1} [\dot{L}(\theta^{(0)})] > L(\theta^{(0)}),$$

取

$$\theta^{(1)} = \theta^{(0)} + \eta^{(0)} [-\ddot{L}(\theta^{(0)})]^{-1} [\dot{L}(\theta^{(0)})],$$

存在 $\eta^{(1)}$, 使得

$$L(\theta^{(2)}) = L(\theta^{(1)}) + \eta^{(1)} [-\ddot{L}(\theta^{(1)})]^{-1} [\dot{L}(\theta^{(1)})] = \max_{0 < \eta \leq 1} L(\theta^{(1)}) + \eta [-\ddot{L}(\theta^{(1)})]^{-1} [\dot{L}(\theta^{(1)})] > L(\theta^{(1)}),$$

取

$$\theta^{(2)} = \theta^{(1)} + \eta^{(1)} [-\ddot{L}(\theta^{(1)})]^{-1} [\dot{L}(\theta^{(1)})],$$

.....

如此进行, 则必满足

$$L(\theta^{(0)}) < L(\theta^{(1)}) < L(\theta^{(2)}) < \cdots < L(\theta^{(i)}) < L(\theta^{(i+1)}) < \cdots,$$

当 $\|\theta^{(i+1)} - \theta^{(i)}\|^2 \leq \delta$ 时, 迭代结束, 其中 δ 可取充分小的正数, 例如 $\delta = 10^{-8}$, 此时选择 $\theta^{(i+1)}$ 作为 ML 估计 $\hat{\theta}$ 的近似值。

4.2 偏 Logistic 正态多元线性回归参数的假设检验

4.2.1 回归系数的显著性检验

设 $x = (x_1, \dots, x_n)^T$, $y = (y_1, \dots, y_n)^T$, 偏 Logistic 正态多元线性回归模型为

$$y_i = x_i^T \beta + \varepsilon_i, \quad i = 1, 2, \dots, n,$$

其中自变量和因变量分别为 $x_i = (x_{i1}, \dots, x_{iq})^T$ 和 y_i , 随机误差项 $\varepsilon_i \sim SLN(0, \sigma^2, \lambda)$, 回归系数为 $\beta = (\beta_1, \dots, \beta_q)^T$, 其第 j 个分量的显著性检验为

$$H_0: \beta_j = 0 \quad \text{vs} \quad H_1: \beta_j \neq 0,$$

其中 j 可取 $1, 2, \dots, q$. 不妨以 $j=1$ 为例进行说明, 其他情况相同, 令 $v = (\beta_2, \beta_3, \dots, \beta_q)^T$,

$\xi = (\beta_1, v^T, \sigma^2, \lambda)^T$, $\xi^{(1)} = (v^T, \sigma^2, \lambda)^T$, 由式(4-1), 可知

$$L(\xi) = n \log 2 - \frac{n}{2} \log \sigma^2 + \sum_{i=1}^n \frac{y_i - x_i^T \beta}{\sigma} - 2 \sum_{i=1}^n \log(1 + e^{\frac{y_i - x_i^T \beta}{\sigma}}) + \sum_{i=1}^n \log \Phi(\lambda \frac{y_i - x_i^T \beta}{\sigma}), \quad (4-2)$$

设 $\hat{\xi} = (\hat{\beta}_1, \hat{\xi}^{(1)T})^T$ 为 ξ 极大似然估计; $\hat{\xi}_0 = (0, \hat{\xi}_0^{(1)T})^T$, 其中 $\hat{\xi}_0^{(1)}$ 为 $\beta_1 = 0$ 时, $\xi^{(1)}$ 的极大似然估计, 由子集参数似然比检验的性质^[27], 可以得到似然比检验统计量

$$LR_1 = 2\{L(\hat{\xi}) - L(\hat{\xi}_0)\} \xrightarrow{L} \chi^2(1).$$

另一方面, 由式(4-2), 可得

$$\frac{\partial^2 L(\xi)}{\partial \beta_1^2} = \sum_{i=1}^n \left(\frac{-2e^{\frac{y_i - x_i^T \beta}{\sigma}}}{\sigma^2 (1 + e^{\frac{y_i - x_i^T \beta}{\sigma}})^2} + \frac{\lambda^2 (\Phi(b_i) \phi'(b_i) - \phi^2(b_i))}{\sigma^2 \Phi^2(b_i)} \right) x_{i1}^2,$$

$$\frac{\partial^2 L(\xi)}{\partial \beta_i \partial v^T} = \sum_{i=1}^n \left(\frac{-2e^{\frac{y_i - x_i^T \beta}{\sigma}}}{\sigma^2 (1 + e^{\frac{y_i - x_i^T \beta}{\sigma}})^2} + \frac{\lambda^2 (\Phi(b_i) \phi'(b_i) - \phi^2(b_i))}{\sigma^2 \Phi^2(b_i)} \right) x_{i1} x_i^{T(i)},$$

$$\begin{aligned} \frac{\partial^2 L(\xi)}{\partial \beta_i \partial \sigma^2} &= \sum_{i=1}^n \frac{x_{i1}}{2\sigma^3} - \sum_{i=1}^n \frac{x_{i1} e^{\frac{y_i - x_i^T \beta}{\sigma}}}{\sigma^3 (1 + e^{\frac{y_i - x_i^T \beta}{\sigma}})} - \sum_{i=1}^n \frac{x_{i1} (y_i - x_i^T \beta) e^{\frac{y_i - x_i^T \beta}{\sigma}}}{\sigma^4 (1 + e^{\frac{y_i - x_i^T \beta}{\sigma}})^2} + \sum_{i=1}^n \frac{\lambda x_{i1} \phi(b_i)}{2\sigma^3 \Phi(b_i)} \\ &\quad + \sum_{i=1}^n \frac{\lambda^2 x_{i1} (y_i - x_i^T \beta) (\phi'(b_i) \Phi(b_i) - \phi^2(b_i))}{2\sigma^4 \Phi^2(b_i)}, \end{aligned}$$

$$\frac{\partial^2 L(\xi)}{\partial \beta_i \partial \lambda} = - \sum_{i=1}^n \left(\frac{\phi(b_i) x_{i1}}{\sigma \Phi(b_i)} + \frac{\lambda x_{i1} (y_i - x_i^T \beta) (\Phi(b_i) \phi'(b_i) - \phi^2(b_i))}{\sigma^2 \Phi^2(b_i)} \right),$$

$$\frac{\partial^2 L(\xi)}{\partial v \partial v^T} = \sum_{i=1}^n \left(\frac{-2e^{\frac{y_i - x_i^T \beta}{\sigma}}}{\sigma^2 (1 + e^{\frac{y_i - x_i^T \beta}{\sigma}})^2} + \frac{\lambda^2 (\Phi(b_i) \phi'(b_i) - \phi^2(b_i))}{\sigma^2 \Phi^2(b_i)} \right) x_i^{(1)} x_i^{T(i)},$$

$$\begin{aligned} \frac{\partial^2 L(\xi)}{\partial v \partial \sigma^2} &= \sum_{i=1}^n \frac{x_i^{(1)}}{2\sigma^3} - \sum_{i=1}^n \frac{x_i^{(1)} e^{\frac{y_i - x_i^T \beta}{\sigma}}}{\sigma^3 (1 + e^{\frac{y_i - x_i^T \beta}{\sigma}})} - \sum_{i=1}^n \frac{x_i^{(1)} (y_i - x_i^T \beta) e^{\frac{y_i - x_i^T \beta}{\sigma}}}{\sigma^4 (1 + e^{\frac{y_i - x_i^T \beta}{\sigma}})^2} + \sum_{i=1}^n \frac{\lambda x_i^{(1)} \phi(b_i)}{2\sigma^3 \Phi(b_i)} \\ &\quad + \sum_{i=1}^n \frac{\lambda^2 x_i^{(1)} (y_i - x_i^T \beta) (\phi'(b_i) \Phi(b_i) - \phi^2(b_i))}{2\sigma^4 \Phi^2(b_i)}, \end{aligned}$$

$$\frac{\partial^2 L(\xi)}{\partial v \partial \lambda} = - \sum_{i=1}^n \left(\frac{\phi(b_i) x_i^{(1)}}{\sigma \Phi(b_i)} + \frac{\lambda x_i^{(1)} (y_i - x_i^T \beta) (\Phi(b_i) \phi'(b_i) - \phi^2(b_i))}{\sigma^2 \Phi^2(b_i)} \right),$$

其中 $b_i = \lambda \frac{y_i - x_i^T \beta}{\sigma}$, $x_i^{(1)} = (x_{i2}, x_{i3}, \dots, x_{iq})^T$, $i = 1, 2, \dots, n$.

由上述结果可以求出 $L_{\beta\beta}$, $L_{\beta\xi^{(1)}}$, $L_{\xi^{(1)}\xi^{(1)}}$ 的表达式如下

$$L_{\beta\beta_1} = \frac{\partial^2 L}{\partial \beta_1^2}, L_{\beta_1 \xi^{(1)}} = \left(\frac{\partial^2 L}{\partial \beta_1 \partial v^T}, \frac{\partial^2 L}{\partial \beta_1 \partial \sigma^2}, \frac{\partial^2 L}{\partial \beta_1 \partial \lambda} \right), L_{\xi^{(1)} \xi^{(1)}} = \begin{bmatrix} \frac{\partial^2 L}{\partial v \partial v^T} & \frac{\partial^2 L}{\partial v \partial \sigma^2} & \frac{\partial^2 L}{\partial v \partial \lambda} \\ \frac{\partial^2 L}{\partial \sigma^2 \partial v^T} & \frac{\partial^2 L}{\partial \sigma^2 \partial \sigma^2} & \frac{\partial^2 L}{\partial \sigma^2 \partial \lambda} \\ \frac{\partial^2 L}{\partial \lambda \partial v^T} & \frac{\partial^2 L}{\partial \sigma^2 \partial \lambda} & \frac{\partial^2 L}{\partial \lambda^2} \end{bmatrix}.$$

由(4-2)式, 可以得到

$$\frac{\partial L(\xi)}{\partial \beta_1} = -\sum_{i=1}^n \frac{x_{i1}}{\sigma} + \sum_{i=1}^n \frac{2x_{i1}e^{\frac{y_i - x_i^T \beta}{\sigma}}}{\sigma(1 + e^{\frac{y_i - x_i^T \beta}{\sigma}})} - \sum_{i=1}^n \frac{\lambda x_{i1} \phi(\lambda \frac{y_i - x_i^T \beta}{\sigma})}{\sigma \Phi(\lambda \frac{y_i - x_i^T \beta}{\sigma})},$$

$$\text{令 } K_i = -\frac{1}{\sigma} + \frac{2e^{\frac{y_i - x_i^T \beta}{\sigma}}}{\sigma(1 + e^{\frac{y_i - x_i^T \beta}{\sigma}})} - \frac{\lambda \phi(\lambda \frac{y_i - x_i^T \beta}{\sigma})}{\sigma \Phi(\lambda \frac{y_i - x_i^T \beta}{\sigma})}, \quad x_1 = (x_{11}, x_{21}, \dots, x_{q1})^T, \quad \hat{\xi}_0 = (0, \hat{\xi}_0^{(1)T})^T, \text{ 则}$$

Score 检验统计量为

$$SC_1 = \left\{ x_1^T K (-[L_{\beta_1 \beta_1} - L_{\beta_1 \xi^{(1)}} L_{\xi^{(1)} \xi^{(1)}}^{-1} L_{\xi^{(1)} \beta_1}^T]^{-1}) K^T x_1 \right\}_{\xi_0 = \hat{\xi}_0} \xrightarrow{L} \chi^2(1).$$

4.2.2 尺度参数的齐次性检验

令 $\sigma_i^2 = \sigma^2 \omega(x_i, \rho)$, $i=1, 2, \dots, n$, 其中 $\omega(x_i, \rho)$ 是关于 x_i 和 ρ 的函数, ρ 是 q_1 维向量,

假定存在着唯一的 ρ_0 使得 $\omega(x_i, \rho_0) \equiv 1$, $\forall i=1, 2, \dots, n$, [28] 则尺度参数的齐次性检验

$$\begin{aligned} H_0: \sigma_i^2 = \sigma^2 \quad \text{vs} \quad H_1: \sigma_i^2 \neq \sigma^2, \quad \forall i=1, 2, \dots, n, \\ \Updownarrow \\ H_0: \rho = \rho_0 \quad \text{vs} \quad H_1: \rho \neq \rho_0. \end{aligned}$$

令 $\xi = (\rho^T, \theta^T)^T$, 则对数似然函数

$$L(\xi) = n \log 2 - \frac{n}{2} \log \sigma^2 - \frac{1}{2} \sum_{i=1}^n \log \omega_i + \sum_{i=1}^n \frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}} - 2 \sum_{i=1}^n \log(1 + e^{\frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}}) + \sum_{i=1}^n \log \Phi(\lambda \frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}), \quad (4-3)$$

设 $\hat{\xi} = (\hat{\rho}^T, \hat{\theta}^T)^T$ 为 ξ 极大似然估计; $\hat{\xi}_0 = (\rho_0^T, \hat{\theta}_0^T)^T$, 其中 $\hat{\theta}_0$ 为 $\rho = \rho_0$ 时, θ 的极大似然估计, 由于子集参数似然比检验的性质 [27], 可以得到

$$LR_2 = 2\{L(\hat{\xi}) - L(\hat{\xi}_0)\} \xrightarrow{L} \chi^2(q_1).$$

另一方面, 由式(4-3), 可以得到

$$\begin{aligned} \frac{\partial^2 L(\xi)}{\partial \rho \partial \beta^T} &= \sum_{i=1}^n \frac{W_i^T x_i^T}{2\sigma \omega_i^{\frac{3}{2}}} - \sum_{i=1}^n \frac{W_i^T x_i^T e^{\frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}}}{\sigma \omega_i^{\frac{3}{2}} (1 + e^{\frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}})} - \sum_{i=1}^n \frac{W_i^T x_i^T (y_i - x_i^T \beta) e^{\frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}}}{\sigma^2 \omega_i^2 (1 + e^{\frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}})^2} + \sum_{i=1}^n \frac{\lambda W_i^T x_i^T \phi(b_i^*)}{2\sigma \omega_i^{\frac{3}{2}} \Phi(b_i^*)} \\ &\quad + \sum_{i=1}^n \frac{\lambda^2 W_i^T x_i^T (y_i - x_i^T \beta) (\phi(b_i^*) \Phi(b_i^*) - \phi^2(b_i^*))}{2\sigma^2 \omega_i^2 \Phi^2(b_i^*)}, \end{aligned}$$

$$\begin{aligned}
\frac{\partial^2 L(\xi)}{\partial \rho \partial \sigma^2} &= \sum_{i=1}^n \frac{W_i^T (y_i - x_i^T \beta)}{4\sigma^3 \omega_i^{\frac{3}{2}}} - \sum_{i=1}^n \frac{W_i^T (y_i - x_i^T \beta) e^{\frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}}}{2\sigma^3 \omega_i^{\frac{3}{2}} (1 + e^{\frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}})} - \sum_{i=1}^n \frac{W_i^T (y_i - x_i^T \beta)^2 e^{\frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}}}{2\sigma^4 \omega_i^2 (1 + e^{\frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}})^2} \\
&\quad + \sum_{i=1}^n \frac{W_i^T \lambda (y_i - x_i^T \beta) \phi(b_i^*)}{4\sigma^3 \omega_i^{\frac{3}{2}} \Phi(b_i^*)} + \sum_{i=1}^n \frac{\lambda^2 W_i^T (y_i - x_i^T \beta)^2 (\phi'(b_i^*) \Phi(b_i^*) - \phi^2(b_i^*))}{4\sigma^4 \omega_i^2 \Phi^2(b_i^*)}, \\
\frac{\partial^2 L(\xi)}{\partial \rho \partial \lambda} &= - \sum_{i=1}^n \frac{W_i^T (y_i - x_i^T \beta) \phi(b_i^*)}{2\sigma \omega_i^{\frac{3}{2}} \Phi(b_i^*)} - \sum_{i=1}^n \frac{\lambda W_i^T (y_i - x_i^T \beta)^2 (\phi'(b_i^*) \Phi(b_i^*) - \phi^2(b_i^*))}{2\sigma^2 \omega_i^2 \Phi^2(b_i^*)}, \\
\frac{\partial^2 L(\xi)}{\partial \rho \partial \rho^T} &= \sum_{i=1}^n \frac{3(y_i - x_i^T \beta) W_i^T W_i}{4\sigma \omega_i^{\frac{5}{2}}} - \sum_{i=1}^n \frac{3(y_i - x_i^T \beta) W_i^T W_i e^{\frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}}}{2\sigma \omega_i^{\frac{5}{2}} (1 + e^{\frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}})} + \sum_{i=1}^n \frac{3\lambda (y_i - x_i^T \beta) W_i^T W_i \phi(b_i^*)}{4\sigma \omega_i^{\frac{5}{2}} \Phi(b_i^*)} + \\
&\quad \sum_{i=1}^n \frac{W_i^T W_i}{2\omega_i^2} - \sum_{i=1}^n \frac{(y_i - x_i^T \beta)^2 W_i^T W_i e^{\frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}}}{2\sigma^2 \omega_i^3 (1 + e^{\frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}})^2} + \sum_{i=1}^n \frac{\lambda^2 (y_i - x_i^T \beta)^2 W_i^T W_i (\phi'(b_i^*) \Phi(b_i^*) - \phi^2(b_i^*))}{4\sigma^2 \omega_i^3 \Phi^2(b_i^*)} \\
&\quad - \sum_{i=1}^n \left(\left(\frac{1}{2\omega_i} + \frac{y_i - x_i^T \beta}{2\sigma \omega_i^{\frac{3}{2}}} - \frac{(y_i - x_i^T \beta) e^{\frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}}}{\sigma \omega_i^{\frac{3}{2}} (1 + e^{\frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}})} + \frac{\lambda (y_i - x_i^T \beta) \phi(b_i^*)}{2\sigma \omega_i^{\frac{3}{2}} \Phi(b_i^*)} \right) \frac{\partial^2 \omega_i}{\partial \rho \partial \rho^T} \right), \\
\text{其中 } b_i^* &= \lambda \frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}, W^T = (W_1^T, W_2^T, \dots, W_n^T), W_i = \frac{\partial \omega_i}{\partial \rho^T}, i = 1, 2, \dots, n.
\end{aligned}$$

由上述结果可以求出 $L_{\rho\rho}, L_{\rho\theta}$ 的解析表达式如下

$$L_{\rho\rho} = \frac{\partial^2 L}{\partial \rho \partial \rho^T}, L_{\rho\theta} = \frac{\partial^2 L}{\partial \rho \partial \theta^T} = \left(\frac{\partial^2 L}{\partial \rho \partial \beta^T}, \frac{\partial^2 L}{\partial \rho \partial \sigma^2}, \frac{\partial^2 L}{\partial \rho \partial \lambda} \right).$$

由式(4-3), 可以得到

$$\begin{aligned}
\frac{\partial L(\xi)}{\partial \rho} &= - \sum_{i=1}^n \frac{W_i^T}{2\omega_i} - \sum_{i=1}^n \frac{W_i^T (y_i - x_i^T \beta)}{2\sigma \omega_i^{\frac{3}{2}}} + \sum_{i=1}^n \frac{W_i^T (y_i - x_i^T \beta) e^{\frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}}}{\sigma \omega_i^{\frac{3}{2}} (1 + e^{\frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}})} - \sum_{i=1}^n \frac{\lambda W_i^T (y_i - x_i^T \beta) \phi(b_i^*)}{2\sigma \omega_i^{\frac{3}{2}} \Phi(b_i^*)}, \\
\text{令 } t &= (t_1, t_2, \dots, t_n)^T, t_i = -\frac{1}{2\omega_i} - \frac{y_i - x_i^T \beta}{2\sigma \omega_i^{\frac{3}{2}}} + \frac{(y_i - x_i^T \beta) e^{\frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}}}{\sigma \omega_i^{\frac{3}{2}} (1 + e^{\frac{y_i - x_i^T \beta}{\sigma \sqrt{\omega_i}}})} - \frac{\lambda (y_i - x_i^T \beta) \phi(b_i^*)}{2\sigma \omega_i^{\frac{3}{2}} \Phi(b_i^*)}, \hat{\xi}_0 = (\rho_0^T, \hat{\theta}_0^T)^T,
\end{aligned}$$

则齐次性检验 Score 统计量为

$$SC_2 = \{t^T W (-[L_{\rho\rho} - L_{\rho\theta} (\ddot{L}(\theta))^{-1} L_{\rho\theta}^T]^{-1}) W^T t\}_{\xi=\hat{\xi}_0} \xrightarrow{L} \chi^2(q_1).$$

4.2.3 偏度参数的齐次性检验

令 $\lambda_i = \lambda m(x_i, \gamma)$, $i=1, 2, \dots, n$, 其中 $m(x_i, \gamma)$ 是关于 x_i 和 γ 的权重函数, γ 是 q_2 维向量,

假定存在着唯一的 γ_0 使得 $m(x_i, \gamma_0) \equiv 1$, $\forall i=1, 2, \dots, n$, [28] 则偏度参数的齐次性检验

$$\begin{aligned} H_0: \lambda_i &= \lambda \quad \text{vs} \quad H_1: \lambda_i \neq \lambda, \quad \forall i=1, 2, \dots, n, \\ &\Updownarrow \\ H_0: \gamma &= \gamma_0 \quad \text{vs} \quad H_1: \gamma \neq \gamma_0, \end{aligned}$$

令 $\xi = (\gamma^T, \theta^T)^T$, 则关于 ξ 的对数似然函数

$$L(\xi) = n \log 2 - \frac{n}{2} \log \sigma^2 + \sum_{i=1}^n \frac{y_i - x_i^T \beta}{\sigma} - 2 \sum_{i=1}^n \log(1 + e^{\frac{y_i - x_i^T \beta}{\sigma}}) + \sum_{i=1}^n \log \Phi(\lambda m_i \frac{y_i - x_i^T \beta}{\sigma}), \quad (4-4)$$

设 $\hat{\xi} = (\hat{\gamma}^T, \hat{\theta}^T)^T$ 为 ξ 极大似然估计, $\hat{\xi}_0 = (\gamma_0^T, \hat{\theta}_0^T)^T$, 其中 $\hat{\theta}_0$ 为 $\gamma = \gamma_0$ 时, θ 的极大似然估计, 由于子集参数似然比检验的性质 [27], 可以得到

$$LR_3 = 2\{L(\hat{\xi}) - L(\hat{\xi}_0)\} \xrightarrow{L} \chi^2(q_2).$$

另一方面, 由式(4-4), 可以得到

$$\frac{\partial^2 L(\xi)}{\partial \gamma \partial \gamma^T} = \sum_{i=1}^n \frac{\lambda^2 (y_i - x_i^T \beta)^2 (\phi'(b_i^*) \Phi(b_i^*) - \phi^2(b_i^*))}{\sigma^2 \Phi^2(b_i^*)} M_i^T M_i + \sum_{i=1}^n \frac{\lambda (y_i - x_i^T \beta) \phi(b_i^*)}{\sigma \Phi(b_i^*)} \frac{\partial^2 m_i}{\partial \gamma \partial \gamma^T},$$

$$\frac{\partial^2 L(\xi)}{\partial \gamma \partial \beta^T} = - \sum_{i=1}^n \frac{\lambda^2 m_i (y_i - x_i^T \beta) (\phi'(b_i^*) \Phi(b_i^*) - \phi^2(b_i^*))}{\sigma^2 \Phi^2(b_i^*)} M_i^T x_i^T - \sum_{i=1}^n \frac{\lambda \phi(b_i^*)}{\sigma \Phi(b_i^*)} M_i^T x_i^T,$$

$$\frac{\partial^2 L(\xi)}{\partial \gamma \partial \sigma^2} = - \sum_{i=1}^n \frac{\lambda^2 m_i (y_i - x_i^T \beta)^2 (\phi'(b_i^*) \Phi(b_i^*) - \phi^2(b_i^*))}{2 \sigma^4 \Phi^2(b_i^*)} M_i^T - \sum_{i=1}^n \frac{\lambda (y_i - x_i^T \beta) \phi(b_i^*)}{2 \sigma^3 \Phi(b_i^*)} M_i^T,$$

$$\frac{\partial^2 L(\xi)}{\partial \gamma \partial \lambda} = \sum_{i=1}^n \frac{\lambda m_i (y_i - x_i^T \beta)^2 (\phi'(b_i^*) \Phi(b_i^*) - \phi^2(b_i^*))}{\sigma^2 \Phi^2(b_i^*)} M_i^T + \sum_{i=1}^n \frac{(y_i - x_i^T \beta) \phi(b_i^*)}{\sigma \Phi(b_i^*)} M_i^T,$$

其中 $b_i^* = \lambda m_i \frac{y_i - x_i^T \beta}{\sigma}$, $M^T = (M_1^T, M_2^T, \dots, M_n^T)$, $M_i = \frac{\partial m_i}{\partial \gamma^T}$, $i=1, 2, \dots, n$.

由上述结果可以求出 $L_{\gamma\gamma}$, $L_{\gamma\theta}$ 的解析表达式

$$L_{\gamma\gamma} = \frac{\partial^2 L}{\partial \gamma \partial \gamma^T}, \quad L_{\gamma\theta} = \frac{\partial^2 L}{\partial \gamma \partial \theta^T} = \left(\frac{\partial^2 L}{\partial \gamma \partial \beta^T}, \frac{\partial^2 L}{\partial \gamma \partial \sigma^2}, \frac{\partial^2 L}{\partial \gamma \partial \lambda} \right).$$

由式(4-4), 可以得到

$$\frac{\partial L(\xi)}{\partial \gamma} = \sum_{i=1}^n \frac{\phi(\lambda m_i \frac{y_i - x_i^T \beta}{\sigma})}{\Phi(\lambda m_i \frac{y_i - x_i^T \beta}{\sigma})} \frac{\lambda(y_i - x_i^T \beta)}{\sigma} \frac{\partial m_i}{\partial \gamma},$$

令 $h = (h_1, h_2, \dots, h_n)^T$, $h_i = \frac{\phi(\lambda m_i \frac{y_i - x_i^T \beta}{\sigma})}{\Phi(\lambda m_i \frac{y_i - x_i^T \beta}{\sigma})} \frac{\lambda(y_i - x_i^T \beta)}{\sigma}$, $\hat{\xi}_0 = (\gamma_0^T, \hat{\theta}_0^T)^T$, 则齐次性检验

Score 统计量为

$$SC_3 = \{h^T M(-[L_{\gamma\gamma} - L_{\gamma\theta}(\ddot{L}(\theta))^{-1} L_{\gamma\theta}^T]^{-1}) M^T h\}_{\xi=\hat{\xi}_0} \xrightarrow{L} \chi^2(q_2).$$

4.3 蒙特卡罗数值模拟分析

本节将 4.1 和 4.2 节所提出的参数估计和假设检验的方法, 在通过 Monte Carlo 数值模拟得到的数据上进行验证。

设变量 $x = (x_1, \dots, x_n)^T$, $y = (y_1, \dots, y_n)^T$, 偏 Logistic 正态多元线性回归模型为

$$y_i = x_i^T \beta + \varepsilon_i, \quad i = 1, 2, \dots, n,$$

其中因变量为 y_i , 自变量为 $x_i = (1, x_{i1}, \dots, x_{iq})^T$, 回归系数为 $\beta = (\beta_0, \beta_1, \dots, \beta_q)^T$, β_0 为截距项, 随机误差 $\varepsilon_i \sim SLN(0, \sigma^2, \lambda)$.

不妨以 $\beta = (\beta_0, \beta_1, \beta_2)^T = (1, 1, 1)^T$, $(\sigma^2, \lambda)^T = (1, -1)^T$ 的情况为例。样本量 n 分别取 300, 600, 900. 然后使用 MATLAB 软件产生相应的模拟数据, 最后运用 4.1 节中改进的 Gauss-Newton 法得到 $(\beta_0, \beta_1, \beta_2, \sigma^2, \lambda)^T$ 的极大似然估计, 并与真值进行比较, 模拟 1000 次。其中参数估计的准确性使用标准差 (STD)、均方误差 (MSE) 和平均绝对误差 (MAE) 来衡量,

$$STD = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{\alpha}_i - \bar{\hat{\alpha}})^2},$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (\alpha_i - \hat{\alpha}_i)^2,$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |\alpha_i - \hat{\alpha}_i|,$$

其中 α_i 和 $\hat{\alpha}_i$ 分别为第 i 次数值模拟中参数的真实值和估计值, $\bar{\hat{\alpha}}$ 为 n 次模拟的参数估计值的平均数。当标准差 (STD)、均方误差 (MSE) 和平均绝对误差 (MAE) 越接近 0 时, 所

得的参数估计的大小越准确。相应结果如下：

表 4-1 样本容量 $n=300$ 时，参数的极大似然估计的结果

参数	实际值	估计值	<i>STD</i>	<i>MSE</i>	<i>MAE</i>
β_0	1	0.9847	0.2624	0.0691	0.2077
β_1	1	1.0001	0.0494	0.0024	0.0390
β_2	1	0.9993	0.0478	0.0023	0.0381
σ^2	1	0.9977	0.2272	0.0516	0.1802
λ	-1	-1.0406	0.3367	0.1150	0.2573

表 4-2 样本容量 $n=600$ 时，参数的极大似然估计的结果

参数	实际值	估计值	<i>STD</i>	<i>MSE</i>	<i>MAE</i>
β_0	1	0.9862	0.1834	0.0338	0.1478
β_1	1	1.0010	0.0347	0.0012	0.0281
β_2	1	1.0001	0.0331	0.0011	0.0266
σ^2	1	0.9926	0.1609	0.0259	0.1292
λ	-1	-1.0140	0.2126	0.0454	0.1679

表 4-3 样本容量 $n=900$ 时，参数的极大似然估计的结果

参数	实际值	估计值	<i>STD</i>	<i>MSE</i>	<i>MAE</i>
β_0	1	0.9974	0.1442	0.0208	0.1145
β_1	1	0.9988	0.0271	0.0007	0.0218
β_2	1	0.9986	0.0281	0.0008	0.0225
σ^2	1	0.9914	0.1277	0.0164	0.1023
λ	-1	-1.0039	0.1639	0.0269	0.1291

从上述表格中的结果可以看出，随着样本量不断地增加，回归系数 $(\beta_0, \beta_1, \beta_2)$ 、尺度参数 σ 、偏度参数 λ 的 ML 估计的标准差、均方误差和平均绝对误差也在不断地减小，参数估计值准确性越来越高，回归系数 $(\beta_0, \beta_1, \beta_2)$ 、位置参数 μ 、尺度参数 σ 、偏度参数 λ 的 ML 估计值也越来越接近真实值。综上所述，随着样本量的增加，利用改进的高斯牛顿迭代法求得的极大似然估计与真实值越来越接近，准确性也在不断地提高。

下面利用上述模拟分析的数据来说明 4.2 节中回归参数假设检验的效果。选取 4.2.2 小节中的 $\omega(x_i, \rho) = \exp(\rho_1 x_{i1} + \rho_2 x_{i2})$ ，4.2.3 小节中的 $\gamma(x_i, \rho) = \exp(\gamma_1 x_{i1} + \gamma_2 x_{i2})$ ，由模拟分析可知， β_1 的真实值为 1， σ^2 和 λ 均为齐次性的，所以可以得到 $\rho = (\rho_1, \rho_2)$ 的真实值为 $\rho_0 = (0, 0)^T$ ， $\gamma = (\gamma_1, \gamma_2)$ 的真实值为 $\gamma_0 = (0, 0)^T$ ，假设检验的结果如下表所示

表 4-4 样本容量 $n = 300$ 时，参数的假设检验结果

原假设 H_0	备择假设 H_1	LR 值	P 值
$\beta_1 = 0$	$\beta_1 \neq 0$	261.82	<0.0001
$\rho = \rho_0$	$\rho \neq \rho_0$	2.0414	0.3603
$\gamma = \gamma_0$	$\gamma \neq \gamma_0$	2.1184	0.3467

表 4-5 样本容量 $n = 600$ 时，参数的假设检验结果

原假设 H_0	备择假设 H_1	LR 值	P 值
$\beta_1 = 0$	$\beta_1 \neq 0$	523.01	<0.0001
$\rho = \rho_0$	$\rho \neq \rho_0$	2.0235	0.3636
$\gamma = \gamma_0$	$\gamma \neq \gamma_0$	1.9545	0.3763

表 4-6 样本容量 $n=900$ 时, 参数的假设检验结果

原假设 H_0	备择假设 H_1	LR 值	P 值
$\beta_1 = 0$	$\beta_1 \neq 0$	777.62	<0.0001
$\rho = \rho_0$	$\rho \neq \rho_0$	2.0128	0.3655
$\gamma = \gamma_0$	$\gamma \neq \gamma_0$	2.0122	0.3656

从上述结果可以看出, 在取置信水平 $\alpha=0.05$ 的情况下, 不同样本量下的模拟数据得出的假设检验的结论相同。(1) $H_0: \beta_1=0$ vs $H_1: \beta_1 \neq 0$ 假设检验的 P 值小于 0.05, 所以拒绝 H_0 , 接受 H_1 , 得到 $\beta_1 \neq 0$; (2) $H_0: \rho=\rho_0$ vs $H_1: \rho \neq \rho_0$ 假设检验的 P 值大于 0.05, 所以不拒绝 H_0 , 得到 $\rho=\rho_0$; (3) $H_0: \gamma=\gamma_0$ vs $H_1: \gamma \neq \gamma_0$ 假设检验的 P 值大于 0.05, 所以不拒绝 H_0 , 得到 $\gamma=\gamma_0$; 由此可以看出, 检验结果与真实情况是一致的。

4.4 实例分析

本节仍选用 3.4 节中波士顿房价的数据集, 来介绍 4.1 节参数估计和 4.2 节假设检验的方法在实例中的应用。并与 3.4 节中正态和偏正态多元线性回归模型情况下数据拟合的效果进行对比。模型拟合数据的优劣性仍采用 AIC 与 BIC 信息准则来评价。

为了使偏 Logistic 正态多元线性回归模型与 3.4 节中的正态和偏正态多元线性回归模型拟合的数据集是一样的, 本节仍使用 x6: 每间住宅中房间的平均数量、x13: 低教育程度的人口占比为自变量, y: 自有住房价格的中位数为因变量, 则偏 Logistic 正态多元线性回归模型为

$$y_i = x_i^T \beta + \varepsilon_i, \quad i=1, 2, \dots, n,$$

其中因变量 y_i 为自有住房价格的中位数, 自变量 $x_i = (1, x_{i1}, x_{i2})^T$, x_{i1} 为每间住宅的平均房间数、 x_{i2} 为人口状况下降百分率, 回归系数 $\beta = (\beta_0, \beta_1, \beta_2)^T$, β_0 为截距项, ε_i 为随机误差项。

取 $\varepsilon_i \sim SLN(0, \sigma^2, \lambda)$, 计算得到偏 Logistic 正态多元线性回归下的参数 ML 估计, 以及对应的 AIC 和 BIC 的值, 结果见表 4-7。

表 4-7 偏 Logistic 正态分布参数估计的结果

回归类型	β_0	β_1	β_2	σ^2	λ	AIC	BIC
偏 Logistic 正态多元线性回归	-0.5869	0.2506	-0.5869	0.2035	1.5359	809.90	831.03

从上表可以看出，偏 Logistic 正态多元线性回归模型的 AIC 的值为 809.90，BIC 的值为 831.03，均小于正态和偏正态多元线性回归模型对应的值，所以偏 Logistic 正态多元线性回归模型能更好地拟合波士顿房价数据集。

另一方面，利用 4.2 的方法，对回归系数的显著性、尺度参数和偏度参数的齐次性进行检验，分别得到 $LR_1 = 51.6249$ 、 $LR_2 = 40.2482$ 和 $LR_3 = 44.0099$ ，所对应的 P 值均小于 0.05。从而可以得到回归系数 β_1 值不为 0，尺度参数 σ^2 和偏度参数 λ 均是非齐次性的。为了进一步验证结论，接下来选择尺度参数非齐次性下的偏 Logistic 正态线性回归模型来拟合数据。

取 $\varepsilon_i \sim SLN(0, \sigma^2 \omega(x_i, \rho), \lambda)$ ， $\omega(x_i, \rho) = \exp(\rho_1 x_{i1} + \rho_2 x_{i2})$ ，相应的极大似然估计、AIC、BIC 的值，结果见表 4-8。

表 4-8 尺度参数非齐次性下的回归模型参数估计的结果

回归类型	ρ_1	ρ_2	β_0	β_1	β_2
	σ^2	λ	AIC	BIC	-
偏 Logistic 正态多元	0.4397	0.0196	-0.6025	0.1014	-0.5265
线性 ($\sigma_i^2 = \sigma^2 \omega(x_i, \rho)$)	0.1929	1.5546	775.65	809.46	-

从上表可以看出，尺度参数非齐次性下的偏正态线性回归模型 AIC 的值为 775.65，BIC 的值为 809.46，均小于齐次性下的偏 Logistic 正态线性回归模型下的值，说明尺度参数非齐次性下的偏 Logistic 正态线性回归模型优于齐次性下的偏 Logistic 正态线性回归模型，而齐次性检验的结果也表明尺度参数是非齐次性的。

第5章 总结与展望

在工程科学、金融经济、以及社会生产等实践活动中产生的数据的分布并不一定具有严格的对称性，而是带有一定程度的偏斜，这类数据如果使用正态分布、 t 分布、Logistic 分布等对称概率统计模型拟合，显然是不科学的，而使用偏态分布拟合，可以更加准确地描述它的分布规律，因此对偏态分布构建和研究是非常重要的。基于此，本文主要提出了一种新的偏态分布-偏对称正态分布，列举了若干偏对称正态分布及其相关性质，并重点研究了其中的偏正态和偏 Logistic 正态分布在回归方面的应用。本文的第一章介绍了本课题的研究背景、研究现状以及国内外已有的相关成果，同时介绍了本文的主要研究内容及创新；第二章给出了偏对称正态分布的定义及相关性质，列举了若干偏对称正态分布，并讨论了它们的数学特征及若干性质，同时介绍了两种 Gauss-Newton 迭代法求解偏对称正态分布参数 ML 估计的方法，并通过蒙特卡罗数值模拟分析进行了说明；第三章研究了偏正态分布在多元线性回归方面的应用，建立偏正态多元线性回归模型，并介绍了计算该模型回归参数 ML 估计的方法，同时基于对数似然函数的表达式，求解了 Fisher 信息矩阵的解析表达式，由此推导出了似然比检验和 Score 检验的统计量，用于检验这两个偏对称正态多元线性回归模型系数的显著性、以及尺度参数和偏度参数齐次性，并通过蒙特卡罗数值模拟研究说明了该方法的有效性，并进行了实例分析。同时对比了正态和偏正态多元线性回归模型在波士顿房价数据集上的拟合效果，结果表明偏正态分布下的回归模型优于正态分布下回归模型，其中模型拟合数据的优劣性通过 AIC 和 BIC 准则来评价。第四章研究了偏 Logistic 正态多元线性回归模型，介绍了模型参数 ML 估计的求解、回归系数显著性检验、以及尺度参数和偏度参数齐次性检验的方法，通过蒙特卡罗数值模拟研究进行了验证，并进行了实例分析。第五章对本文内容进行了总结。

本文主要研究了偏对称正态分布的理论及相关应用，还存在一些需要进一步研究的问题，例如（1）本文重点研究了偏正态和偏 Logistic 正态多元线性回归模型，还有其他的偏对称正态，例如偏 t 正态、偏 Laplace 正态等多元线性回归模型，需要进一步研究；（2）本文主要研究了偏对称正态多元线性回归模型，对于非线性的情况有待进一步研究；（3）本文研究了非缺失数据下的统计方法，但实际生活中收集到的数据，往往是有缺失的，对缺失数据下的研究还需要进一步补充。相关的研究将在今后的学习中继续进行。

参考文献

- [1] Azzalini A. A Class of Distributions Which Includes the Normal Ones [J]. Scandinavian Journal of Statistics, 1985, 12(2):171-178.
- [2] Arnold B C, Beaver R J. The skew-Cauchy distribution [J]. Statistics & Probability Letters, 2000, 49(3):285-290.
- [3] Gupta A K, Chang F C, Huang W J. Some skew-symmetric models [J]. Random Operators and Stochastic Equations, 2002, 10(2):133-140.
- [4] Nadarajah S, Kotz S. Skewed distributions generated by the normal kernel [J]. Statistics and Probability Letters, 2003, 65:269-277.
- [5] Fang B Q. The skew elliptical distributions and their quadratic forms [J]. Journal of Multivariate Analysis, 2003, 87(2):298-314.
- [6] Wang J, Genton M G. The multivariate skew-slash distribution [J]. Journal of Statistical Planning and Inference, 2006, 136(1):209-220.
- [7] Elal-Olivero D. Alpha skew normal distribution [J]. Proyecciones Journal of Mathematics, 2010, 29(3):224-240.
- [8] Harandi S S, Alamatsaz M H. Alpha skew Laplace distribution [J]. Statistics and Probability Letters, 2013, 83(3):774-782.
- [9] Hazarika P J, Chakraborty S. Alpha Skew Logistic Distribution [J]. IOSR Journal of Mathematics, 2014, 10(4):36-46.
- [10] Arellano-Valle R B, Bolfarine H and Lachos V H. Skew-normal linear mixed models [J]. Journal of Data Science, 2005, 3:415-438.
- [11] Monti A C. A note on the estimation of the skew normal and the skew exponential power distributions [J]. Metron, 2003, LXI(2):205-219.
- [12] Xie F C, Wei B C, Lin J G. Homogeneity diagnostics for skew-normal nonlinear regression models [J]. Statistics and Probability Letters, 2009, 79(6):821-827.
- [13] Cancho V G, Víctor H. Lachos, Ortega E M M. A nonlinear regression model with skew-normal errors [J]. Statistical Papers, 2010, 51(3):547-558.
- [14] A. Garay, V. Lachos, C. Abanto-Valle. Nonlinear regression models based on scale mixtures of skew-normal distributions [J]. Journal of the Korean Statistical, 2011, 40:115-124.

- [15] Lachos V H, Bandyopadhyay D, Garay A M. Heteroscedastic nonlinear regression models based on scale mixtures of skew-normal distributions [J]. Statistics and Probability Letters, 2011, 81(8):1208-1217.
- [16] Filidor V. Labra, Aldo M. Garay, Victor H. Lachos, Edwin M.M. Ortega. Estimation and diagnostics for heteroscedastic nonlinear regression models based on scale mixtures of skew-normal distributions [J]. Journal of Statistical Planning and Inference, 2012, 142:2149-2165.
- [17] 万文, 吴刘仓, 马梦蝶. 偏正态数据下联合位置与尺度模型的统计诊断[J]. 应用数学, 2017, 30(2):313-321.
- [18] Yalçinkaya A, Şenoğlu B, Yolcu U. Maximum likelihood estimation for the parameters of skew normal distribution using genetic algorithm [J]. Swarm and Evolutionary Computation, 2018, 38:127-38.
- [19] 吴刘仓, 杨松琴, 戴琳. 基于偏正态数据下联合位置与尺度混合专家回归模型的参数估计[J]. 高校应用数学学报 A 辑, 2018, 33(1):36-44.
- [20] Lin J G, Xie F C, Wei B C. Statistical Diagnostics for Skew-t-Normal Nonlinear Models [J]. Communications in Statistics-Simulation and Computation, 2009, 38(10):2096-2110.
- [21] Nadarajah S. The skew logistic distribution [J]. Asta Advances in Statistical Analysis, 2009, 93(2):187-203.
- [22] Azzalini A, Arellano-Valle R B. Maximum penalized likelihood estimation for skew-normal and skew-t distributions [J]. Journal of Statistical Planning and Inference, 2013, 143(2):419-433.
- [23] 吴刘仓, 张家茂, 李玲雪. 缺失偏 t 正态数据下线性回归模型的统计推断[J]. 应用数学, 2015, 28(1):16-25.
- [24] Ferreira Clécio S, Lachos Víctor H. Nonlinear regression models under skew scale mixtures of normal distributions [J]. Statistical Methodology, 2016, 33:131-146.
- [25] Kahrari F, Arellano-Valle R B, Rezaei M, Yousefzadeh F. Scale mixtures of skew-normal-Cauchy distributions [J]. Statistics and Probability Letters, 2017, 126:1-6.
- [26] 田莞, 宗序平. 双参数离散偏拉普拉斯分布的若干性质和参数估计[J]. 天津理工大学学报, 2020, 36(1):54-59.
- [27] 韦博成. 参数统计教程[M]. 北京: 高等教育出版社, 2006.
- [28] Cook R D, Weisberg S. Diagnostics for heteroscedasticity in regression [J]. Biometrika, 1983, 70:1-10.
- [29] 翁云妹. 半参数变系数分位数回归模型及其两阶段估计[D]. 厦门: 厦门大学, 2008.
- [30] 宗序平, 费绍金, 赵俊, 张爱武. 数理统计学及其应用[M]. 北京: 机械工业出版社, 2016.

攻读学位期间取得的研究成果

陈超, 田荒, 宗序平. 偏对称正态分布的若干性质[J]. 淮阴师范学院学报(自然科学版), 18(01):16-22.

致谢

时光荏苒，岁月如梭，充实而快乐的研究生生活即将画上句号，内心充满了万千的不舍与感动。回首这三年在扬州大学的学习与生活，有苦有甜，有辛勤付出时的汗水，也有收获成果时的喜悦。一路走来，我不仅学到了统计学方面的专业知识，而且学会了很多为人处世的道理，有太多的感谢要说。感谢自己曾经选择了读研，以及读研期间的努力与拼搏，无论未来如何，这段奋斗的经历值得我用一生去珍藏。更要感谢三年来在学习和生活中给予我关心与帮助的老师、同学和亲朋好友。

首先，由衷地感谢我最尊敬的导师宗序平教授，您在我未入学之前就是我最想选择的导师，最终非常荣幸地成为了您的学生。学习上，在宗老师的严格要求和悉心指导下，我不仅丰富了专业知识，而且学习到了如何发现问题，思考问题，解决问题。使我掌握了统计学研究的基本思路，同时养成了良好的学习习惯；生活上，宗老师给予了我很多的关心与帮助，引导我积极乐观地面对生活中遇到的挫折，您高尚的人格魅力深深地影响了我。论文写作上，从最初的选题到最终的论文完成，宗老师都一直在悉心指导我，您严谨务实的治学态度与孜孜不倦的工作热情，都深深地感染了我，我也将从中受益终生。在此，衷心地感谢我的导师。

同时，还要由衷地感谢李刚教授，陈建华副教授，严钧副教授，黄健飞副教授等数学科学学院的各位老师，他们教给了我从事统计学研究所需要的基础理论知识，为我今后在专业领域上的进一步学习打下了扎实的基础，由衷地感谢他们。

其次，由衷地感谢我的室友郭浩、田莞、龚浩博，和你们一起度过了人生中最重要的一年，衷心地感谢你们在生活和学习中对我的包容与帮助，这都将成为我人生中最珍贵的回忆。

同时，由衷地感谢数学科学学院数研 17 级的全体同学，你们的一路陪伴和帮助让我感受到了大家庭的温暖，衷心地感谢你们，祝愿你们在人生的旅途中事业有成，前程似锦，也祝愿我们的同学之谊天长地久。

最后，由衷地感谢参考文献中的每一位学术界前辈，他们让我学到了很多统计学方面的专业知识，衷心地感谢他们。